PROJET DE DATA SCIENCE

Analyse des ventes d'une enseigne de fournitures et d'équipements

Étude réalisée à partir du jeu de données

Superstore Dataset



Début du projet : Juillet 2026

Fin du projet : Août 2026

Nom et prénom :	Ngomo Luigy
Niveau d'études :	Master 2
Diplôme :	Mathématiques appliquées, statistiques et Data Science
Dernière expérience professionnelle :	Enseignant de Mathématiques et d'Algorithmique appliquée
Profil LinkedIn :	www.linkedin.com/in/luigy-ngomo-7129312a6
Adresse électronique :	ngomoluigy@gmail.com

Résumé

Ce projet étudie l'ensemble des ventes d'une enseigne de fournitures et d'équipement entre janvier 2014 et décembre 2017, à partir du jeu de données *Superstore Dataset*. Dans cette étude, nous analysons notamment les ventes, les réductions, les quantités vendues et les profits en fonction de différentes caractéristiques.

Le travail comprend notamment l'analyse des valeurs manquantes et des valeurs aberrantes, ainsi que des analyses temporelles et des analyses par mode de livraison, segment de clientèle, catégorie et sous-catégorie de produits, ville, État, produit, etc. Ces différentes analyses permettent de dégager des connaissances sur l'activité de l'enseigne et de formuler des recommandations commerciales.

L'étude comprend également la décomposition des séries temporelles, la prévision de la quantité d'articles vendus et du chiffre d'affaires, ainsi que la segmentation des clients.

Les modèles utilisés pour les prévisions sont notamment : *Meta Prophet*, *Holt-Winters* (*Triple Exponential Smoothing*) et SARIMA. Enfin, l'algorithme K-Means est utilisé pour réaliser la segmentation des clients.

Mots et expressions importantes : Analyse business, rentabilité, chiffre d'affaires, segmentation client, recommandations commerciales stratégiques, machine learning, Meta Prophet, tendance, saisonnalité, résidus, test de Ljung-Box, modèle Holt-Winters, modèle SARIMA, bruit blanc, autocorrélation, tuning d'hyperparamètres, validation croisée K-fold, autoregression, RMSE (Root Mean Square Error), décomposition additive, KPIs, segmentation RFM, méthode du coude, méthode de la silhouette, algorithme K-Means, Analyse en Composante Principale (ACP), etc.

Table des matières

Résumé **1**

Table des figures **4**

I Introduction et objectifs **6**

II Chargement des données **6**

III Familiarisation avec les données **6**

IV Analyse exploratoire des données **8**
IV.1 Gestion des valeurs manquantes 8
IV.2 Gestions des valeurs doubles 8
IV.3 Gestions des valeurs aberrantes 9
IV.4 Corrélations 10

V Visualisations de données et recommandations commerciales stratégiques **11**
V.1 Visualisations temporelles des données 11
V.1.1 Variation du nombre de livraison par mois 11
V.1.2 Variation du montant total des ventes par mois et du nombre de commandes (ventes) par mois 12
V.1.3 Variation du profit total par mois 13
V.1.4 Variation du nombre de commandes bénéficiant d'une remise par mois 14
V.1.5 Variation de la quantité totale vendue par mois 14
V.1.6 Ventes vs profits par année 15
V.1.7 Quantités vs profits par année 16
V.2 Visualisations des données par mode de livraison 17
V.2.1 Répartition des commandes par mode de livraison 17
V.2.2 Distribution du profit total par mode de livraison 18
V.2.3 Distribution du montant total des ventes par mode de livraison . . 18
V.3 Visualisations des données par segment 20
V.3.1 Distribution des commandes par segment de clientèle 20
V.3.2 Distribution du profit total par Segment 21
V.3.3 Distribution du montant total des ventes par Segment 21
V.3.4 Distribution du nombre total de commandes par segment, ventilé par mode de livraison 22
V.3.5 Distribution du montant total des ventes par segment, ventilé par mode de livraison 23
V.3.6 Distribution du profit total par segment, ventilé par mode de livraison 24
V.4 Visualisations des données par Catégories de produits 26
V.4.1 Répartition des commandes clients par catégories de produits . . . 26
V.4.2 Distribution du montant total des ventes par catégorie de produits . 27
V.4.3 Distribution du profit total par catégorie de produits 28
V.5 Visualisations des données par sous-catégories de produits 29
V.5.1 Distribution des commandes par sous-catégories de produits 29
V.5.2 Distribution du profit total par sous-catégories de produits 30

V.5.3 Distribution du montant total des ventes par sous-catégories de produits . . . 31
V.6 Visualisations des données par Région . . . 32
V.6.1 Distribution des commandes par Région . . . 32
V.6.2 Distribution du profit total par Région . . . 33
V.6.3 Distribution du montant total des ventes par Région . . . 34
V.7 Visualisations des Tops 25 par État . . . 35
V.7.1 Top 25 du nombre de commandes par État . . . 35
V.7.2 Top 25 des commandes ayant bénéficié d'une remise par État . . . 36
V.7.3 Top 25 du montant total des ventes par État . . . 36
V.7.4 Top 25 du profit total par État . . . 36
V.8 Visualisations des Tops 25 par ville . . . 38
V.8.1 Top 25 du nombre de commandes par ville . . . 38
V.8.2 Top 25 du profit total par ville . . . 38
V.8.3 Top 25 du montant total des ventes par ville . . . 39
V.8.4 Top 25 du nombre de commandes ayant bénéficié d'une remise par ville . . . 39
V.9 Visualisations des Tops 10 par produit . . . 40
V.9.1 Top 10 du profit total par produit . . . 40
V.9.2 Top 10 du montant total des ventes par produit . . . 41
V.9.3 Top 10 du nombre total de commandes par produit . . . 41
V.10 Visualisations par niveau de réduction . . . 42
V.10.1 Profit total par niveau de réduction . . . 42
V.10.2 Quantité totale vendue par niveau de réduction . . . 43
V.10.3 Montant total des ventes par niveau de réduction . . . 43

VI Décomposition des séries temporelles mensuelles 44

VII Modèles de Prévision de la demande (Demand Forecasting) 46
VII.1 Séparation des données . . . 47
VII.2 Entrainement des modèles . . . 48

VIII Modèles de Prévision des ventes (Sales Forecasting) 51

IX Clients inactifs et KPIs 52
IX.1 Clients perdus et nouveaux clients . . . 52
IX.2 Quelques indicateurs clés de performances . . . 53

X Segmentation des clients par K-Means 55
X.1 Construction des variables RFM et Profit . . . 55
X.2 Méthode du coude, de la silhouette et algorithme K-Means . . . 56
X.2.1 Méthode du coude et méthode de la Silhouette . . . 57
X.2.2 Algorithme K-Means et interprétation commerciale . . . 58
X.3 Visualisations des clusters et identification des clients du groupe "clients VIP" 64

Références 67

Table des figures

1 Aperçu du jeu de données Superstore . . . 6
2 Distributions des variables numériques . . . 9
3 Matrice de corrélations . . . 10
4 Nombre de livraisons par mois . . . 11
5 Montant total des ventes par mois . . . 12
6 Nombre de commandes par mois . . . 12
7 Profit total par mois . . . 13
8 Profit total par année . . . 13
9 Nombre de commandes mensuelles bénéficiant d'une réduction . . . 14
10 Quantité totale d'articles vendus par mois . . . 15
11 Ventes vs profits par année . . . 15
12 Quantités vs profits par année . . . 16
13 Répartition des commandes par mode de livraison . . . 17
14 Profit total par mode de livraison . . . 18
15 Montant total des ventes par mode de livraison . . . 19
16 Distribution des commandes par segment de clientèle . . . 20
17 Profit total par segment de clientèle . . . 21
18 Montant total des ventes par segment de clientèle . . . 22
19 Nombre total de commande par segment, ventilé par mode de livraison . . . 23
20 Montant total des ventes par segment, ventilé par mode de livraison . . . 24
21 Profit total par segment, ventilé par mode de livraison . . . 25
22 Répartition des commandes clients par catégories de produits . . . 26
23 Montant total des ventes par catégorie de produits . . . 27
24 Profit total par catégorie de produits . . . 28
25 Distribution des commandes par sous-catégories de produits . . . 29
26 Profit total par sous-catégories de produits . . . 30
27 Montant total des ventes par sous-catégories de produits . . . 31
28 Répartition des commandes par région . . . 32
29 Profit total par région . . . 33
30 Montant total des ventes par région . . . 34
31 Top 25 des nombres de commandes par État . . . 35
32 Top 25 du nombre de commandes ayant bénéficié d'une remise par État . . . 36
33 Top 25 du montant total des ventes par État . . . 36
34 Top 25 du profit total par État . . . 37
35 Top 25 du nombre de commandes par ville . . . 38
36 Top 25 du profit total par ville . . . 38
37 Top 25 du montant total des ventes par ville . . . 39
38 Top 25 du nombre de commandes ayant bénéficié d'une remise par ville . . . 39
39 Top 10 du profit total par produit . . . 40
40 Top 10 du montant total des ventes par produit . . . 41
41 Top 10 du nombre total de commandes par produit . . . 41
42 Profit total par niveau de réduction . . . 42
43 Profit total avec et sans réduction . . . 42
44 Quantité totale vendue par niveau de réduction . . . 43
45 Quantité totale vendue avec et sans réduction . . . 43
46 Montant total des ventes par niveau de réduction . . . 43

47 Montant total des ventes avec et sans réduction 43
48 Décomposition additive de la quantité totale vendue par mois 45
49 Décomposition additive du montant total des ventes par mois 45
50 Aperçu des 15 premiers mois de la série d'entrainement 47
51 Série de test 47
52 Erreurs de prédictions des 3 modèles sur les 12 mois de test 50
53 Comparaison des prévisions de la quantité totale vendue sur les 12 mois de test avec les valeurs réelles 50
54 Comparaison des prévisions du montant totale des ventes sur les 12 mois de test avec les valeurs réelles 52
55 Quelques indicateurs clés de performances 54
56 Aperçu des 15 premiers cliens et les valeurs des variables RFM et Profit . . 55
57 Aperçu des 15 premiers cliens et les valeurs des variables RFM et Profit standardisées 56
58 Méthode du coude pour le choix du nombre de clusters 57
59 Score de silhouette selon le nombre de clusters 58
60 Clusters associés au 15 premiers clients par l'algorithme K-Means ($k = 3$) . 59
61 Nombre de clients et moyenne des variables par clusters (k=3) 59
62 Clusters associés au 15 premiers clients par l'algorithme K-Means ($k = 4$) . 60
63 Nombre de clients et moyenne des variables par clusters (k=4) 60
64 Clusters associés au 15 premiers clients par l'algorithme K-Means ($k = 5$) . 61
65 Nombre de clients et moyenne des variables par clusters (k=5) 61
66 Nombre de clients et moyenne des variables par clusters (k=5) 62
67 Visualisation des 5 clusters de clients (profit en fonction du chiffre d'affaire) 64
68 Clients du cluster 4 64
69 Visualisation des 5 clusters clients par ACP 65

I Introduction et objectifs

Ce projet a pour objectif principal d'analyser les ventes d'une enseigne de fournitures et d'équipements, puis de formuler des recommandations commerciales à partir des informations dégagées dans le but de contribuer à l'optimisation de l'activité commerciale. L'étude s'articule autour de trois grandes parties essentiellement.

Une première partie est consacrée à la visualisations de données. Elle se concentre sur la visualisation et l'analyse des principales caractéristiques du jeu de données notamment en croisant ses variables pour mettre en évidence les tendances, les relations et les éléments susceptibles d'expliquer les performances commerciales. Les visuels obtenus permettent de dégager différentes connaissances sur l'activité commerciale de l'enseigne et de lui proposer des recommandations commerciales adaptées.

Une deuxième partie est consacrée à l'analyse et à la prévision de deux variables quantitatives importantes du jeu de données : le chiffre d'affaires et la quantité d'articles vendus. L'étude de leur évolution temporelle et la construction des modèles de prévision permettent d'estimer leurs valeurs futures. Ce type de prévision peut aider l'enseigne à mieux anticiper ses besoins en matière de stocks, de logistique et, plus généralement, de ressources nécessaires pour les périodes à venir.

Enfin, une troisième partie est consacrée à la segmentation de la clientèle. Une analyse RFM est d'abord réalisée pour de caractériser les clients. L'algorithme K-Means est ensuite utilisé pour regrouper les clients présentant des comportements commerciaux similaires. Cette segmentation permet d'identifier différents profils de clients et contribue par là même à l'adaptation des stratégies commerciales à des clientèles spécifiques. Cette partie présente d'ailleurs des résultats particulièrement intéressants dans la présente étude..

Le jeu de données est structuré en ligne par commande. Une même commande, identifiée par un même Order ID, peut ainsi apparaître sur plusieurs lignes lorsqu'elle contient plusieurs produits différents.

II Chargement des données

Les données sont au format csv, nous les lisons en python en utilisant pandas

Row ID	Order ID	Order Date	Ship Date	Ship Mode	Customer ID	Customer Name	Segment	Country	City	State	Postal Code	Region	Product ID	Category	Sub-Category	Product Name	Sales	Quantity	Discount	Profit
1	CA-2016-152156	11/8/2016	11/11/2016	Second Class	CG-12520	Claire Gute	Consumer	United States	Henderson	Kentucky	42420	South	FUR-BO-10001798	Furniture	Bookcases	Bush Somerset Collection Bookcase	261.9600	2	0.00	41.9136
2	CA-2016-152156	11/8/2016	11/11/2016	Second Class	CG-12520	Claire Gute	Consumer	United States	Henderson	Kentucky	42420	South	FUR-CH-10000454	Furniture	Chairs	Hon Deluxe Fabric Upholstered Stacking Chairs,...	731.9400	3	0.00	219.5820
3	CA-2016-138688	6/12/2016	6/16/2016	Second Class	DV-13045	Darrin Van Huff	Corporate	United States	Los Angeles	California	90036	West	OFF-LA-10000240	Office Supplies	Labels	Self-Adhesive Address Labels for Typewriters b...	14.6200	2	0.00	6.8714
4	US-2015-108966	10/11/2015	10/18/2015	Standard Class	SO-20335	Sean O'Donnell	Consumer	United States	Fort Lauderdale	Florida	33311	South	FUR-TA-10000577	Furniture	Tables	Bretford CR4500 Series Slim Rectangular Table	957.5775	5	0.45	-383.0310
5	US-2015-108966	10/11/2015	10/18/2015	Standard Class	SO-20335	Sean O'Donnell	Consumer	United States	Fort Lauderdale	Florida	33311	South	OFF-ST-10000760	Office Supplies	Storage	Eldon Fold 'N Roll Cart System	22.3680	2	0.20	2.5164
6	CA-2014-115812	6/9/2014	6/14/2014	Standard Class	BH-11710	Brosina Hoffman	Consumer	United States	Los Angeles	California	90032	West	FUR-FU-10001487	Furniture	Furnishings	Eldon Expressions Wood and Plastic Desk Access...	48.8600	7	0.00	14.1694
7	CA-2014-115812	6/9/2014	6/14/2014	Standard Class	BH-11710	Brosina Hoffman	Consumer	United States	Los Angeles	California	90032	West	OFF-AR-10002833	Office Supplies	Art	Newell 322	7.2800	4	0.00	1.9656
8	CA-2014-115812	6/9/2014	6/14/2014	Standard Class	BH-11710	Brosina Hoffman	Consumer	United States	Los Angeles	California	90032	West	TEC-PH-10002275	Technology	Phones	Mitel 5320 IP Phone VoIP phone	907.1520	6	0.20	90.7152
9	CA-2014-115812	6/9/2014	6/14/2014	Standard Class	BH-11710	Brosina Hoffman	Consumer	United States	Los Angeles	California	90032	West	OFF-BI-10003910	Office Supplies	Binders	DXL Angle-View Binders with Locking Rings by S...	18.5040	3	0.20	5.7825
10	CA-2014-115812	6/9/2014	6/14/2014	Standard Class	BH-11710	Brosina Hoffman	Consumer	United States	Los Angeles	California	90032	West	OFF-AP-10002892	Office Supplies	Appliances	Belkin F5C206VTEL 6 Outlet Surge	114.9000	5	0.00	34.4700

FIGURE 1 – Aperçu du jeu de données Superstore

III Familiarisation avec les données

Nous affichons ci-dessous certaines informations sur le jeu de données afin de mieux nous familiarisé avec ce dernier :

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9994 entries, 0 to 9993
Data columns (total 21 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
 0   Row ID         9994 non-null   int64
 1   Order ID       9994 non-null   object
 2   Order Date     9994 non-null   object
 3   Ship Date      9994 non-null   object
 4   Ship Mode      9994 non-null   object
 5   Customer ID    9994 non-null   object
 6   Customer Name  9994 non-null   object
 7   Segment        9994 non-null   object
 8   Country        9994 non-null   object
 9   City           9994 non-null   object
 10  State          9994 non-null   object
 11  Postal Code    9994 non-null   int64
 12  Region         9994 non-null   object
 13  Product ID     9994 non-null   object
 14  Category       9994 non-null   object
 15  Sub-Category   9994 non-null   object
 16  Product Name   9994 non-null   object
 17  Sales          9994 non-null   float64
 18  Quantity       9994 non-null   int64
 19  Discount       9994 non-null   float64
 20  Profit         9994 non-null   float64
dtypes: float64(3), int64(3), object(15)
```

Le jeu de données comporte donc au total 9994 observations et 21 variables. Il a 3 types de données : int64 (entier), float64 (nombre réel), objet (texte).
Aucune variable ne contient des valeurs manquantes.

Nous affichons ci-après un petit résumer par commandes sur les principales variables numériques du jeu de données :

`Nombre total de commandes` : 5 009

`Fourchette du montant total des ventes par commande` : $0,56$ - $23\ 661,23$

`Fourchette du profit total par commande` : $-6\ 892,37$ - $8\ 762,39$

`Fourchette des réductions appliquées` : 0% - 80%

`Fourchette de la quantité totale vendue par commande` : 1 - 52

Les montants des ventes varient de $0,56$ dollars à $23\ 661,23$ dollars. Il y a donc une très forte hétérogénéité des montants des ventes. Le jeu de données contient à la fois des commandes de très faible montant et des commandes de très grande valeur. Cela suggère que l'entreprise commercialise des produits couvrant une large gamme de prix ou que certaines commandes regroupent plusieurs articles.

Le profit total par commande varie de $-6\ 892,37$ dollars à $8\ 762,39$ dollars. Ce qui montre que certaines commandes génèrent des pertes importantes tandis que d'autres sont très

rentables. Une telle variabilité indique que toutes les ventes ne contribuent pas de la même manière à la rentabilité de l'entreprise et justifie une analyse plus approfondie des facteurs influençant le profit, comme les remises, les catégories de produits ou les mêmes régions.

Les remises accordées par commandes varient de 0% à 80%. Cela montre que certaines commandes sont vendues sans réduction, alors que d'autres bénéficient de remises très importantes. Ce qui suggère une politique commerciale flexible et conduit naturellement à s'interroger sur l'impact des remises sur les ventes et sur la rentabilité.

Les quantités totales d'articles vendues par commandes varient de 1 à 52, ce qui montre qu'il y a une très grande hétérogénéité du volume d'articles par commandes. Certaines commandes peuvent contenir juste un article par exemple tandis que d'autres peuvent en contenir jusqu'à une cinquantaine d'articles.

IV Analyse exploratoire des données

IV.1 Gestion des valeurs manquantes

Comme remarqué à la partie précédente, le jeu de données ne contient pas de valeurs manquantes (NAN) :

```
Nombre de valeurs manquantes par variable :
Row ID           0
Order ID         0
Order Date       0
Ship Date        0
Ship Mode        0
Customer ID      0
Customer Name    0
Segment          0
Country          0
City             0
State            0
Postal Code      0
Region           0
Product ID       0
Category         0
Sub-Category     0
Product Name     0
Sales            0
Quantity         0
Discount         0
Profit           0
```

IV.2 Gestions des valeurs doubles

Le dataset ne contient aucunes observations doubles :

```
Nombre de lignes dupliquées : 0
Nombre de lignes uniques : 9994
```

IV.3 Gestions des valeurs aberrantes

Nous visualisons ci-dessous les histogrammes et les boxplots des variables numériques du dataset (exceptée Row ID) :

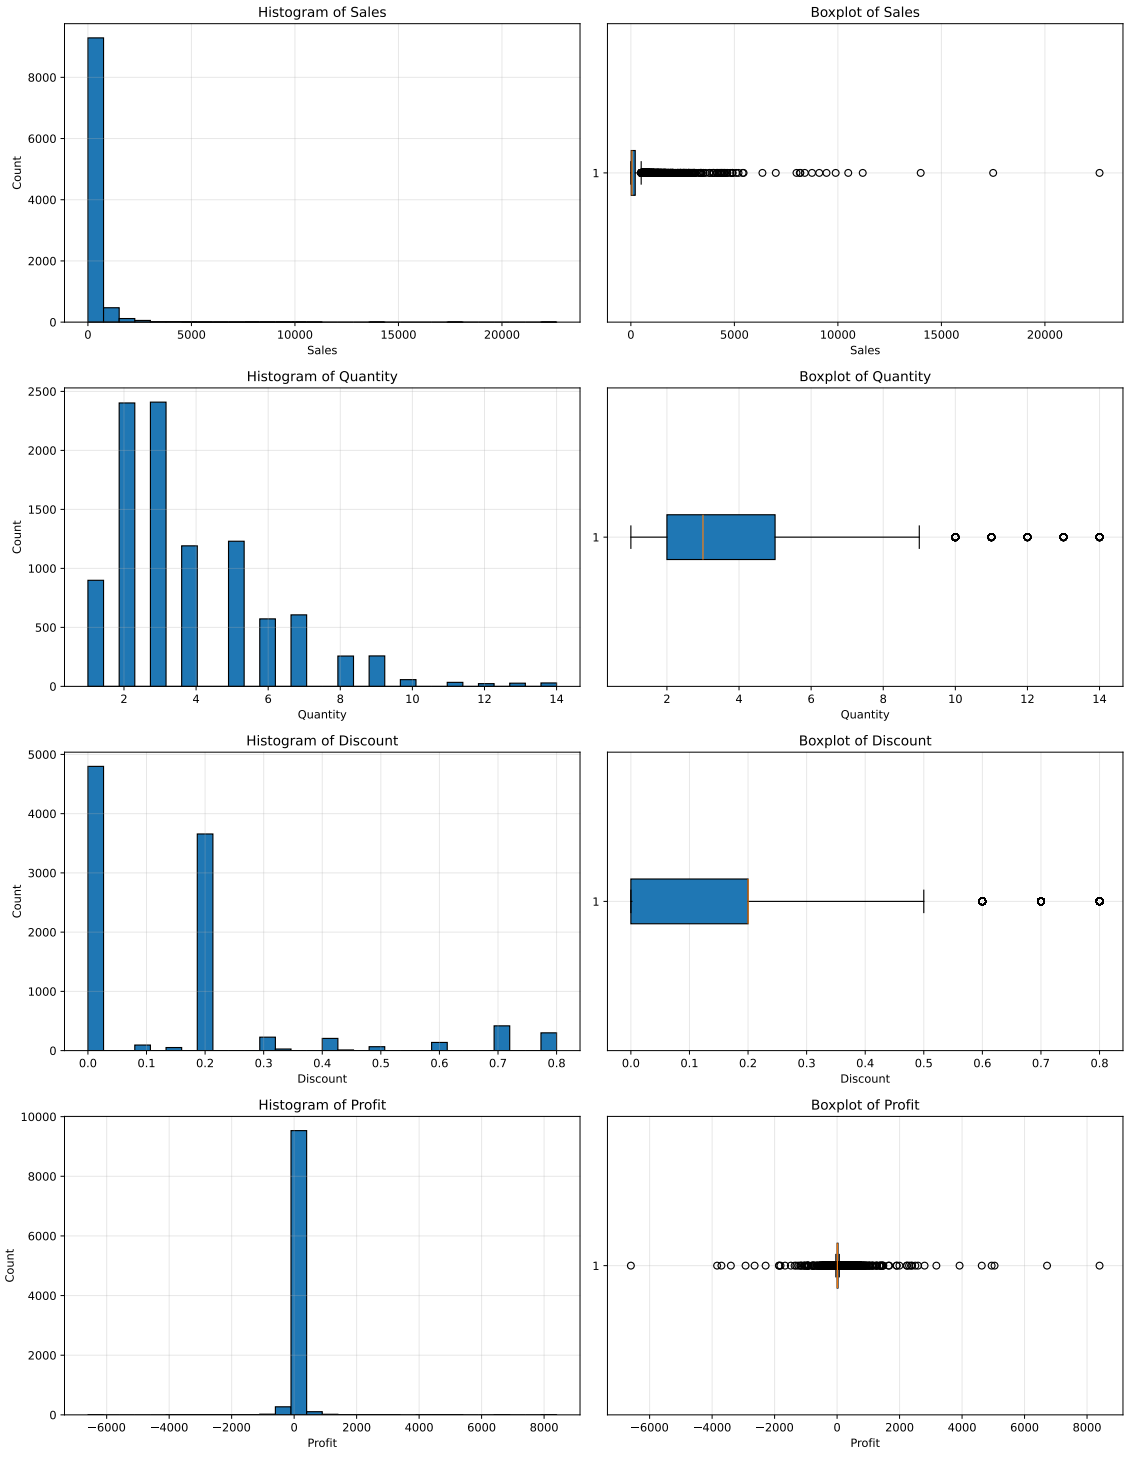


FIGURE 2 – Distributions des variables numériques

Les histogrammes et les boxplots mettent en évidence la présence de valeurs extrêmes, notamment pour les variables Sales, Quantity et Profit. Ces valeurs correspondent très probablement à des commandes réelles (commandes volumineuses, profits ou pertes im-

portants) plutôt qu'à des erreurs de saisie. Elles sont donc conservées pour les analyses ultérieures.

IV.4 Corrélations

Nous affichons ci-après la matrice de corrélations des variables numériques quantitatives :

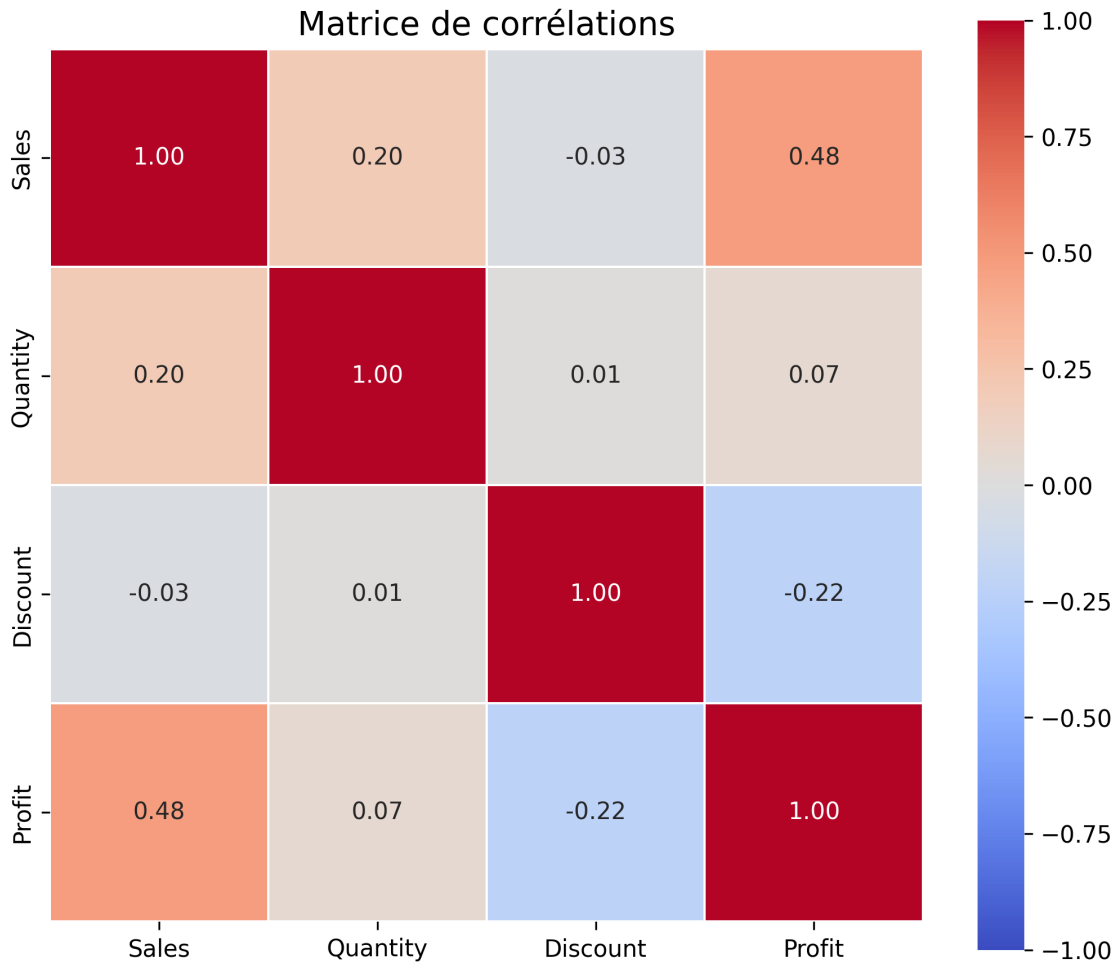


FIGURE 3 – Matrice de corrélations

Les commandes avec des montants de vente élevés semblent tendre à produire des profits plus importants. Toutefois, cette relation reste modérée (0,48), ce qui indiquerait sans doute que d'autres facteurs, comme les remises ou le type de produit par exemple, influenceraient également la rentabilité.

Une augmentation des remises est globalement associée à une diminution du profit. Bien que cette corrélation soit relativement faible, elle suggère néanmoins qu'accorder des réductions importantes tend à réduire la rentabilité des ventes.

Les commandes contenant davantage d'articles ont tendance à générer un montant de vente plus élevé. Cependant, cette relation reste faible, ce qui laisse penser que le prix unitaire des produits joue également un rôle important dans le montant total des ventes.

La quantité vendue présente une corrélation très faible avec le profit. Le fait de vendre davantage d'articles n'entraîne donc pas nécessairement une augmentation du bénéfice.

Aucune relation linéaire significative n'est observée entre les remises accordées et le montant des ventes. Les réductions ne semblent donc pas être directement associées à une augmentation du montant des ventes.

La quantité commandée ne présente pratiquement aucune relation linéaire avec le niveau de remise accordé.

Dans l'ensemble, les coefficients de corrélation sont relativement faibles à modérés. Cela suggère que les relations entre les variables numériques sont limitées et donc qu'une part importante de la variabilité des ventes et du profit est probablement expliquée par d'autres variables du jeu de données, comme la catégorie de produit, le segment de clientèle, la région ou le mode d'expédition.

V Visualisations de données et recommandations commerciales stratégiques

V.1 Visualisations temporelles des données

V.1.1 Variation du nombre de livraison par mois

Le graphique suivant répond aux questions de savoir : comment évolue le nombre de livraisons au fils du temps ? Existe-t-il une saisonnalité ?

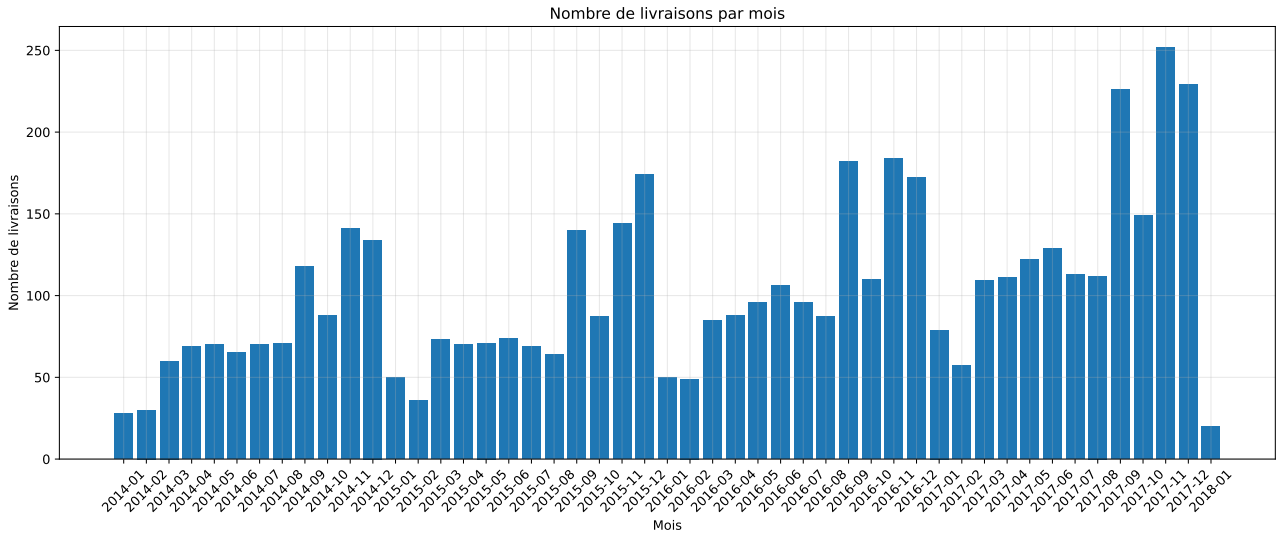


FIGURE 4 – Nombre de livraisons par mois

On observe que globalement, le nombre de livraison augmente entre 2014 et 2017. On constate également que chaque année, les 4 derniers mois (septembre à décembre) présentent souvent davantage de livraisons que le reste des mois.

Recommandations :

L'enseigne pourrait :

- prévoir davantage de personnel logistique entre septembre et décembre
- augmenter les stocks avant cette période
- anticiper les besoin en transport

V.1.2 Variation du montant total des ventes par mois et du nombre de commandes (ventes) par mois

Le premier graphique répond à la question de savoir : comment évolue le chiffre d'affaire au fil du temps ? Et le second : comment évolue le nombre de commandes avec le temps ? Ce qui peut permettre au passage de savoir, dans le cas où le chiffre d'affaire augmente, s'il augmente principalement parce qu'il y a davantage de commandes ou parce que les commandes des clients deviennent plus importantes en montant.

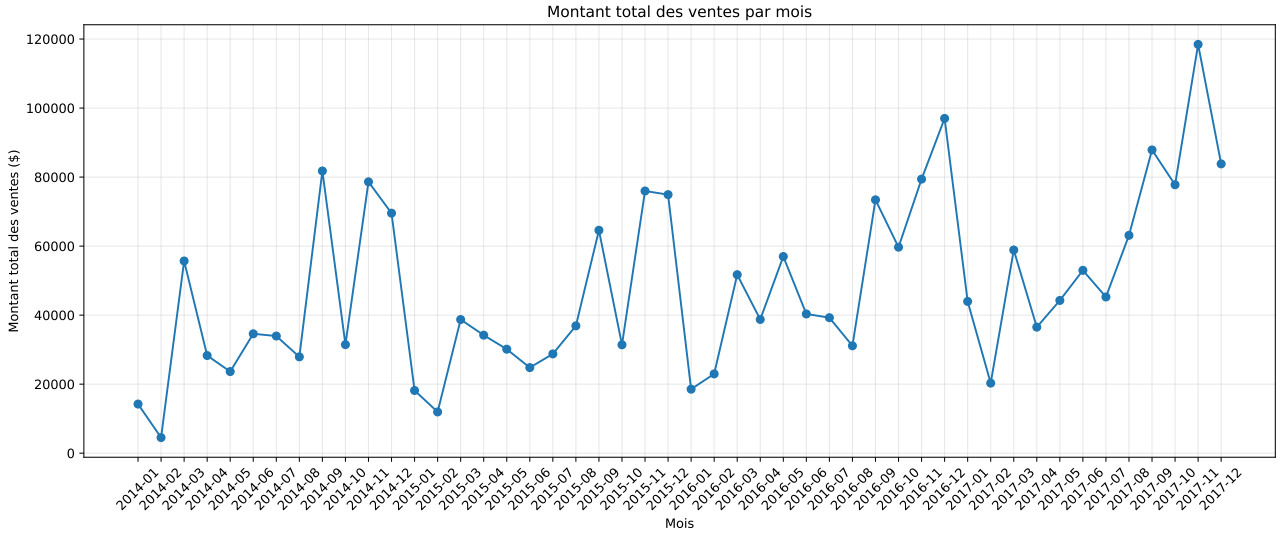


FIGURE 5 – Montant total des ventes par mois

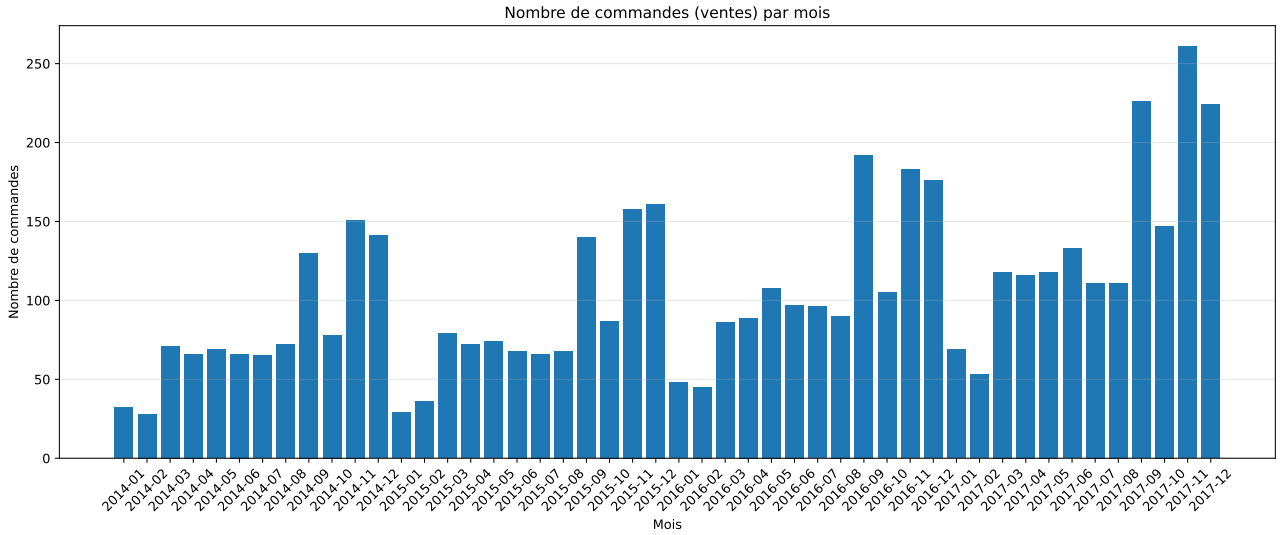


FIGURE 6 – Nombre de commandes par mois

Le montant total des ventes augmentent globalement de 2014 à 2017. Les ventes sont généralement plus importantes durant les derniers mois de l'année (septembre à décembre).

De même, le nombre de commandes suit aussi la même tendance, il augment globalement sur la période étudiée. Chaque année, il est le plus important sur les 4 derniers mois à peu près.

En comparant ces observations, on peut imaginer qu'une partie de la croissance du chiffre d'affaire provient d'une augmentation du volume des commandes.

Recommandations :

L'enseigne pourrait :

- Concentrer ses campagnes marketing durant les mois les plus rentables
- préparer davantage de stock avant ces périodes
- renforcer ses équipes pendant les périodes où le nombre de commandes explose et adapter sa capacité logistique

V.1.3 Variation du profit total par mois

Le graphique suivant répond à la question : comment évolue la rentabilité au fils du temps ?

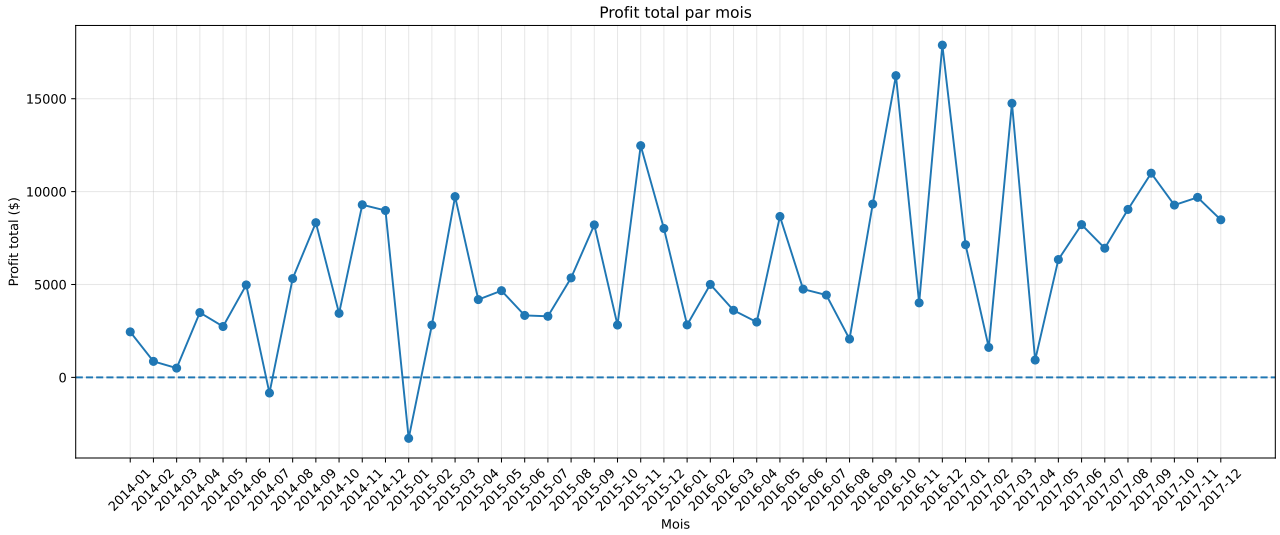


FIGURE 7 – Profit total par mois

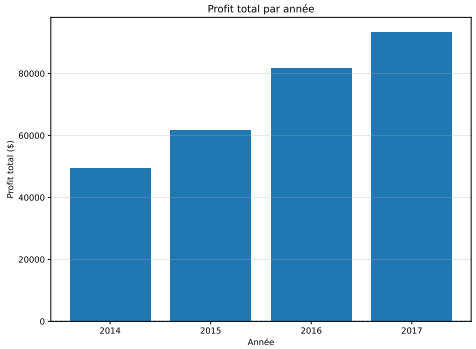


FIGURE 8 – Profit total par année

On peut voir que le profit augmente au fil des année. Chaque année, le profit est souvent le plus important entre les mois de septembre à décembre à peu près. On observe également plusieurs mois où le profit baisse fortement, voire devient négatif. Cela mérite une analyse particulière.

Recommandation :

L'enseigne pourrait :

- analyser les mois déficitaires ; les causes possibles : promotions, coûts logistiques, catégories peu rentables, etc.

V.1.4 Variation du nombre de commandes bénéficiant d'une remise par mois

Le graphique suivant nous permet de répondre à la question : comment évolue l'utilisation des promotions au cours du temps ?

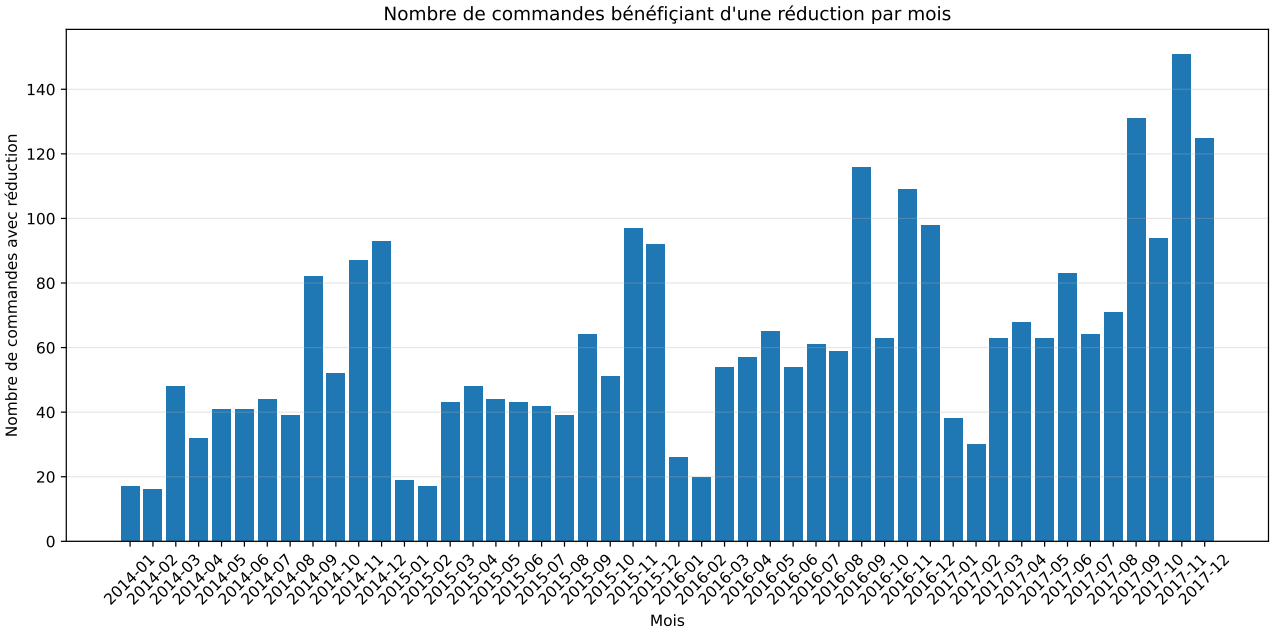


FIGURE 9 – Nombre de commandes mensuelles bénéficiant d'une réduction

On peut voir que le nombre total de commandes par mois bénéficiant d'une réduction suit la même tendance générale que le nombre total de commandes ou le montant total des ventes par mois. Les remises semblent donc être plus nombreuses lorsque l'activité commerciale augmente, ce qui semble logique : plus le nombre total de commandes augmente, plus on est susceptible d'avoir un nombre important de commandes bénéficiant d'une remise.

Recommandations :

L'enseigne pourrait planifier davantage les promotions pendant les périodes ou elles semblent les plus efficaces ; et vérifier que ces promotions génèrent davantage de profits

V.1.5 Variation de la quantité totale vendue par mois

Le graphique suivant permet de répondre à la question : comment évolue le volume d'articles vendus au fil du temps ?

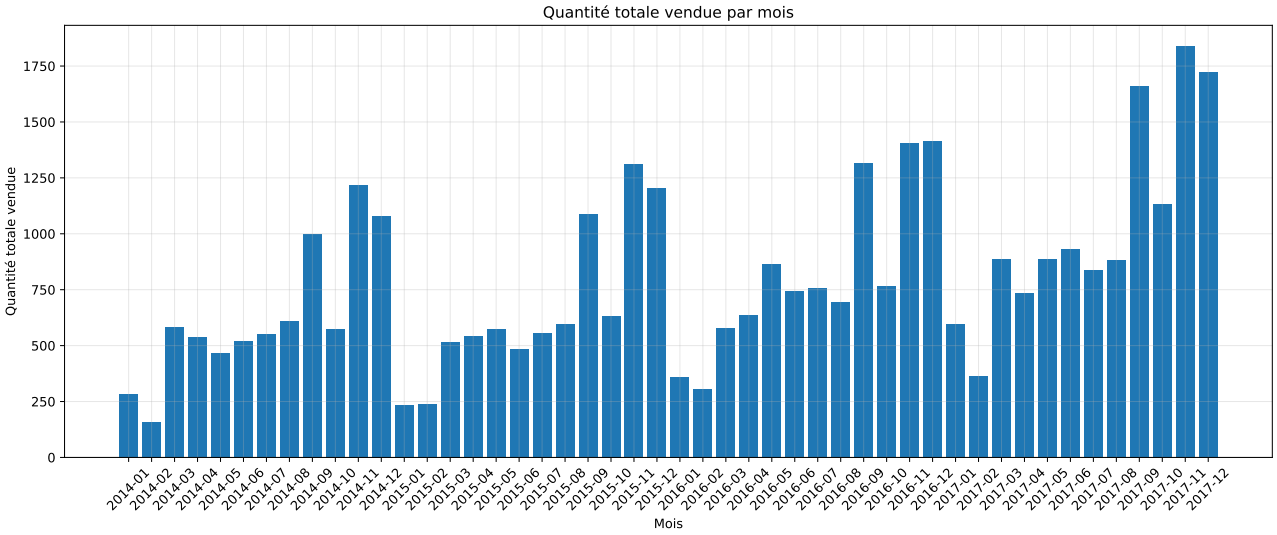


FIGURE 10 – Quantité totale d'articles vendus par mois

La quantité total vendue par mois augmente globalement sur la période étudiée. Et chaque année elle est la plus élevée environ vers les mois de septembre à décembre. On peut également ajouter que, lorsque le nombre de commandes augmente, la quantité augmente aussi. Cela pourrait signifier que la croissance du chiffre d'affaire ne provient pas seulement de l'augmentation du nombre de commandes mais aussi du nombre d'articles vendus.

Recommandation :

L'enseigne pourrait prévoir d'avantage de stock et de personnel en entrepôt

V.1.6 Ventes vs profits par année

Le graphique suivant permet de répondre à la question : l'augmentation du chiffre d'affaires s'accompagne-t-elle d'une augmentation du profit ?

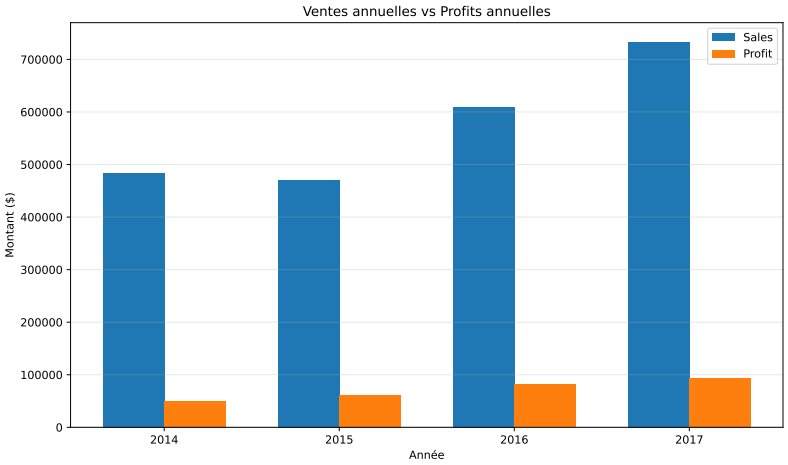


FIGURE 11 – Ventes vs profits par année

L'évolution du profit suit globalement celle des ventes, ce qui montre que l'augmentation du chiffre d'affaires ne s'effectue pas au détriment de la rentabilité.

Recommandation :

L'enseigne pourrait :

- maintenir et continuer les stratégies commerciales ayant permis cette croissance.

V.1.7 Quantités vs profits par année

Le graphique suivant permet de répondre à la question : l'augmentation du volume vendu s'accompagne t'il d'une augmentation du profit ?

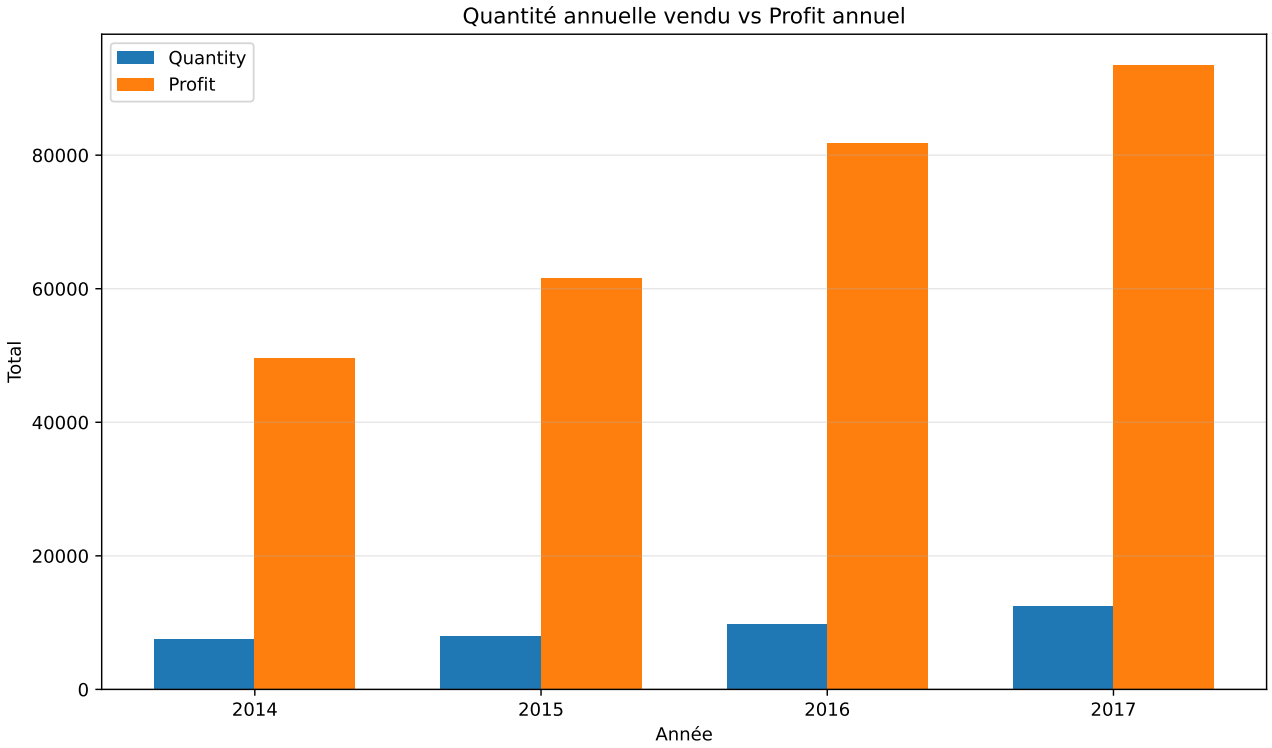


FIGURE 12 – Quantités vs profits par année

Les années où davantage d'articles sont vendus sont également celles où le profit est le plus élevé.

Bilan de fin de sous-section :

L'ensemble des visualisations temporelles met en évidence une croissance progressive de l'activité commerciale entre 2014 et 2017. Le nombre de commandes, les livraisons, les ventes, les quantités vendues ainsi que les profits présentent une tendance générale à la hausse.
Aussi, les derniers mois de chaque année se présentent souvent comme les périodes les plus dynamiques, suggérant un effet de saisonnalité. Ces résultats indiquent que l'enseigne devrait non seulement maintenir et continuer les stratégies commerciales ayant permis cette croissance mais aussi anticiper une augmentation de la demande en renforçant ses stocks, ses capacités logistiques et ses effectifs durant les périodes de forte activité.

V.2 Visualisations des données par mode de livraison

V.2.1 Répartition des commandes par mode de livraison

Le graphique suivant permet de répondre à la question : comment sont répartis les commandes entre les différentes modes de livraison utilisés par les clients ?

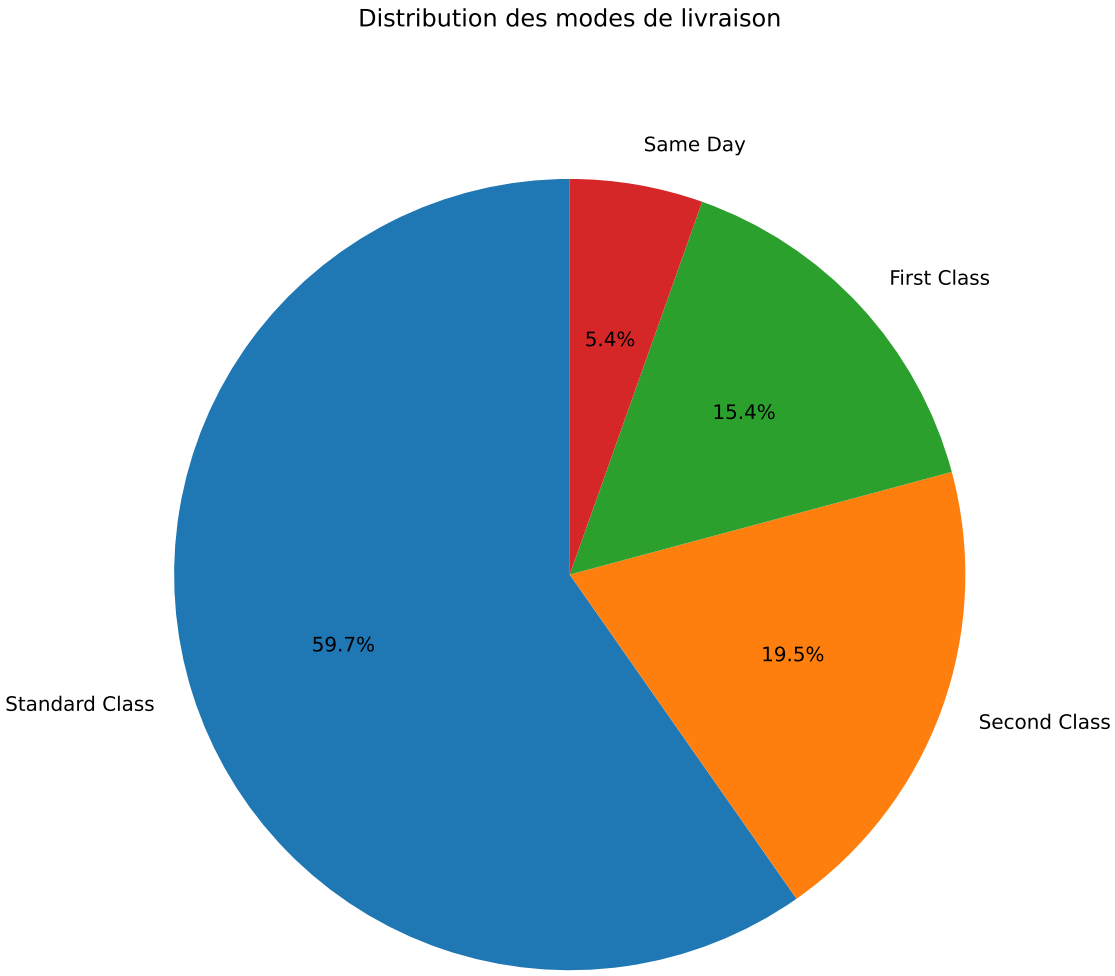


FIGURE 13 – Répartition des commandes par mode de livraison

On peut voir que Standard Class est de loin (59, 7%) le mode de livraison le plus utilisé par les clients, suivit de Second Class puis de First Class et en dernier de Same Day.

Recommandations :

L'enseigne pourrait :

- Continuer à investir dans le mode Standard Class, puisqu'il constitue le principal mode de livraison choisi par les clients
- maintenir une bonne qualité de service sur ce mode de livraison

- analyser les raisons de la faible utilisation de Same Day afin de déterminer si ce service répond réellement à un besoin ou s'il pourrait être améliorer

V.2.2 Distribution du profit total par mode de livraison

Le graphique suivant répond à la question : dans quelles mesures chaque mode de livraison contribue t'il au profit total ?

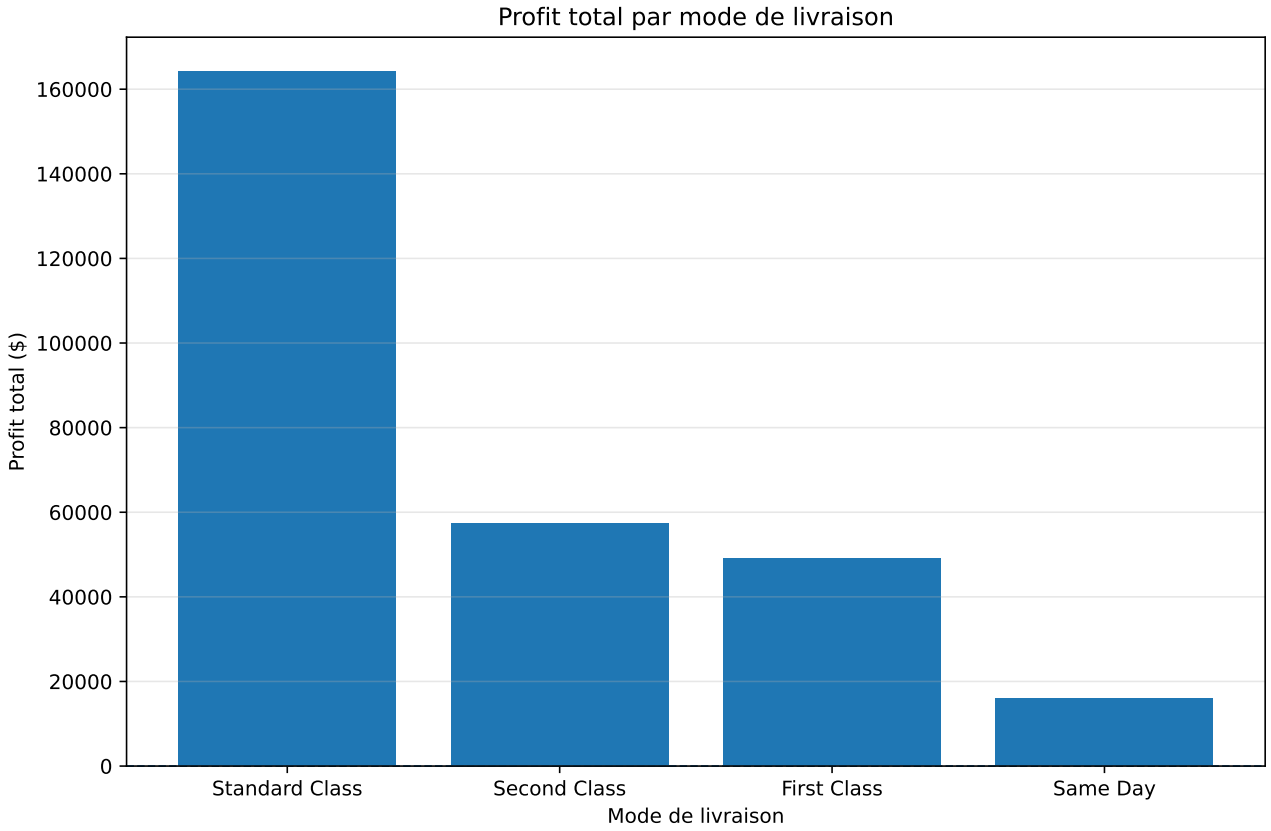


FIGURE 14 – Profit total par mode de livraison

On voit que le mode de livraison le plus utilisé est aussi celui qui contribue le plus au profit : Standard Class. Son profit élevé s'explique donc en grande partie par le nombre important de commandes qui l'utilise.

Recommandation :

L'enseigne pourrait :

- continuer à optimiser le mode Standard Class qui constitue le mode de livraison principal source de profit par rapport aux autres.

V.2.3 Distribution du montant total des ventes par mode de livraison

Le graphique suivant répond à la question : dans quelles mesures chaque mode de livraison contribue t'il au chiffre d'affaires ?

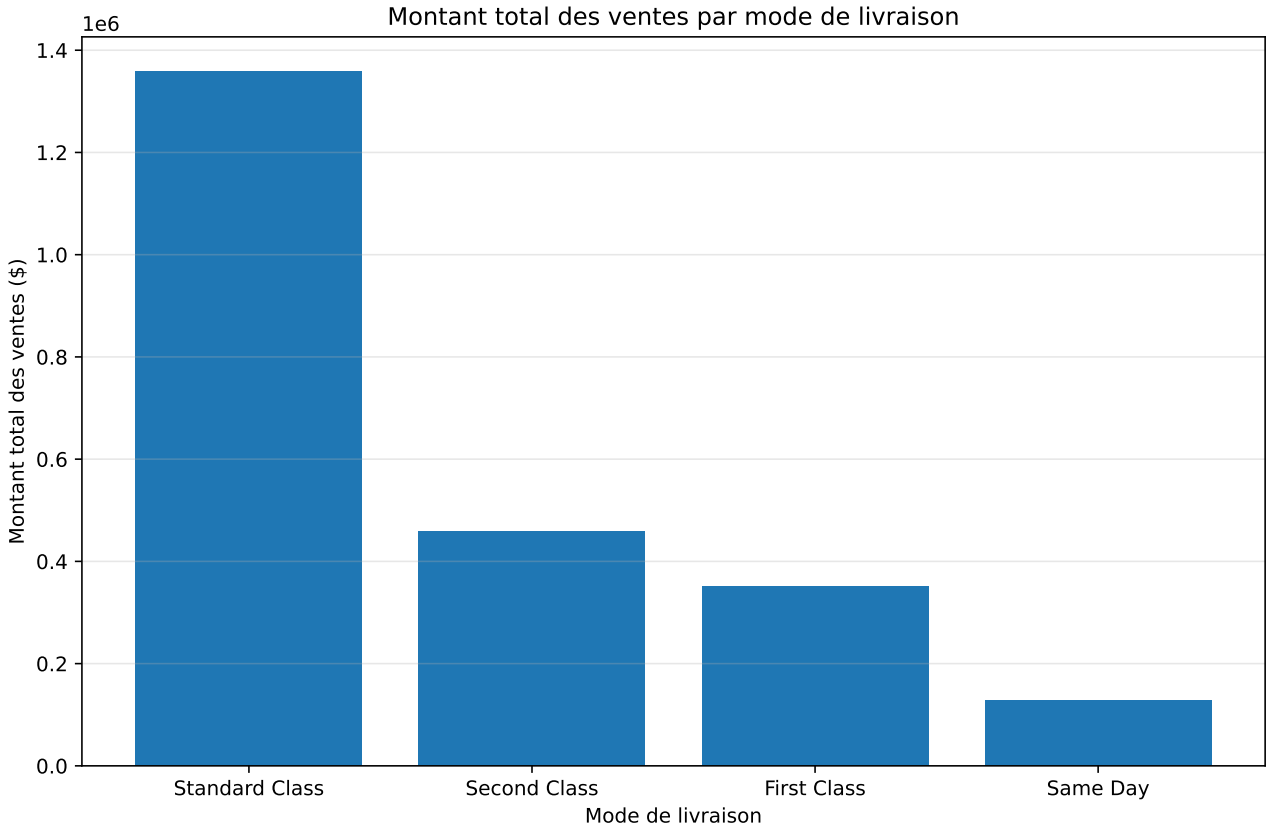


FIGURE 15 – Montant total des ventes par mode de livraison

Les résultats suivent la même hiérarchie qu'avec le profit. Standard Class qui est le mode de livraison le plus utilisé, il est celui qui contribue le plus au montant total des ventes et au profit.

Recommandations :

L'enseigne pourrait :

- continuer à privilégier Standard Class qui constitue le mode de livraison moteur principal de l'activité commerciale.
- réévaluer le positionnement du service Same Day si son coût de fonctionnement est élevé par rapport à son volume d'activité.
- développer des offres adaptées aux utilisateurs de First Class et Second Class afin d'augmenter progressivement leur utilisation.

Bilan de fin de sous-section :

Le mode de livraison Standard Class est le plus utilisé par les clients. Il est également celui qui contribue le plus au chiffre d'affaires et au profit total. Cette domination s'explique très probablement par le fait qu'il concentre près de 60% des commandes. Tout cela justifie que l'enseigne continue à investir, optimiser et maintenir une bonne qualité de service sur ce mode.
À l'inverse, le mode Same Day est peu utilisé et contribue faiblement aux ventes ainsi qu'au profit, ce qui peut justifier une analyse plus approfondie sur ce mode de livraison.

V.3 Visualisations des données par segment

V.3.1 Distribution des commandes par segment de clientèle

Le graphique suivant répond à la question : comment se répartissent les commandes entre les différents segments de clientèle ?

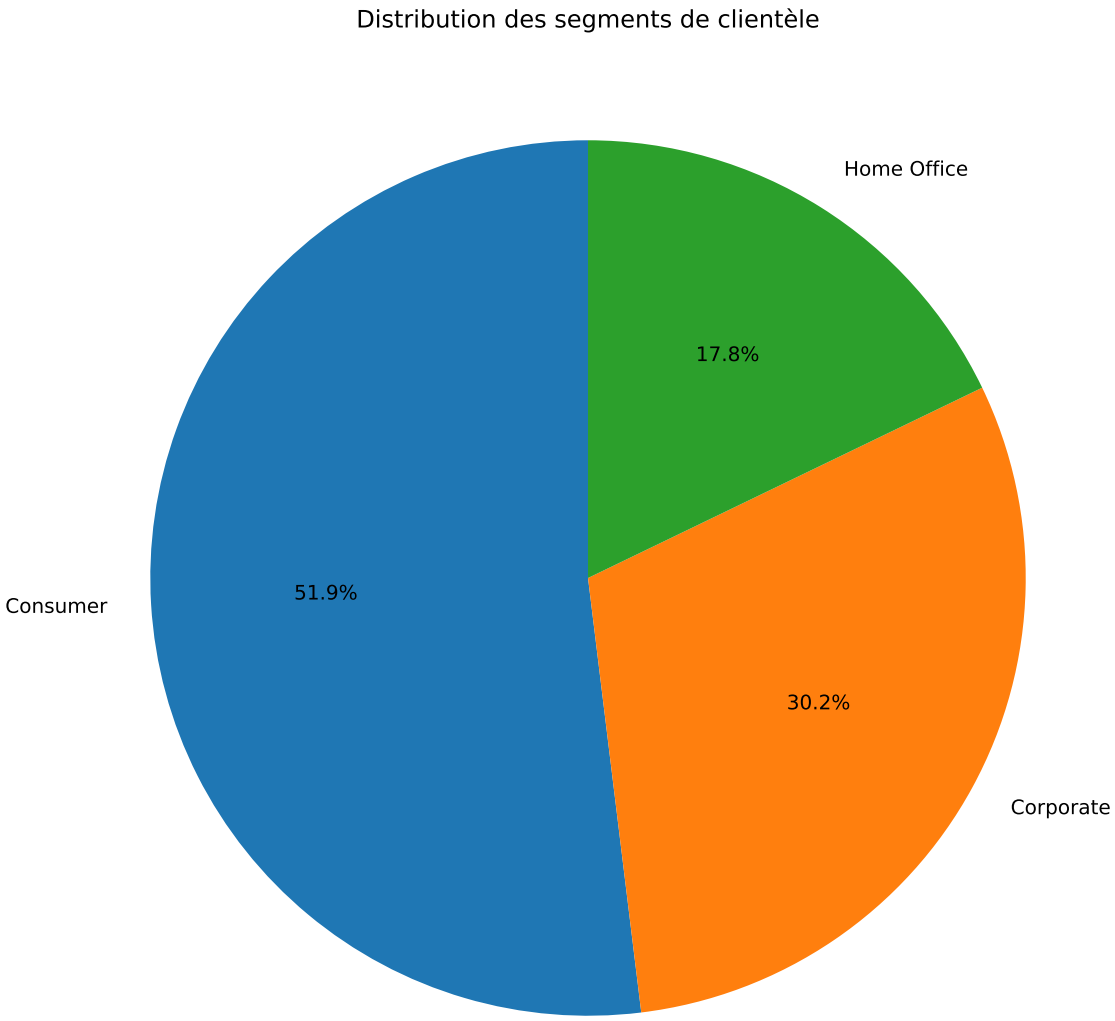


FIGURE 16 – Distribution des commandes par segment de clientèle

Le segment Consumer représente la majorité des commandes (51, 9%) suivit de Corporate (30, 2%) et de home office (17, 8%).

Recommandations :

L'enseigne pourrait :

- Continuer à fidéliser les clients Consumer, qui constituent la principale clientèle
- Développer des actions commerciales ciblées pour les segments Corporate et Home office afin d'augmenter leur part dans les commandes

V.3.2 Distribution du profit total par Segment

Le graphique suivant répond à la question : dans quelles mesures chaque segment de clientèle contribue t'il au profit ?

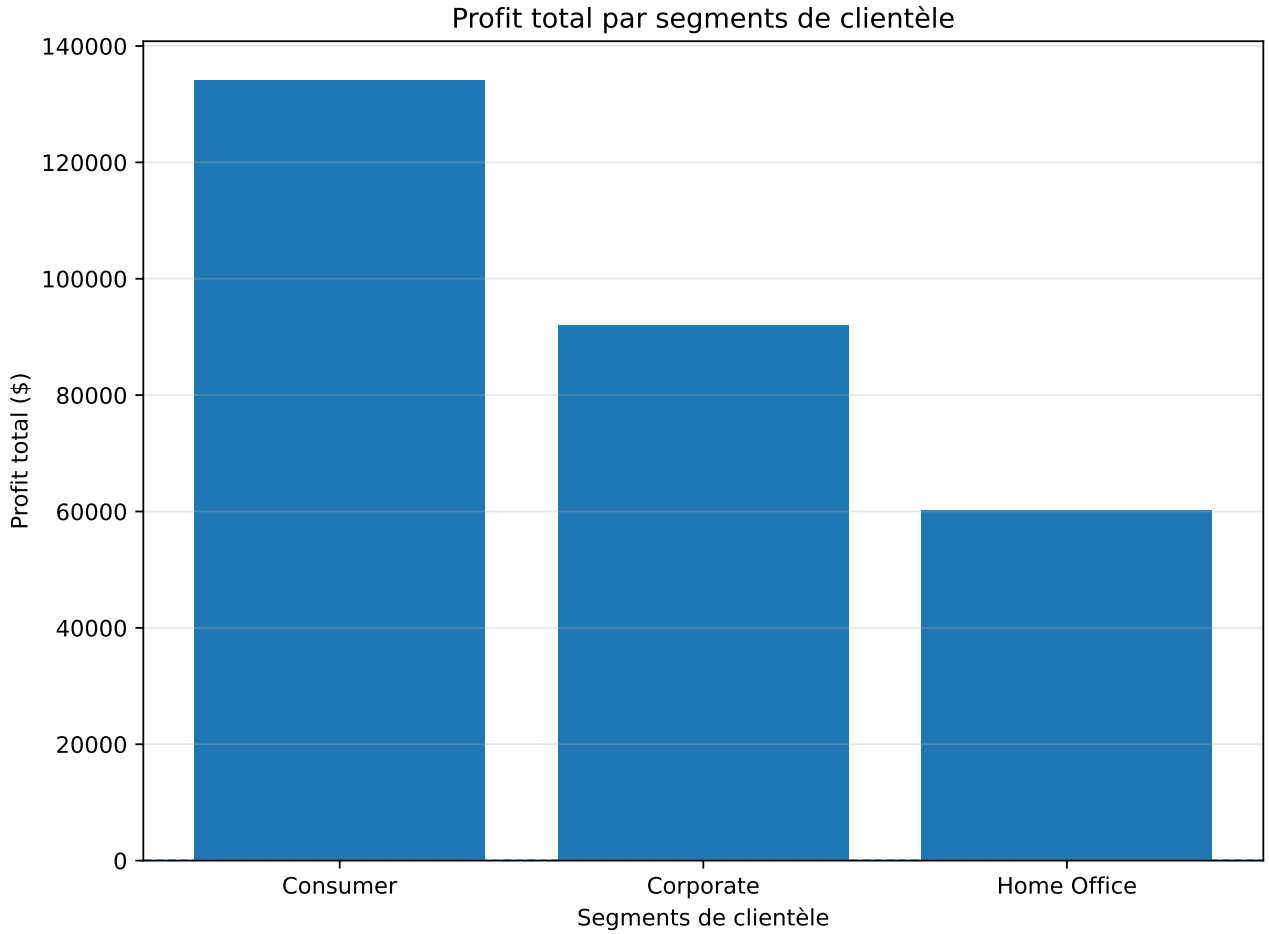


FIGURE 17 – Profit total par segment de clientèle

On constate que le segment majoritaire Consumer est aussi celui qui contribue le plus au profit total, mais suivit de pas très loin par le segment Corporate, qui contribue également de manière importante. Le segment Homme Office est celui qui contribue le moins au profit total.

Recommandations :

L'enseigne pourrait :

- consolider les actions de fidélisations auprès du segment Consumer
- identifier les catégories de produits les plus rentables pour les segments Corporate et Home Office afin d'accroître leur contribution au profit total.

V.3.3 Distribution du montant total des ventes par Segment

Le graphique suivant répond à la question : comment le chiffre d'affaire est-il répartie par segment de clientèle ?

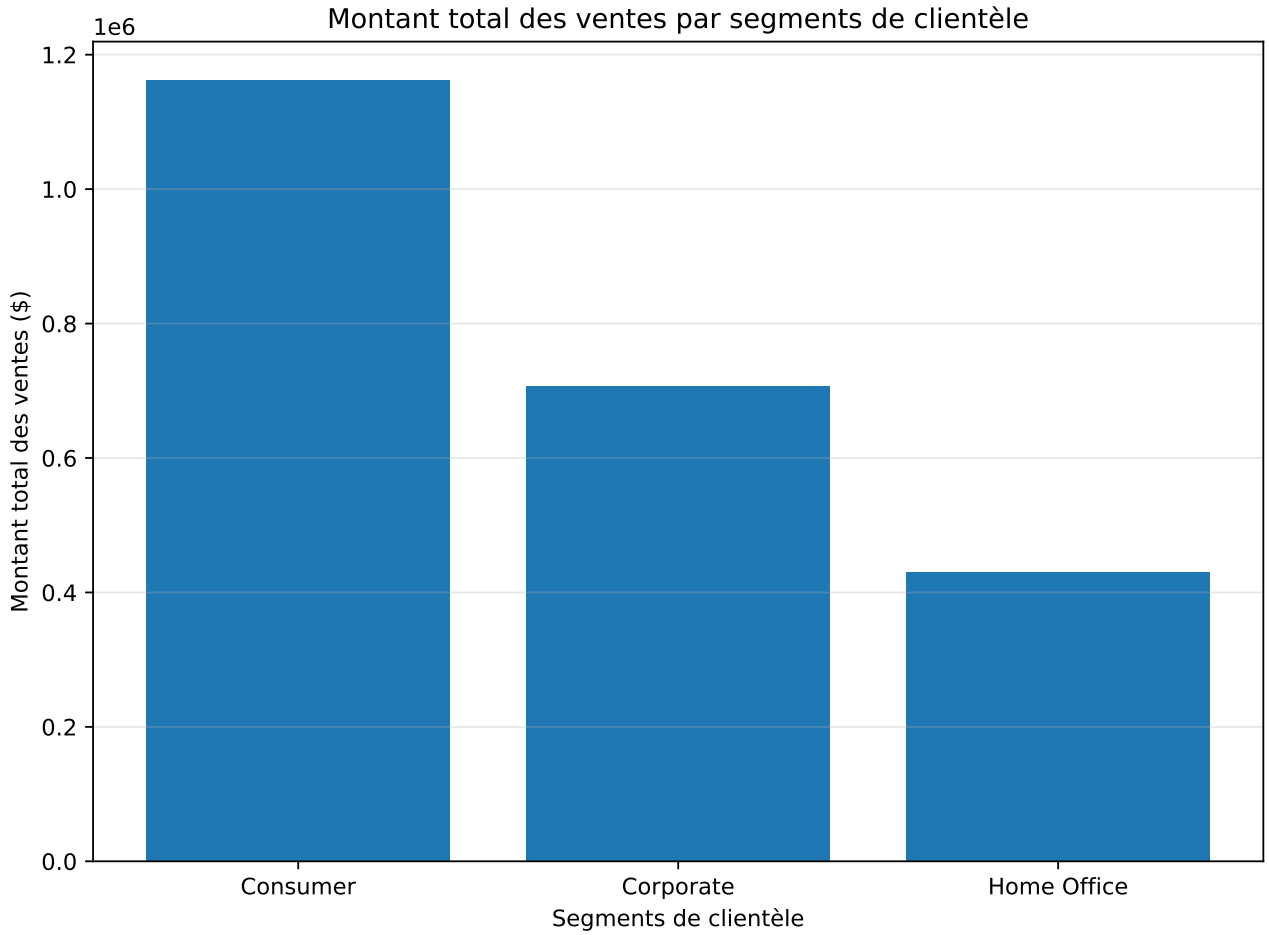


FIGURE 18 – Montant total des ventes par segment de clientèle

On peut observer que le segment Consumer contribue le plus au chiffre d'affaires. Corporate arrive en deuxième. Et Home Office contribue le moins aux ventes. Cette hiérarchie est cohérente avec la répartition des segments de clientèles observée précédemment sur le profit total.

Recommandations :

L'enseigne pourrait :

- Maintenir une offre attractive pour le segment Consumer
- Développer des offres spécifiques destinées aux segments Corporate et Home Office.

V.3.4 Distribution du nombre total de commandes par segment, ventilé par mode de livraison

Le graphique suivant répond à la question : comment les différents modes de livraison sont-ils utilisés selon chaque segment de clientèle ?

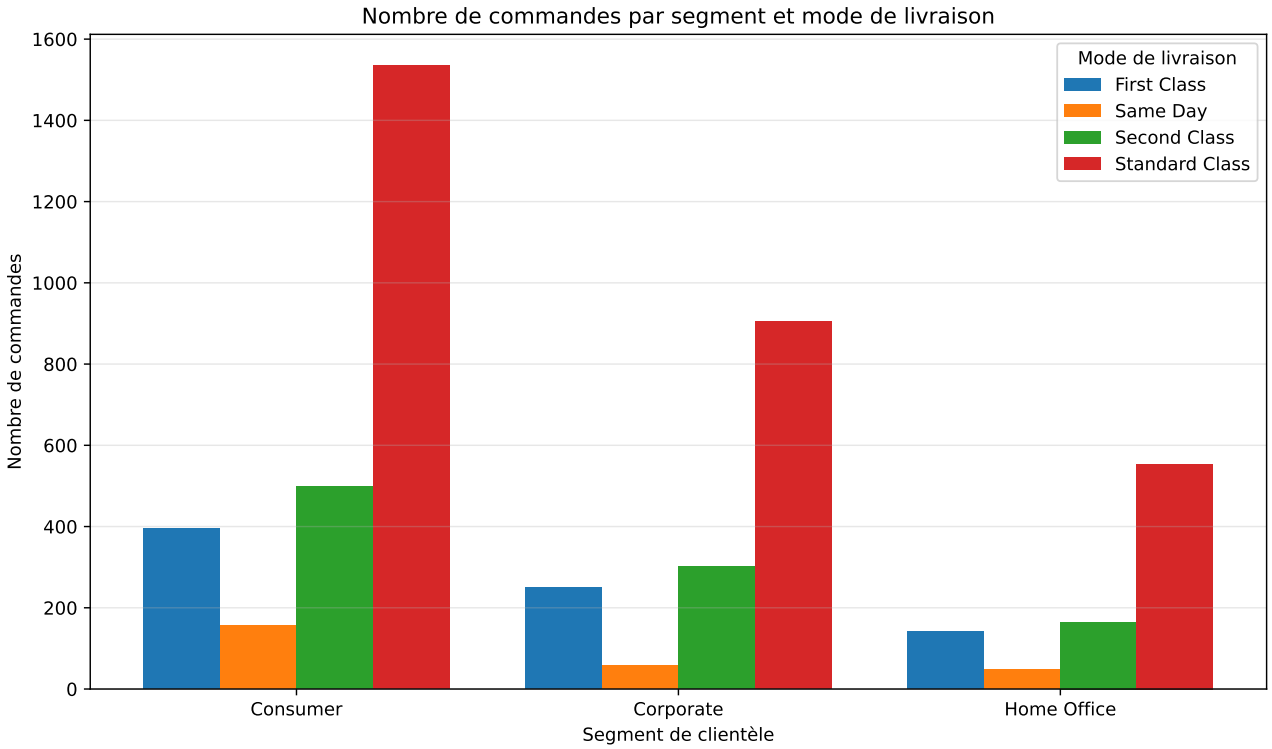


FIGURE 19 – Nombre total de commande par segment, ventilé par mode de livraison

On peut voir que quel que soit le segment, Standard Class est le mode de livraison le plus utilisé. Le segment Consumer passe le plus grand nombre de commandes pour chacun des modes de livraison. Same Day est le mode de livraison le moins utilisé dans tous les segments.

Recommandations :

- Continuer à optimiser le service Standard Class, qui est privilégié par tous les segments.
- Étudier les raisons de la faible utilisation du mode de livraison Same Day.
- Adapter les services de livraison aux besoins spécifiques de chaque segment

V.3.5 Distribution du montant total des ventes par segment, ventilé par mode de livraison

Le graphique suivant répond à la question : comment le chiffre d'affaires se répartit-il selon le segment de clientèle ventilé par mode de livraison ?

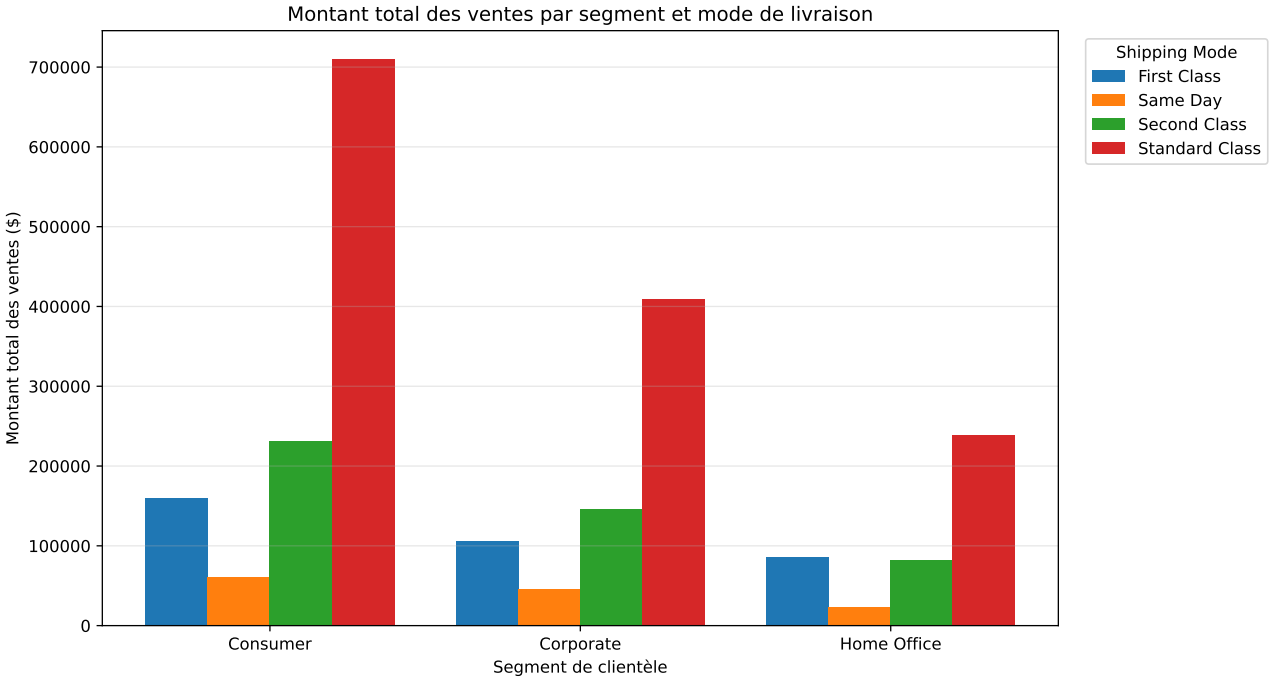


FIGURE 20 – Montant total des ventes par segment, ventilé par mode de livraison

On observe que les commandes du segment Consumer utilisant Standard Class contribuent le plus au chiffre d'affaires total. La même tendance est observée pour les segments Corporate et Home Office. Les montant des ventes associées au mode Same Day restent faibles dans tous les segments.

Recommandation :

- Continuer à développer le mode Standard Class, principal contributeur au chiffre d'affaires.

V.3.6 Distribution du profit total par segment, ventilé par mode de livraison

Le graphique suivant répond à la question : comment le profit total se répartit-il selon le segment de clientèle ventilé par mode de livraison ?

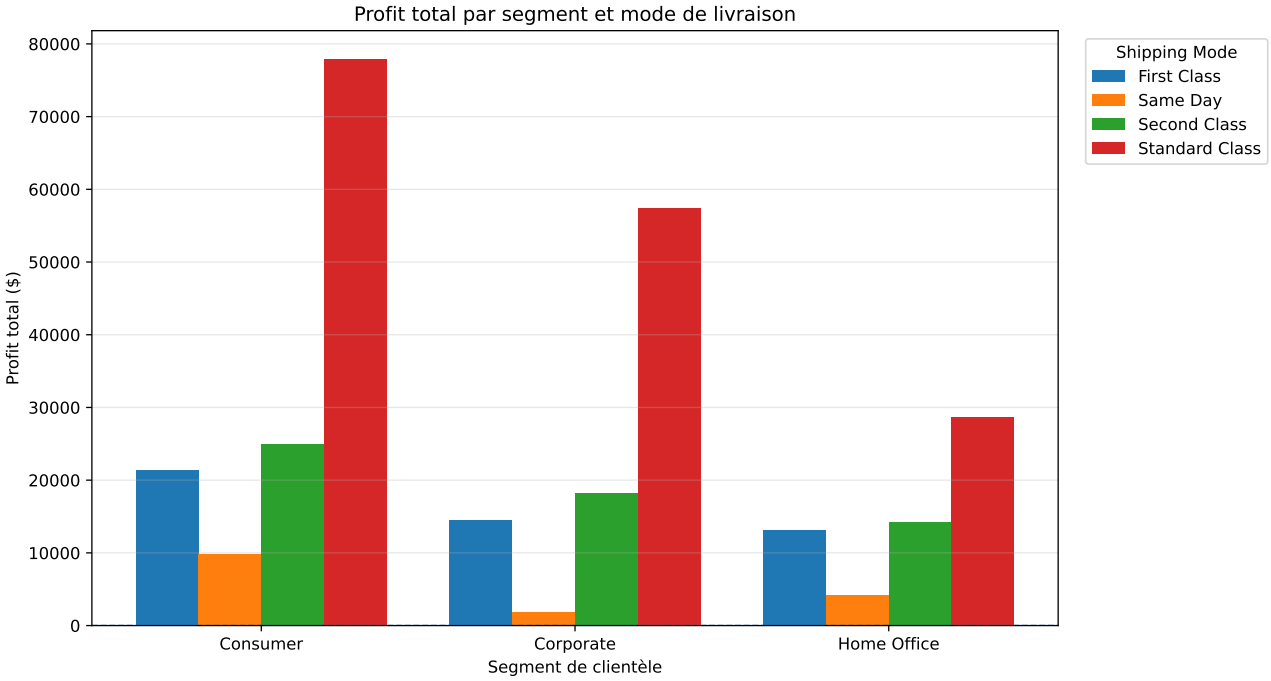


FIGURE 21 – Profit total par segment, ventilé par mode de livraison

On observe que les commandes du segment Consumer utilisant Standard Class contribuent le plus au profit total. Cette tendance est également observée pour les segments Corporate et Home Office. Le mode Same Day contribue faiblement au profit, quel que soit le segment.

Recommandations :

- Continuer à optimiser le mode Standard Class, qui représente la principale contribution au profit.
- Analyser les coûts associés au mode Same Day afin de vérifier si ce service est suffisamment rentable.
- Étudier les préférences de chaque segment pour proposer des offres de livraison plus adaptées et améliorer leur contribution au profit.

Bilan de fin de sous-section :

Les analyses réalisées selon les segments de clientèle montrent que le segment Consumer constitue le principal contributeur à l'activité commerciale de l'enseigne.
Par ailleurs, quel que soit le segment de clientèle, le mode de livraison Standard Class est le plus utilisé et contribue également le plus au chiffre d'affaires ainsi qu'au profit total.
À l'inverse, le mode Same Day reste marginal dans l'ensemble des segments. Ces résultats indiquent que l'activité commerciale de l'enseigne repose principalement sur les clients Consumer utilisant le mode de livraison Standard Class.
L'enseigne pourrait donc poursuivre l'optimisation de ce mode de livraison tout en mettant en place des stratégies commerciales ciblées afin de développer la contribution des segments Corporate et Home Office et d'encourager une utilisation plus importante des autres modes de livraison lorsque cela est pertinent.

Les analyses précédentes ont permis d'identifier les principaux segments de clientèle qui contribuent le plus à l'activité commerciale. Les analyses suivantes s'intéresseront plus

finement aux catégories de produits, aux régions géographiques et aux niveaux de réduction afin d'identifier d'autres facteurs influençant les ventes et le profit.

V.4 Visualisations des données par Catégories de produits

V.4.1 Répartition des commandes clients par catégories de produits

Le garphique suivant répond à la question : Quelle est la répartition des commandes entre les différents catégories de produits ?

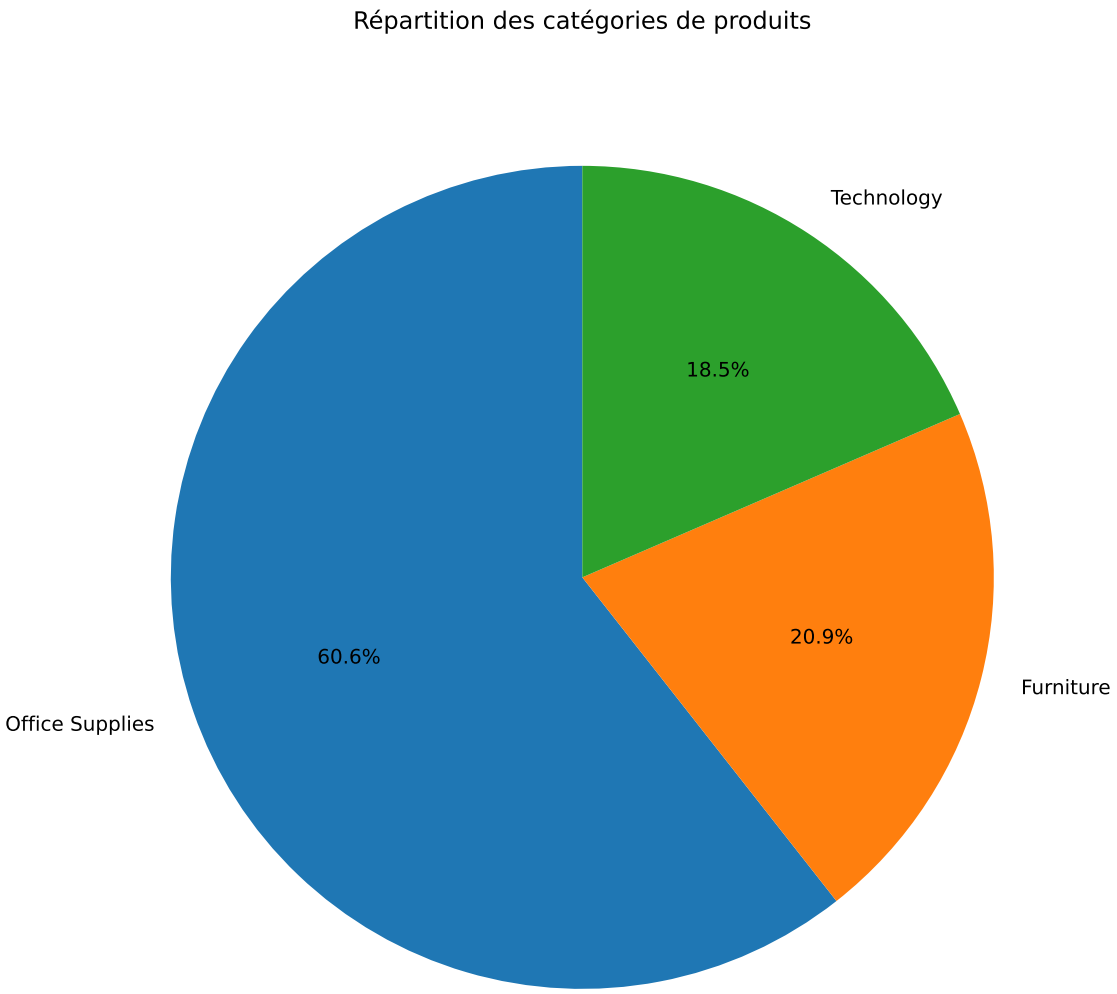


FIGURE 22 – Répartition des commandes clients par catégories de produits

La catégorie qui est de loin la plus représentée dans les commandes des clients est la catégorie Office Supplies (60, 6%) suivit de Furniture (20, 9%) et de Technology (18, 5%) qui elles sont nettement moins représentées dans les commandes des clients. Les ventes sont donc principalement concentrées sur les fournitures de bureau (Office Supplies).

Recommandations :

L'enseigne pourrait :

- Maintenir une bonne disponibilité des produits Office Supplies en adaptant les niveaux de stock à la forte demande de cette catégorie.
- Mettre en place des actions commerciales visant à accroître les ventes des catégories Furniture et Technology.

V.4.2 Distribution du montant total des ventes par catégorie de produits

Le graphique suivant répond à la question : comment est répartie le montant total des ventes par catégorie de produits ?

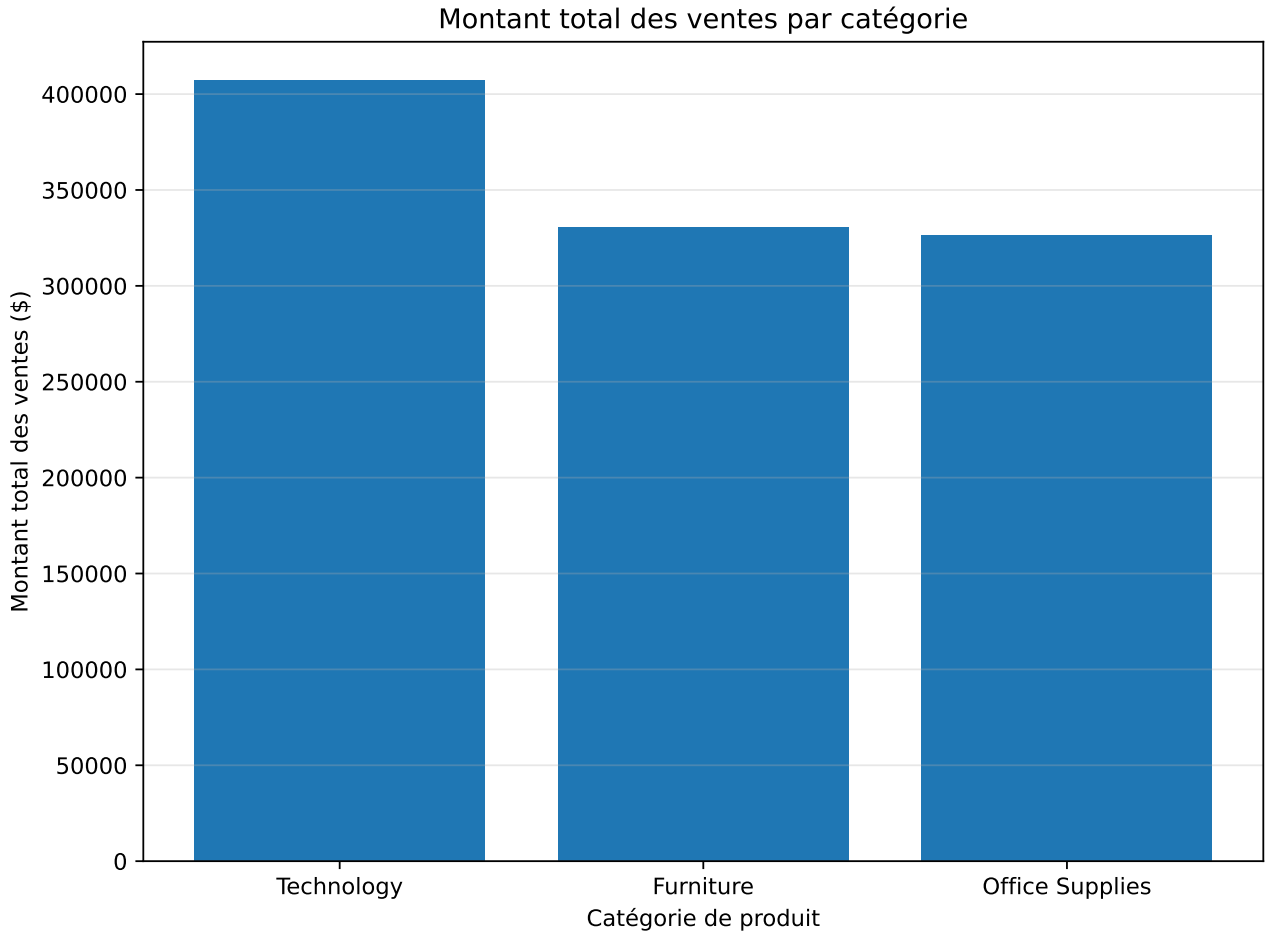


FIGURE 23 – Montant total des ventes par catégorie de produits

La catégorie de produit contribuant le plus au chiffre d'affaire n'est pas celle la plus représentée dans les commandes des clients. Mais plutôt celle la moins représentée. Il s'agit de la catégorie Technology. Furniture occupe la deuxième place. Office Supplies bien que très fortement représentées dans les commandes des clients, contribue la moins des trois au chiffre d'affaire.
Cela suggère très certainement que les produits de la catégorie Technology ont en moyenne un prix plus élevé que ceux de la catégorie Office Supplies.

Recommandation :

L'enseigne pourrait :

- Continuer à promouvoir les produits technologiques qui représentent une source importante de chiffre d'affaires.

V.4.3 Distribution du profit total par catégorie de produits

Le graphique suivant répond à la question : dans quelles mesures chaque catégorie de produits contribue t'elle au profit total de l'enseigne ?

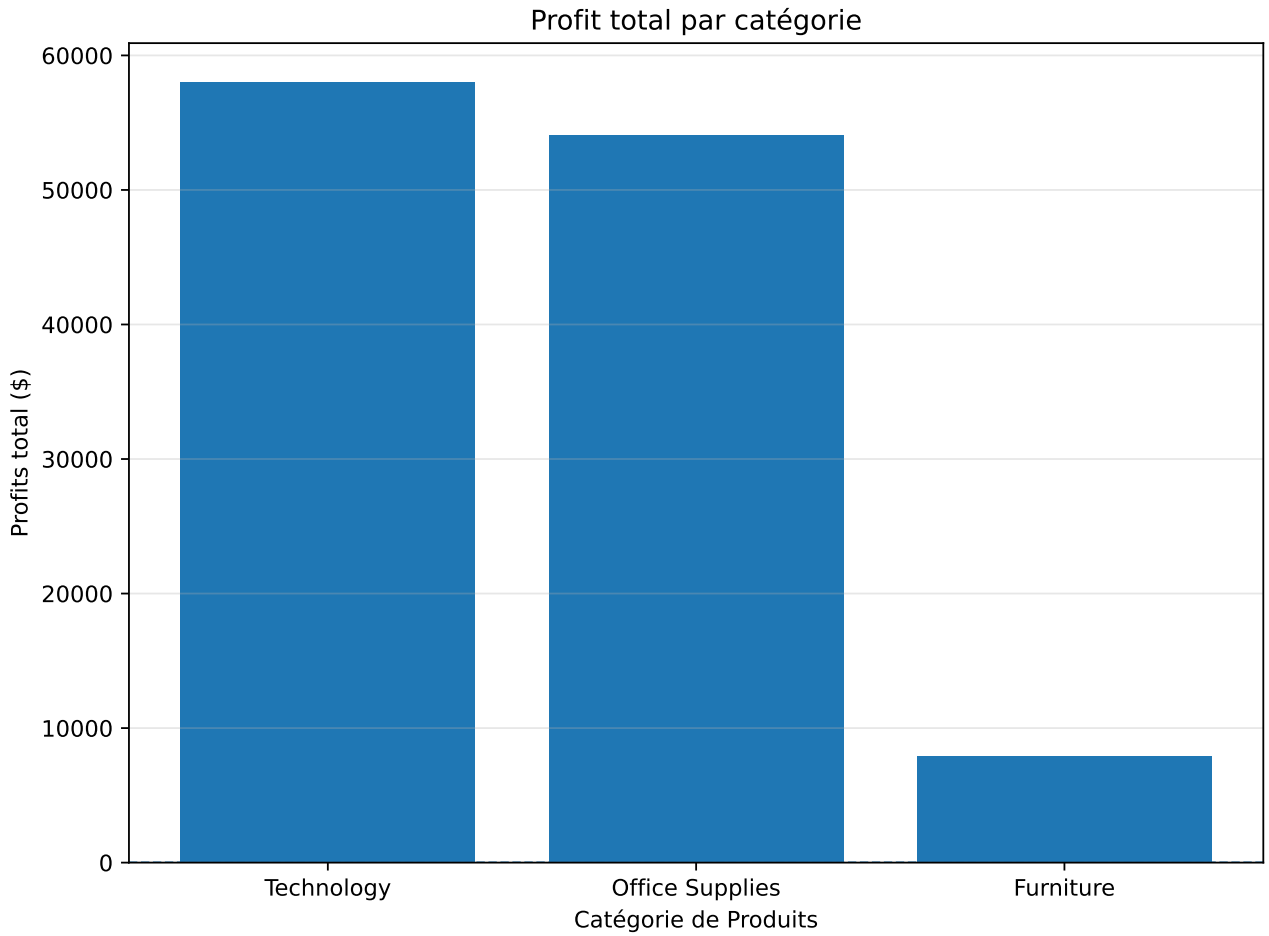


FIGURE 24 – Profit total par catégorie de produits

La catégorie de produits qui contribue le plus au profit total est encore celle qui est la moins commandée par les clients, c'est à dire la catégorie Technology ; suivit de celle la plus commandée par les clients, c'est à dire la catégorie Office Supplies. La catégorie Furniture qui est la deuxième la plus commandée par les clients, contribue très faiblement au profit total par rapport aux deux autres catégories, et cela malgré un chiffre d'affaire relativement élevé.
Ce qui veut dire que la catégorie Furniture possède une marge bénéficiaire plus faible que les autres catégories.

Recommandations :

L'enseigne pourrait :

- Identifier les causes de la faible contribution au profit des produits de la catégorie Furniture
- Revoir la politique tarifaire, le coût d'approvisionnement ou les remises accordées sur cette catégorie.
- Renforcer les investissements commerciaux sur la catégorie Technology qui combine un chiffre d'affaire élevé et un profit important

Bilan de fin de sous-section :

L'analyse des catégories de produits met en évidence des comportements différents selon l'indicateur examiné. La catégories Office Supplies représentent la majorité des commandes mais ne contribue pas le plus au profit total, tandis que la catégorie Technology représente la minorité des commandes mais contribue le plus au chiffre d'affaires et au profit total. À l'inverse, la catégorie Furniture possède un chiffre d'affaires relativement élevé mais a une contribution limitée au profit, ce qui suggère une marge bénéficiaire plus faible. L'enseigne peu donc continuer à renforcer et promouvoir les investissements commerciaux sur la catégorie Technology tout en mettant en place des actions commerciales visant à accroître les ventes et le profit des deux autres catégories, en particulier celui de la catégorie Furniture.

V.5 Visualisations des données par sous-catégories de produits

V.5.1 Distribution des commandes par sous-catégories de produits

Le graphique suivant répond à la question : comment les commandes sont-elles distribuées par sous-catégories de produits ?

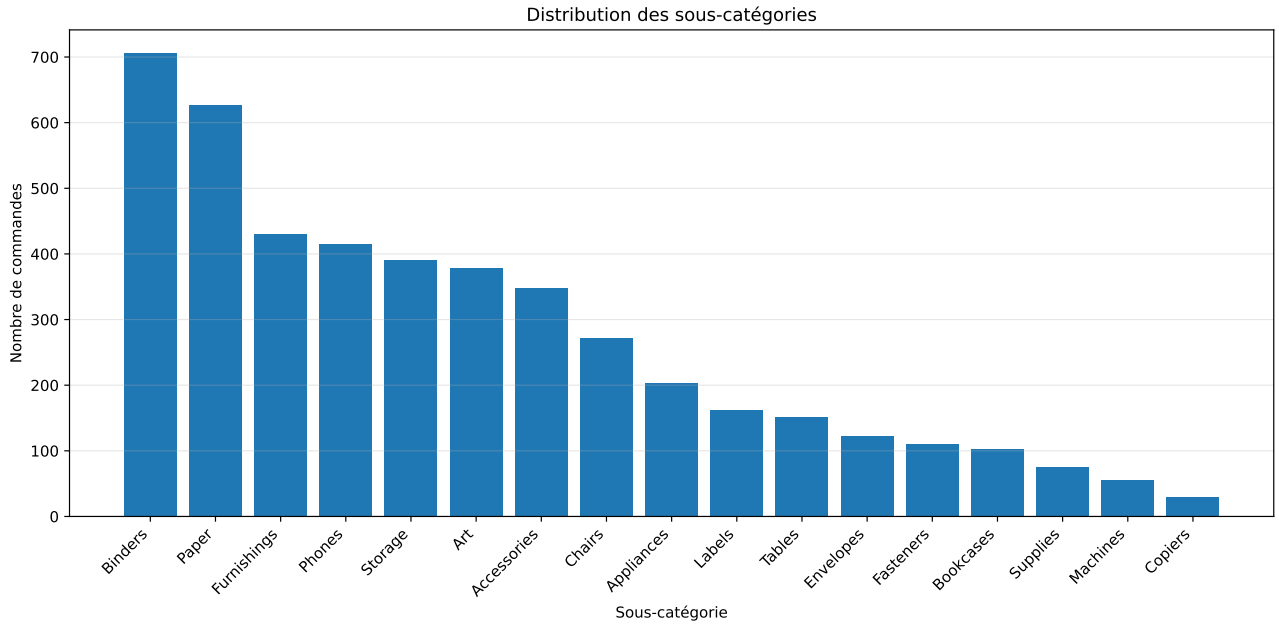


FIGURE 25 – Distribution des commandes par sous-catégories de produits

On peut voir que Blinders est la sous-catégorie la plus commandée suivie de Paper. Les sous-catégories Machines et Copiers sont les moins commandées. La fréquence des commandes varie assez fortement d'une sous-catégories à l'autre.

Recommandations :

L'enseigne pourrait :

- Maintenir un niveau de stock élevé pour les sous-catégories les plus demandées.
- Étudier les raisons de la faible demande des sous-catégories les moins commandées (prix, besoin limité, concurrence, visibilité, etc)
- Adapter les stratégies marketing selon la popularité de chaque sous-catégorie

V.5.2 Distribution du profit total par sous-catégories de produits

Le graphique suivant répond à la question : dans quelles mesures chaque sous-catégories contribue t'elle au profit total ?

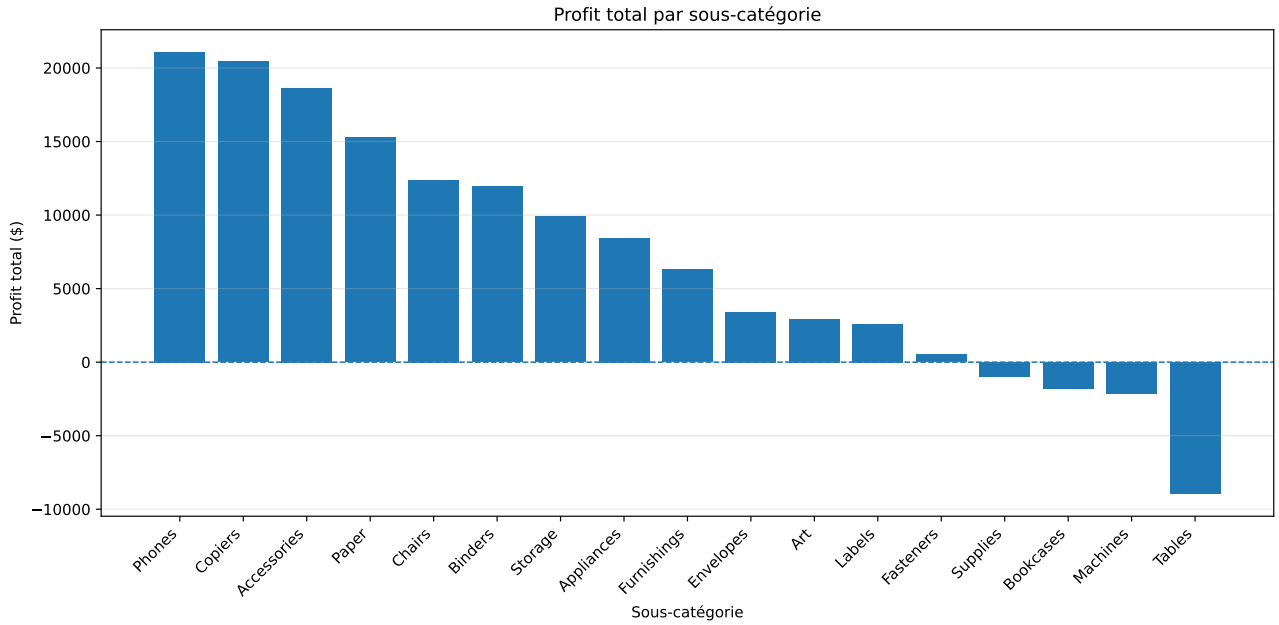


FIGURE 26 – Profit total par sous-catégories de produits

Copiers qui est la sous-catégorie la moins commandée de toutes par les clients, est celle qui contribue le plus au profit total, suivie de Phones et Accessoires. Certaines sous-catégories présentent un profit très faible. Tables, Bookcases et Supplies affichent une contribution négative au profit, ce qui signifie qu'elles génèrent des pertes.

Recommandations :

L'enseigne pourrait :

- Renforcer la mise en avant des sous-catégories les plus profitables (Copiers, Phones, Accessories).
- Réaliser une analyse détaillée des sous-catégories déficitaires pour identifier les causes des pertes (coût d'achat élevé, remises importantes, faible marge, coût logistique, etc).
- Réviser la politique tarifaire ou les promotions appliquées aux produits déficitaires.

V.5.3 Distribution du montant total des ventes par sous-catégories de produits

Le graphique suivant répond à la question : dans quelles mesures chaque sous-catégories contribue t-elle au chiffre d'affaires ?

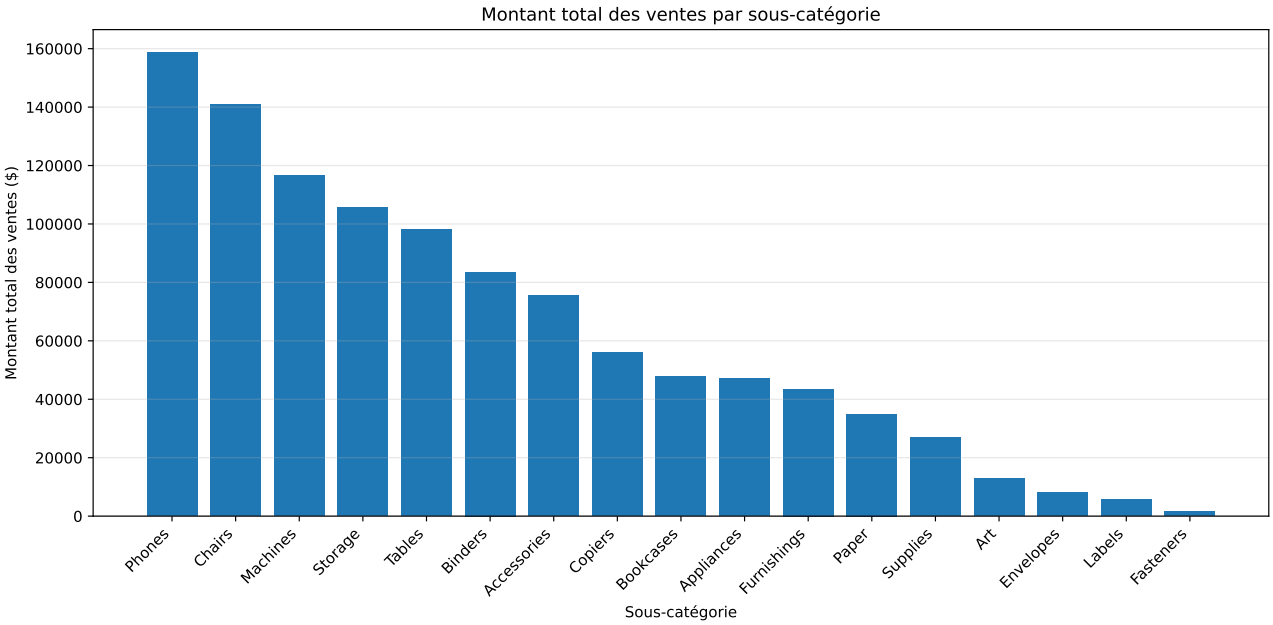


FIGURE 27 – Montant total des ventes par sous-catégories de produits

Phones et Chairs contribuent le plus au chiffre d'affaires. Storage, Tables et Blinders figurent également parmi les sous-catégories possédant un chriffre d'affaires important. A l'inverse Fasteners, Labels et Envelopes contribuent très peu au chiffre d'affaires.
On peut aussi remarquer que Tables qui possède un chiffre d'affaires relativement élevé apparaît déficitaire d'après le graphique précédent sur le profit total.

Recommandations :

L'enseigne pourrait :

- Continuer à promouvoir les sous-catégories qui combinent un chiffre d'affaires élevé et une bonne contribution au profit, comme Phones.
- Analyser les sous-catégories générant un chiffre d'affaires élevé mais une faible rentabilité (notamment Tables) afin d'améliorer leurs marges.
- Adapter les niveaux de stock en fonction de la contribution réelle de chaque sous-catégorie aux ventes et au profit.

Bilan de la sous-section :

L'analyse par sous-catégorie met en évidence des différences importantes entre le volume des commandes, le chiffre d'affaires et la rentabilité. Certaines sous-catégories, comme Binders, sont très fréquemment commandées sans être les plus rentables. À l'inverse, Copiers contribue fortement au profit malgré un nombre de commandes très faible, ce qui indique une marge élevée.
Enfin, des sous-catégories comme Tables génèrent un chiffre d'affaires important tout en affichant une contribution négative au profit, soulignant la nécessité de distinguer

performance commerciale et rentabilité.
Les sous-catégories les plus profitables comme Copiers, Phones ou encore Accessories devraient ainsi être mise en avant, tandis que des sous-catégories déficitaires comme Tables par exemple méritent une analyse approfondie afin d'identifier les causes possibles des pertes.

V.6 Visualisations des données par Région

V.6.1 Distribution des commandes par Région

Le graphique suivant répond à la question : comment les commandes sont-elles réparties entre les différentes régions ?

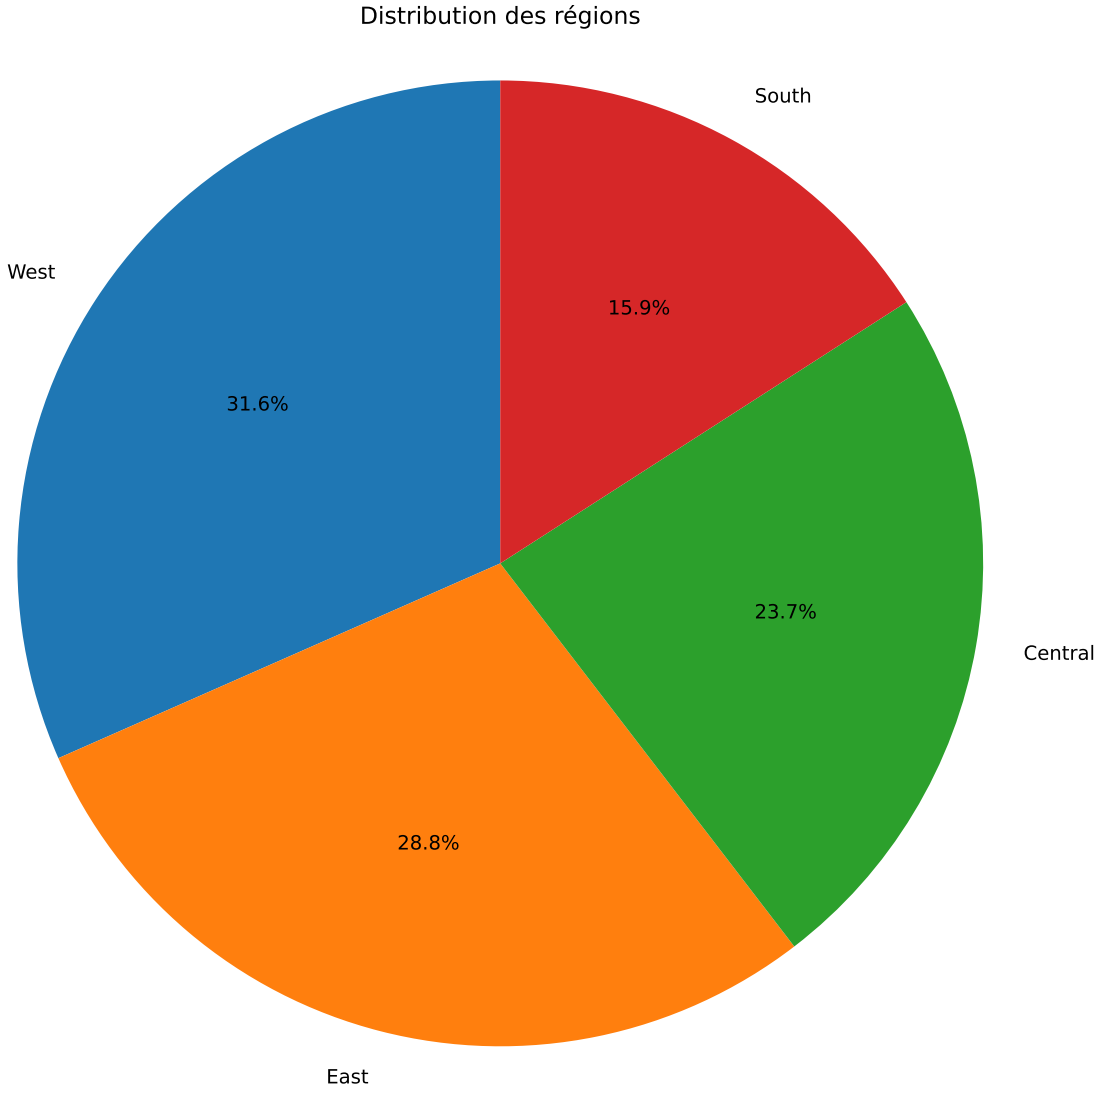


FIGURE 28 – Répartition des commandes par région

On peut voir que West (Ouest) représente la plus grande part des commandes (31, 6%) suivie de près par la région East (Est) (28, 8%). Ensuite vient la région Central (centre) (23, 7%). La région South (Sud) enregistre la plus faible part des commandes (15, 9%). Les

commandes sont réparties de manière relativement équilibrées même si West et East sont légèrement dominantes.

Recommandations :

L'enseigne pourrait :

- Maintenir des capacité logistiques importantes dans les régions West et East afin de répondre à la forte demande.
- Étudier les raisons de la faible activité dans la région South (potentiel commercial, concurrence, stratégie marketing, etc)

V.6.2 Distribution du profit total par Région

Le graphique suivant répond à la question : quelle est la contribution de chaque région au profit total ?

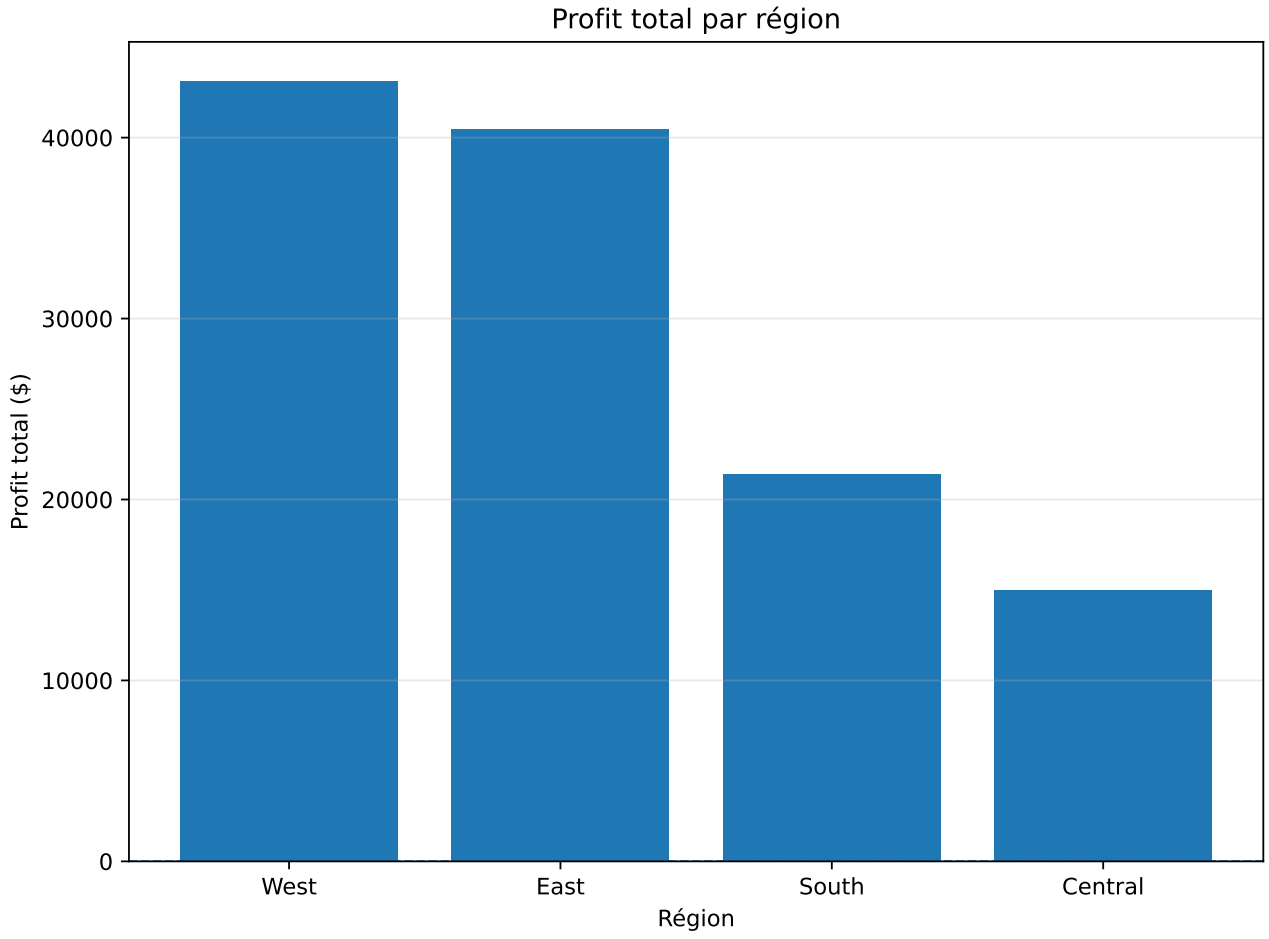


FIGURE 29 – Profit total par région

On peut voir que la région Ouest qui enregistre le plus de commandes contribue également le plus fortement au profit total. La région Est arrive en deuxième position avec un profit également élevé. Les régions Sud et Centre contribuent beaucoup moins au profit total. Et malgré un nombre total de commandes supérieur à celui de Sud, la région centre contribue légèrement moins au profit que Sud.

Recommandations :

L'enseigne pourrait :

- Analyser l'activité commerciale des régions Centre et Sud pour identifier les causes de leur faible contribution au profit.
- Adapter les politiques tarifaires, les remises ou les coûts logistiques dans les régions les moins rentables
- Consolider les performances commerciales dans les régions Ouest et Est.

V.6.3 Distribution du montant total des ventes par Région

Le graphique suivant répond à la question : quelle est la contribution de chaque région au chiffre d'affaires ?

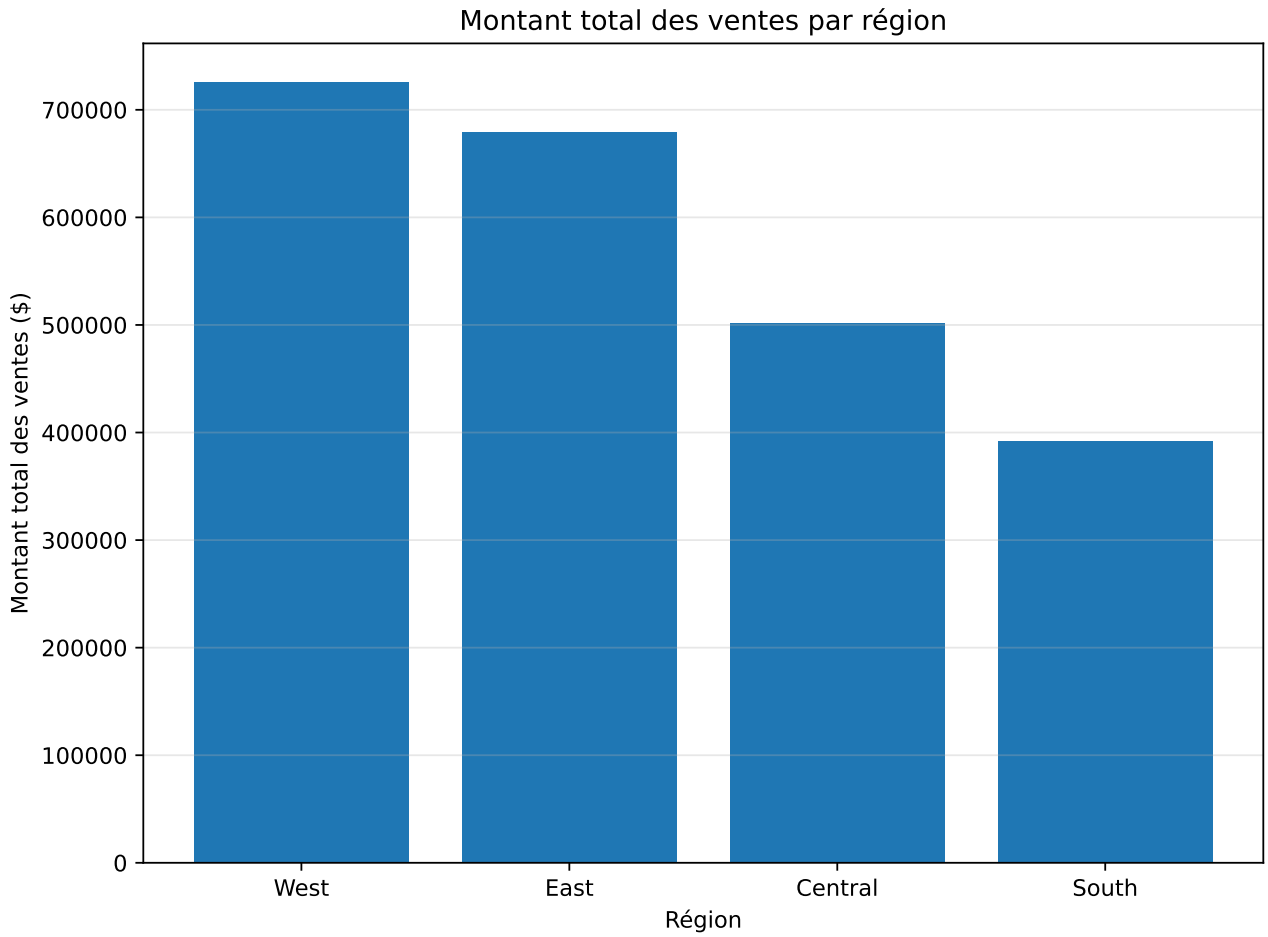


FIGURE 30 – Montant total des ventes par région

Les régions West et East qui possèdent le plus grand nombre de commandes et qui contribuent également le plus au profit total, sont celles qui contribuent aussi le plus au chiffre d'affaires, suivie de Central puis de South. L'ordre observé est totalement cohérent avec celui du nombre de commandes et presque cohérent (à une inversion de position) avec celui du profit total. Ce qui suggère que globalement, les régions qui réalise le plus de ventes sont également celles qui contribuent le plus au profit.

Recommandations :

L'enseigne pourrait :

- Continuer à développer les activité commerciales dans les régions West et East afin de préserver leur contribution au chiffre d'affaires.
- Identifier les opportunités de croissance dans les régions Central et South (nouveaux clients, campagnes marketing, etc)
- Comparer les performances régionales afin d'identifier les bonnes pratiques des régions les plus performantes et les appliquer aux régions moins performantes lorsque c'est possible.

Bilan de fin de sous-section :

L'analyse régionale met en évidence des différences de performance entre les quatre régions. Les régions West et East constituent les principaux moteurs du chiffre d'affaires et du profit total, tandis que South présente les performances les plus faibles sauf pour le profit total. La région Central occupe une position intermédiaire mais semble légèrement moins rentable que son volume de commandes pourrait le laisser penser. Ces résultats permettent d'orienter les décisions stratégiques commerciales et d'optimisation de la rentabilité notamment en continuant à développer les activité commerciales dans les régions West et East afin de préserver leur contribution au chiffre d'affaires et au profit total mais également à identifier les les bonnes dans ces régions qui performent bien et les appliquer aux régions moins performantes lorsque c'est possible.

Dans la suite, nous ne ferons à chaque fois qu'un bilan de fin de sous-section.

V.7 Visualisations des Tops 25 par État

V.7.1 Top 25 du nombre de commandes par État

Le graphique suivant montre le classement des 25 premiers États comptabilisant le plus grands nombre de commandes.

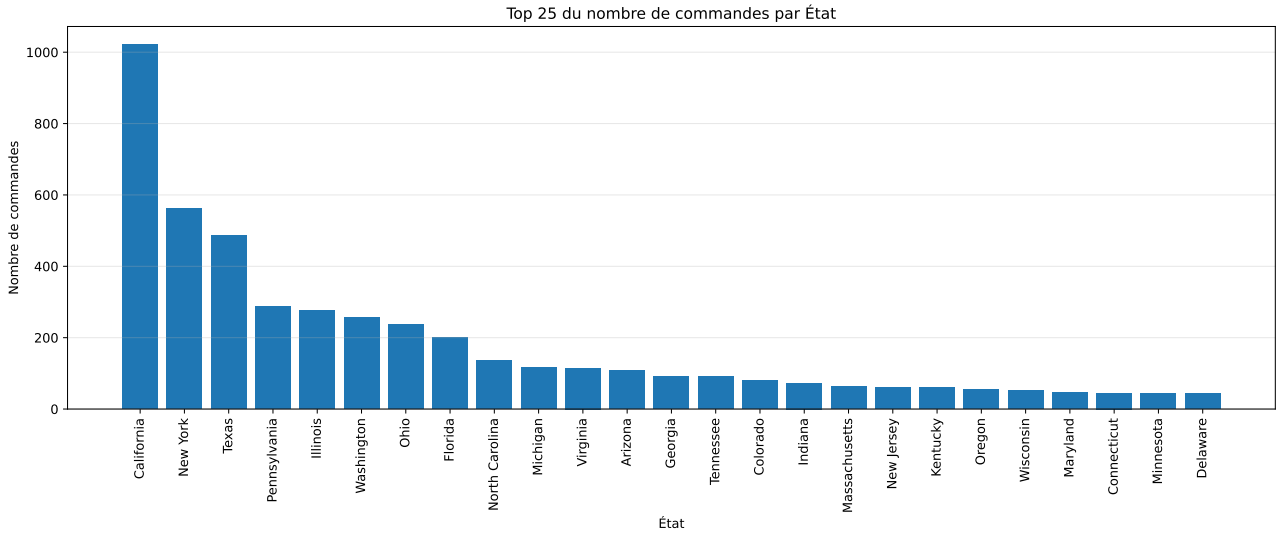


FIGURE 31 – Top 25 des nombres de commandes par État

V.7.2 Top 25 des commandes ayant bénéficié d'une remise par État

Le graphique suivant montre le classement des 25 premiers États comptabilisant le plus grands nombre de commandes ayant bénéficié d'une remise.

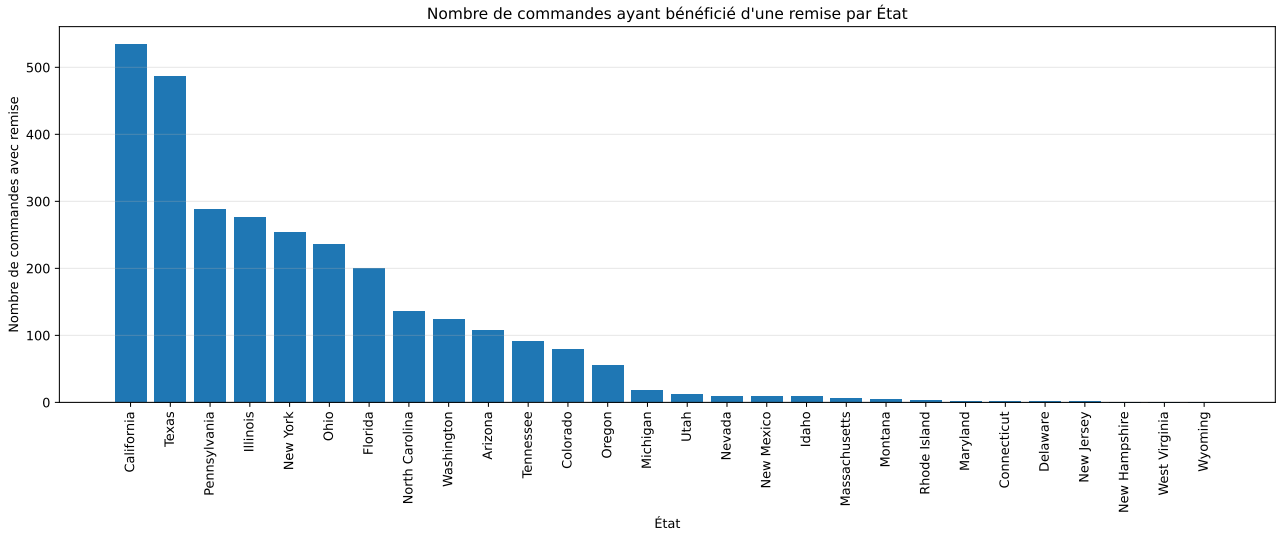


FIGURE 32 – Top 25 du nombre de commandes ayant bénéficié d'une remise par État

V.7.3 Top 25 du montant total des ventes par État

Le graphique suivant montre le classement des 25 premiers États comptabilisant le plus grands chiffre d'affaires.

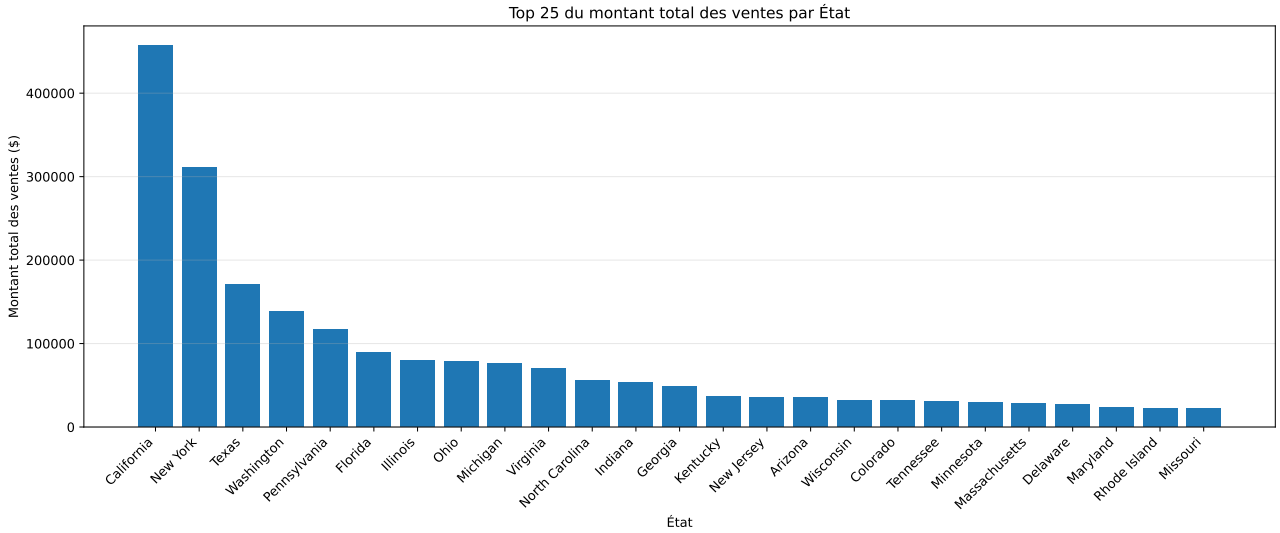


FIGURE 33 – Top 25 du montant total des ventes par État

V.7.4 Top 25 du profit total par État

Le graphique suivant montre le classement des 25 premiers États contribuant le plus au profit total.

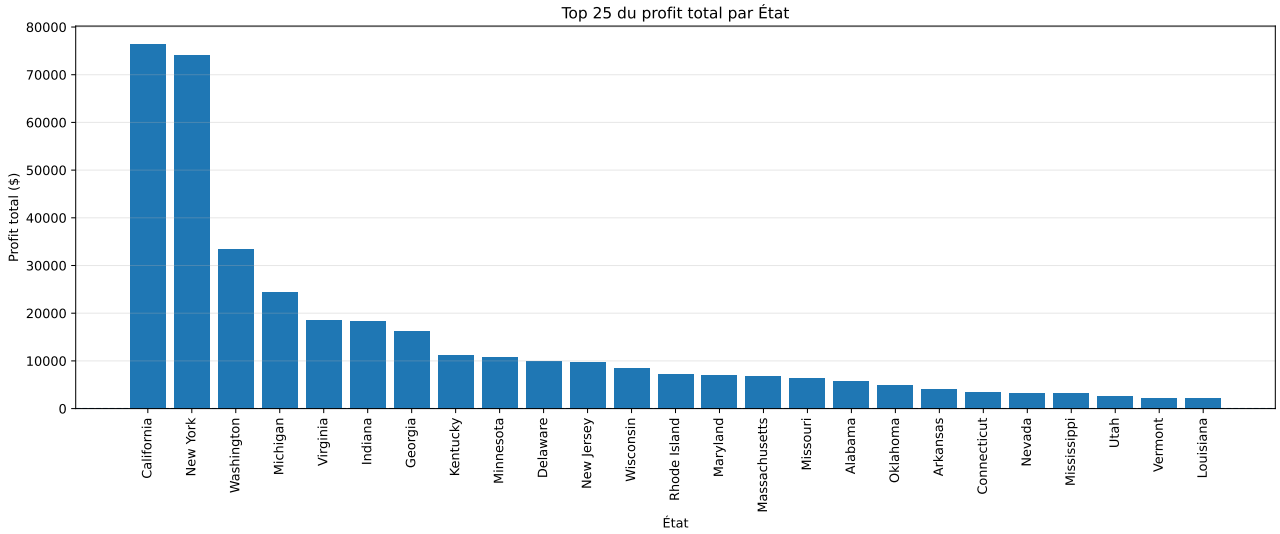


FIGURE 34 – Top 25 du profit total par État

La Californie domine très clairement les quatre classements. Elle est l'État qui enregistre le plus grand nombre de commandes, le plus grand nombre de commandes bénéficiant d'une remise, le montant total des ventes le plus élevé et le profit total le plus important. Elle constitue donc le principal marché de l'enseigne.

New York occupe également une position stratégique. Il figure parmi les tout premiers États en nombre de commandes, en chiffre d'affaires et en profit, mais le recours aux remises y est moins marqué qu'en Californie, ce qui laisse penser que de bonnes performances commerciales peuvent être obtenues sans dépendre autant des promotions.

Le Texas, bien qu'il fasse partie des États ayant le plus grand nombre de commandes et un chiffre d'affaires élevé, n'apparaît pas parmi les tout premiers en matière de profit. Cette situation suggère que sa rentabilité est plus faible, peut etre en raison d'un recours plus fréquent aux remises.

Des États comme **Washington**, **Michigan** ou **Virginie** affichent un profit relativement élevé alors qu'ils enregistrent un volume de commandes inférieur à celui de certains États mieux classés. Ces État semblent donc générer une meilleure rentabilité par commande.

Les commandes bénéficiant d'une remise sont fortement concentrées dans quelques États, principalement la **Californie**, le **Texas** et la **Pennsylvanie**. Cette concentration invite à évaluer si les politiques promotionnelles mises en place dans ces États améliorent réellement la rentabilité ou réduisent inutilement les marges.

Recommandations :

L'enseigne pourrait :

- Consolider les investissements dans les États les plus performants, notamment la **Californie** et New York, en renforçant les actions commerciales, les stocks et la qualité du service afin de préserver leur rôle de moteurs en terme de chiffre d'affaires et de profit.
- Réévaluer la politique de remises dans les États où elle est très utilisée, en particulier en **Californie**, au **Texas** et en **Pennsylvanie**, afin de vérifier que les promotions

génèrent un gain réel de rentabilité et ne dégradent pas excessivement les marges.
- S'inspirer des États avec une forte rentabilité, comme **Washington** ou le **Michigan**, pour identifier les facteurs expliquant leurs bonnes performances (niveau de remises, stratégie commerciale, profil des clients, etc) et les reproduire dans les États où le volume de ventes est important mais la rentabilité reste plus faible.

V.8 Visualisations des Tops 25 par ville

V.8.1 Top 25 du nombre de commandes par ville

Le graphique suivant montre le classement des 25 premiers villes comptabilisant le plus grands nombre de commandes.

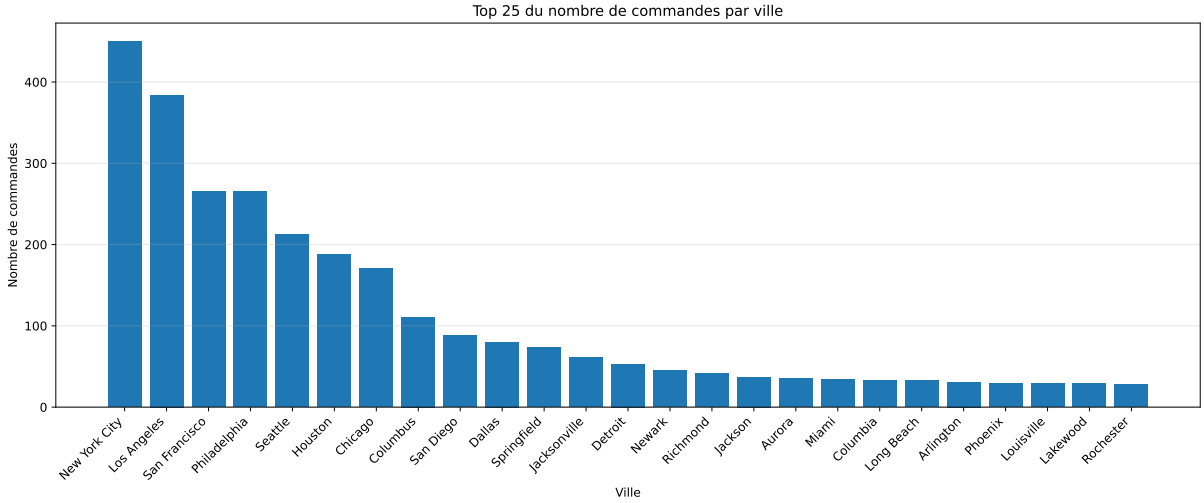


FIGURE 35 – Top 25 du nombre de commandes par ville

V.8.2 Top 25 du profit total par ville

Le graphique suivant montre le classement des 25 premiers villes contribuant le plus au profit total.

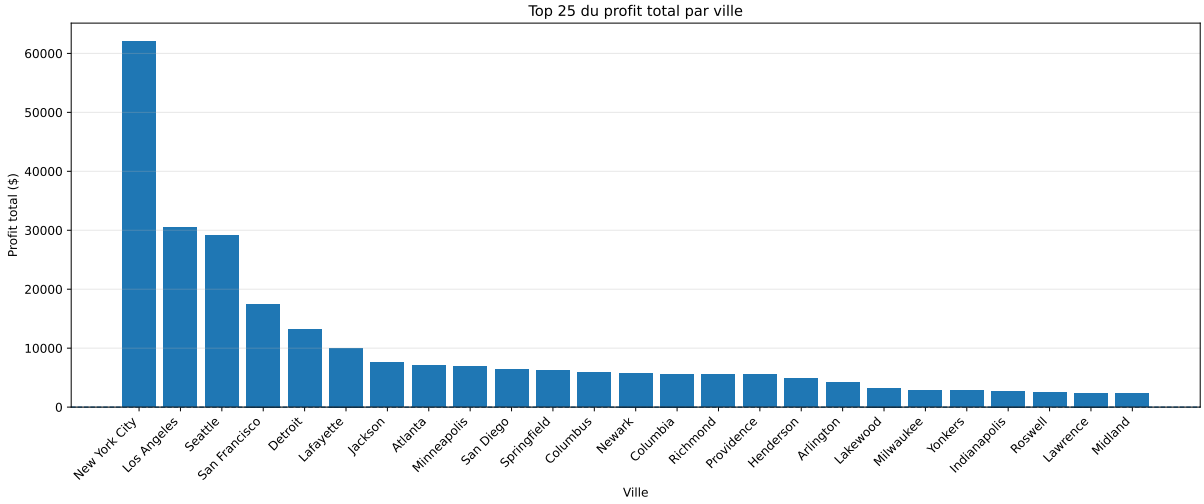


FIGURE 36 – Top 25 du profit total par ville

V.8.3 Top 25 du montant total des ventes par ville

Le graphique suivant montre le classement des 25 premiers villes contribuant le plus au montant total des ventes par ville.

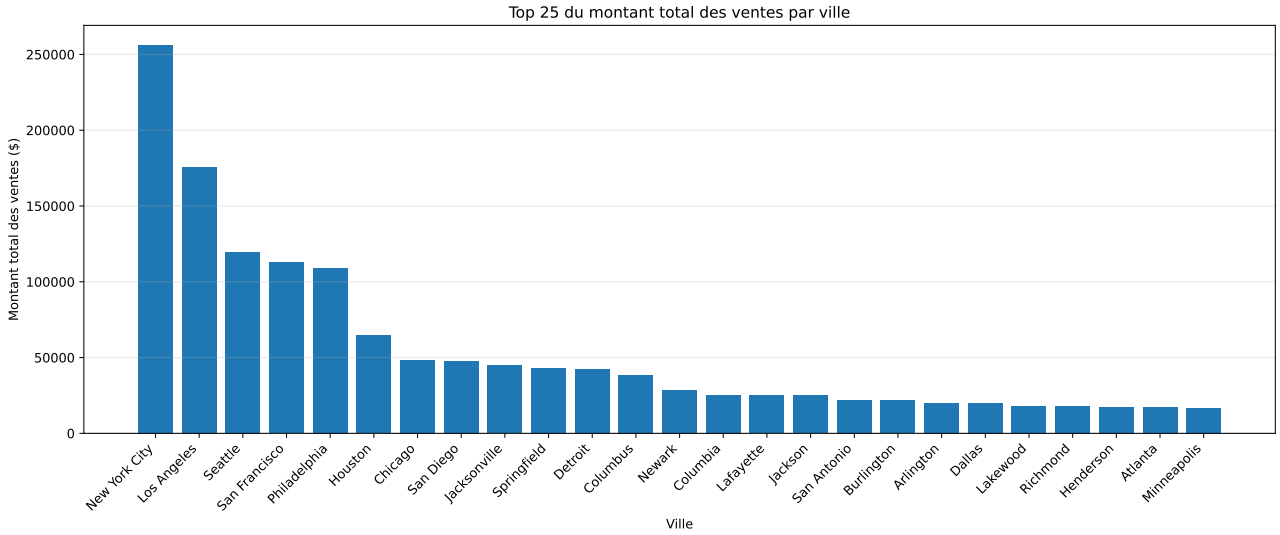


FIGURE 37 – Top 25 du montant total des ventes par ville

V.8.4 Top 25 du nombre de commandes ayant bénéficié d'une remise par ville

Le graphique suivant montre le classement des 25 premiers villes comptabilisant le plus grands nombre de commandes ayant bénéficié d'une remise.

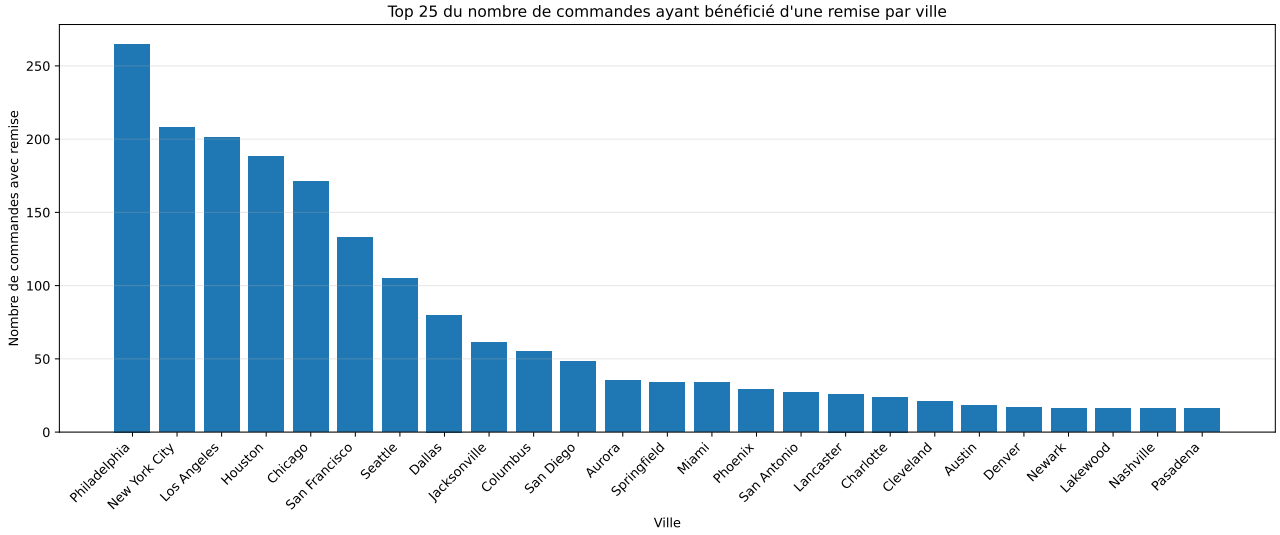


FIGURE 38 – Top 25 du nombre de commandes ayant bénéficié d'une remise par ville

New York City se distingue très clairement comme la ville la plus stratégique. Elle occupe la première place en nombre de commandes, en montant total des ventes et en profit total, ce qui montre qu'elle constitue le principal moteur de performance commerciale de l'enseigne.

Los Angeles et **Seattle** figurent également parmi les villes les plus performantes. Elles combinent un volume élevé de commandes, un chiffre d'affaires important et une forte rentabilité, confirmant leur rôle majeur dans les résultats de l'enseigne.

Philadelphie présente un cas particulier. Elle apparaît parmi les villes ayant le plus de commandes et de ventes, mais elle est également la ville comptant le plus grand nombre de commandes ayant bénéficié d'une remise. Cela suggère que ses bonnes performances commerciales reposent en partie sur une politique promotionnelle plus intensive.

Certaines villes, comme **Detroit**, **Lafayette** ou **Jackson**, figurent parmi les meilleures en termes de profit sans apparaître parmi les premières en nombre de commandes ou en chiffre d'affaires. Elles semblent donc générer une rentabilité élevée par commande.

Recommandations :

L'enseigne pourrait :

- Renforcer les investissements commerciaux dans les villes les plus performantes, en particulier **New York City**, **Los Angeles** et **Seattle**, afin de consolider leur contribution au chiffre d'affaires et au profit (gestion des stocks, fidélisation des clients, amélioration de la disponibilité des produits).
- Réexaminer la politique de remises dans les villes où elle est la plus importante, notamment **Philadelphie**, **Houston** et **Chicago**, afin de vérifier que les promotions augmentent réellement la rentabilité et ne réduisent pas excessivement les marges.
- Analyser les facteurs de succès des villes très rentables, comme **Detroit** ou **Lafayette**, afin d'identifier les bonnes pratiques (politique tarifaire, stratégie commerciale ou comportement des clients) pouvant être reproduites dans d'autres villes à fort potentiel mais moins rentables.

V.9 Visualisations des Tops 10 par produit

V.9.1 Top 10 du profit total par produit

Le graphique suivant montre le classement des 10 premiers produits contribuant le plus au profit total.

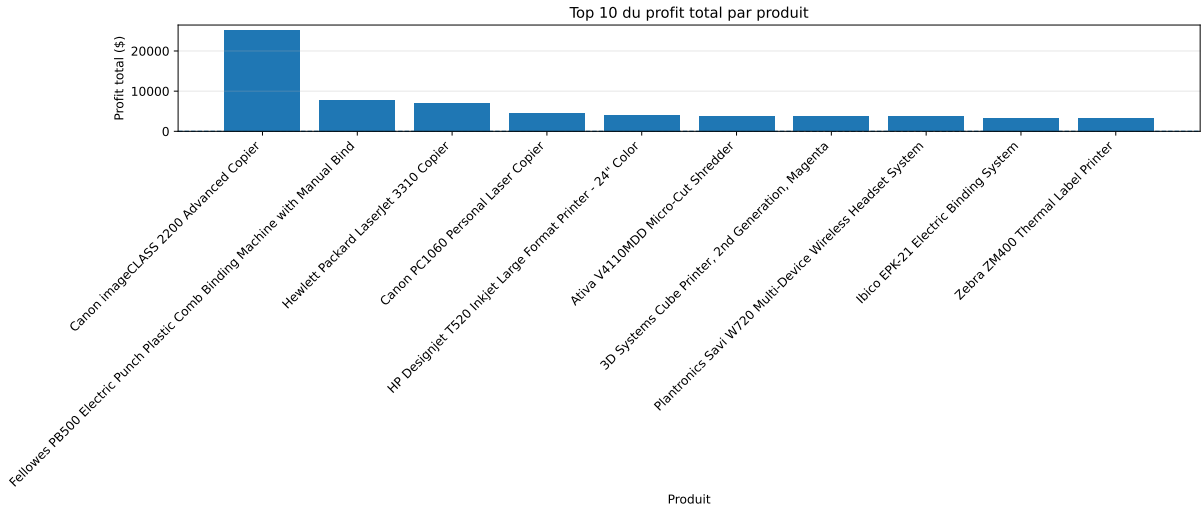


FIGURE 39 – Top 10 du profit total par produit

V.9.2 Top 10 du montant total des ventes par produit

Le graphique suivant montre le classement des 10 premiers produits contribuant le plus au chiffre d'affaires.

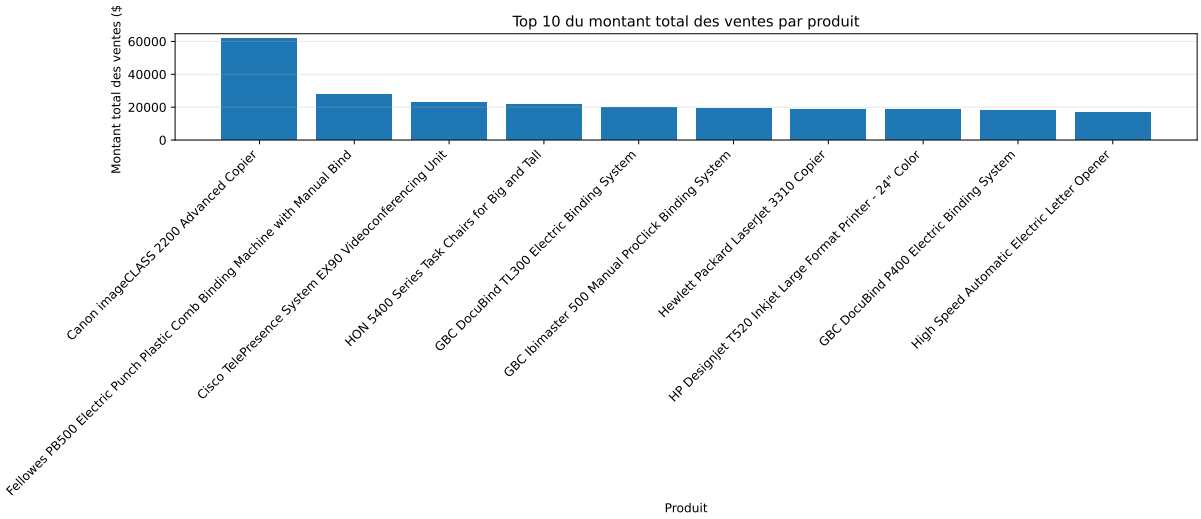


FIGURE 40 – Top 10 du montant total des ventes par produit

V.9.3 Top 10 du nombre total de commandes par produit

Le graphique suivant montre le classement des 10 premiers produits comptabilisant le plus grands nombre de commandes.

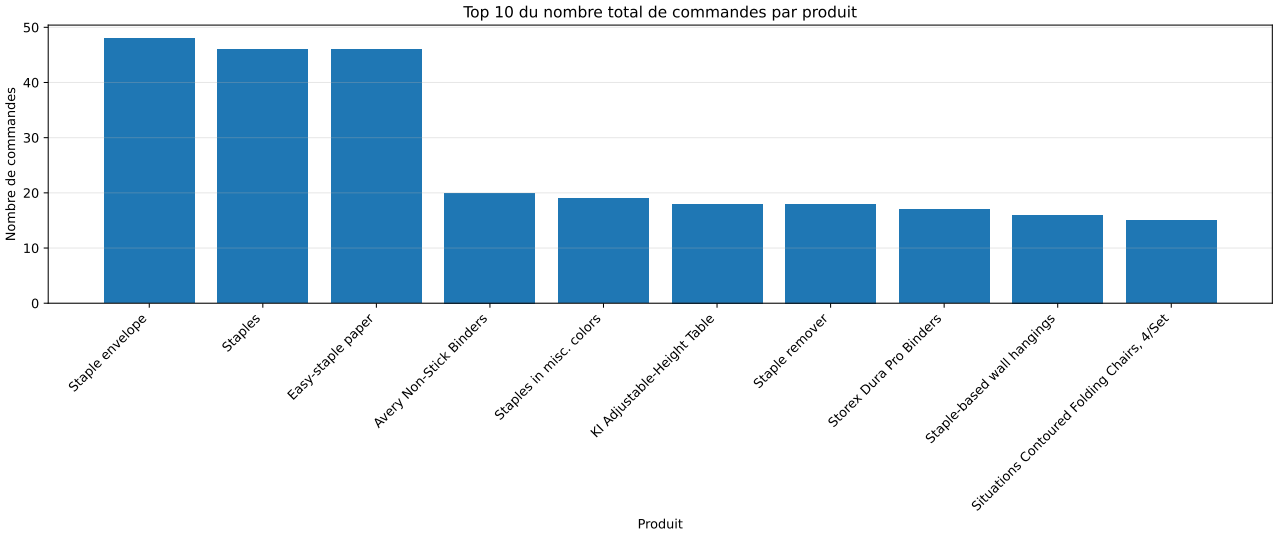


FIGURE 41 – Top 10 du nombre total de commandes par produit

Le **Canon imageCLASS 2200 Advanced Copier** domine très largement les deux premiers classements. Il est à la fois le produit générant le chiffre d'affaires le plus élevé et le profit total le plus important, ce qui en fait le produit le plus stratégique du catalogue.

Plusieurs produits apparaissent simultanément parmi les meilleurs en chiffre d'affaires et en profit, notamment le **Fellowes PB500 Electric Punch Plastic Comb Binding Machine**,

le **Hewlett Packard LaserJet 3310 Copier** ou encore le **HP DesignJet T520**. Cela montre qu'ils sont non seulement vendus à un prix élevé, mais qu'ils dégagent également des marges importantes.

À l'inverse, les produits les plus fréquemment commandés (**Staple envelope**, **Staples**, **Easy-staple paper**, etc.) sont principalement des fournitures de bureau à faible valeur unitaire. Ils figurent parmi les meilleures ventes en volume, mais n'apparaissent pas parmi les produits générant le plus de chiffre d'affaires ni de profit.

Les produits les plus rentables sont majoritairement des équipements technologiques (copieurs, imprimantes, systèmes de reliure, etc), tandis que les produits les plus commandés correspondent essentiellement à des fournitures de bureau ou mobiliers.

Cette analyse (ainsi que celles effectuées précédemment par catégorie puis sous-catégories de produits) met en évidence le fait que le volume de ventes n'est pas nécessairement synonyme de rentabilité : un produit peut être commandé très fréquemment sans générer autant de profit qu'un équipement vendu en plus faible quantité mais à fort profit.

Recommandations :

L'enseigne pourrait :

- Renforcer la disponibilité et promouvoir les produits les plus rentables, notamment les copieurs, imprimantes,... afin d'augmenter davantage le chiffre d'affaires et les bénéfices.
- Analyser l'activité des produits très fréquemment commandés (**Staples**, **Staple envelope**, **Easy-staple paper**, etc.) afin d'identifier des opportunités d'amélioration de la rentabilité, par exemple par une optimisation des coûts d'approvisionnement, une légère révision des prix ou des offres groupées avec des produits à plus forte valeur ajoutée.

V.10 Visualisations par niveau de réduction

V.10.1 Profit total par niveau de réduction

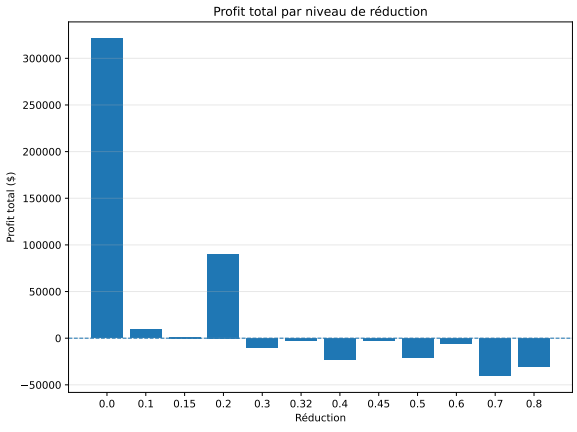


FIGURE 42 – Profit total par niveau de réduction

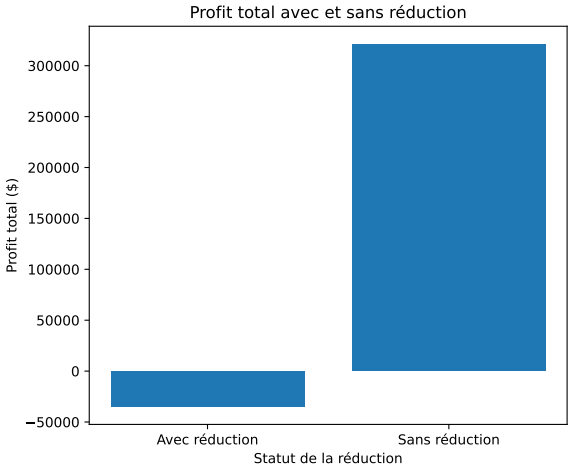


FIGURE 43 – Profit total avec et sans réduction

V.10.2 Quantité totale vendue par niveau de réduction

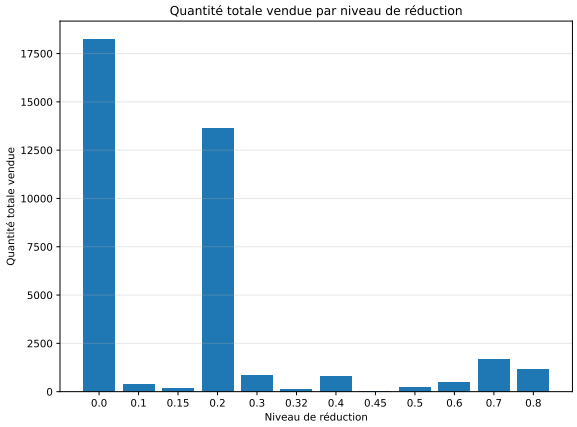


FIGURE 44 – Quantité totale vendue par niveau de réduction

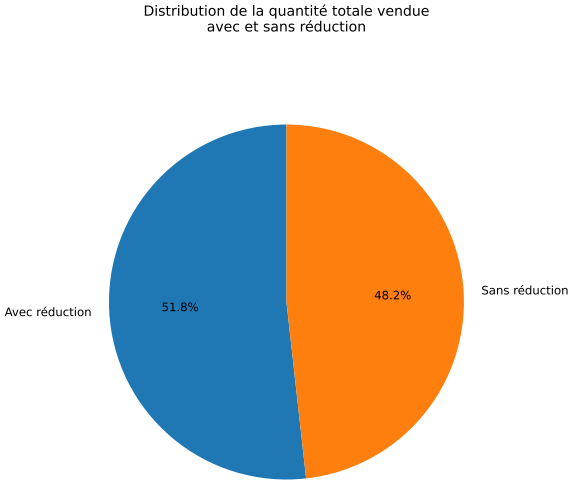


FIGURE 45 – Quantité totale vendue avec et sans réduction

V.10.3 Montant total des ventes par niveau de réduction

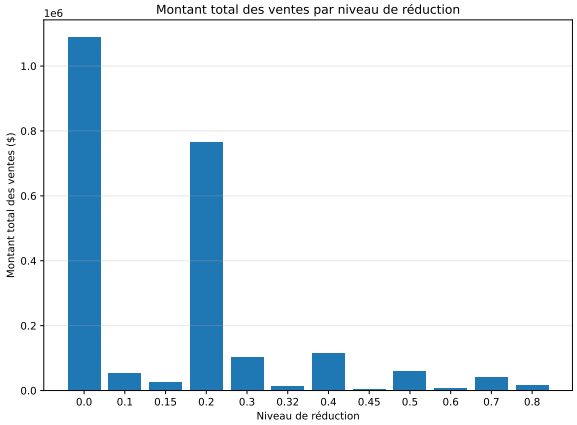


FIGURE 46 – Montant total des ventes par niveau de réduction

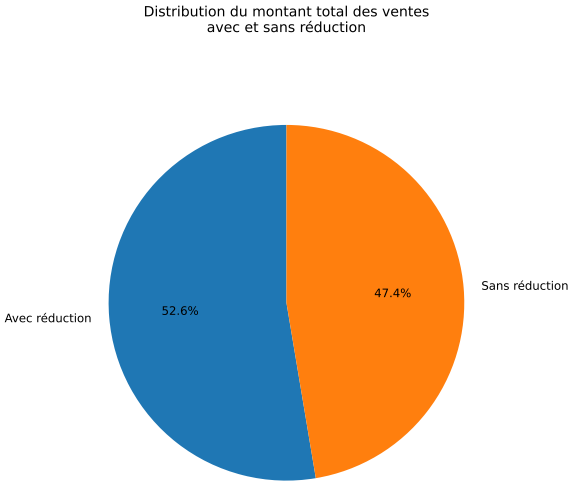


FIGURE 47 – Montant total des ventes avec et sans réduction

Les commandes sans réduction (0%) génèrent de très loin le profit total le plus élevé, le montant total des ventes le plus important ainsi que la plus grande quantité vendue. Cela montre que l'enseigne réalise l'essentiel de sa performance financière sans recourir aux remises.

Le niveau de 20% de réduction constitue une exception : il représente le meilleur compromis parmi les ventes remisées. Il génère un volume de ventes élevé, une quantité importante de

produits vendus et demeure fortement rentable. Cette réduction semble donc être la plus efficace pour stimuler les ventes tout en préservant la rentabilité.

À partir de 30% de réduction, le profit diminue fortement et devient même négatif pour plusieurs niveaux de remise (30%, 40%, 50%, 70% et 80%). Les remises importantes ne compensent donc pas la perte de marge.

Les réductions les plus élevées (70% et 80%) permettent certes d'écouler davantage de produits que certains niveaux intermédiaires, mais elles s'accompagnent des pertes financières les plus importantes.

Les diagrammes circulaires montrent que les ventes avec réduction représentent environ 52% aussi bien du montant total des ventes que de la quantité totale vendue, contre environ 48% pour les ventes sans réduction. Les remises contribuent donc légèrement à la majorité de l'activité commerciale, mais cette augmentation de volume ne se traduit pas systématiquement par une amélioration du profit, puisque l'essentiel du profit est réalisé par les ventes sans réductions.

Recommandations :

L'enseigne pourrait :

- Privilégier les remises modérées, en particulier autour de 20%, qui offrent le meilleur équilibre entre augmentation des ventes et maintien de la rentabilité.
- Réduire ou limiter les remises supérieures à 30%, notamment celles de 70% et 80%, sauf dans des situations particulières (liquidation de stocks, etc), car elles génèrent des pertes importantes.
- Mettre en place une politique de remise plus fondée sur la rentabilité.

VI Décomposition des séries temporelles mensuelles

Avant de mettre en œuvre l'entraînement des modèles de prévision, nous analysons le comportement de deux principales variables au cours du temps afin de mieux comprendre leur évolution.
Dans cette section, deux séries temporelles mensuelles sont construites à partir du jeu de données : la quantité totale vendue par mois et le montant total des ventes par mois.
Chacune de ces séries temporelles couvre l'ensemble de la période d'étude, c'est à dire de janvier 2014 à décembre 2017.

Une décomposition additive est ensuite réalisée sur chacune d'elles afin de les séparer en quatre composantes : les valeurs observées, la tendance, la saisonnalité et les résidus. Cette analyse permet notamment de répondre à plusieurs questions importantes comme :

— la série présente t-elle une tendance générale (croissante, décroissante ou stable) au fil du temps.
— Existe t-il une saisonnalité, c'est-à-dire un comportement qui se répète régulièrement d'une année à l'autre (comme une augmentation des ventes durant certaines périodes de l'année)

Ces informations sont importantes pour le choix et le paramétrage de certains des modèles que nous allons entraîner par la suite.

À l'issue de cette décomposition, un test de Ljung-Box est appliqué aux résidus de chaque série. Ce test permet de vérifier si les résidus sont indépendants dans le temps, autrement dit s'ils se comportent comme un bruit blanc.

Nous affichons ci-dessous les décompositions additives de la quantité totale vendue et du montant total des ventes par mois :

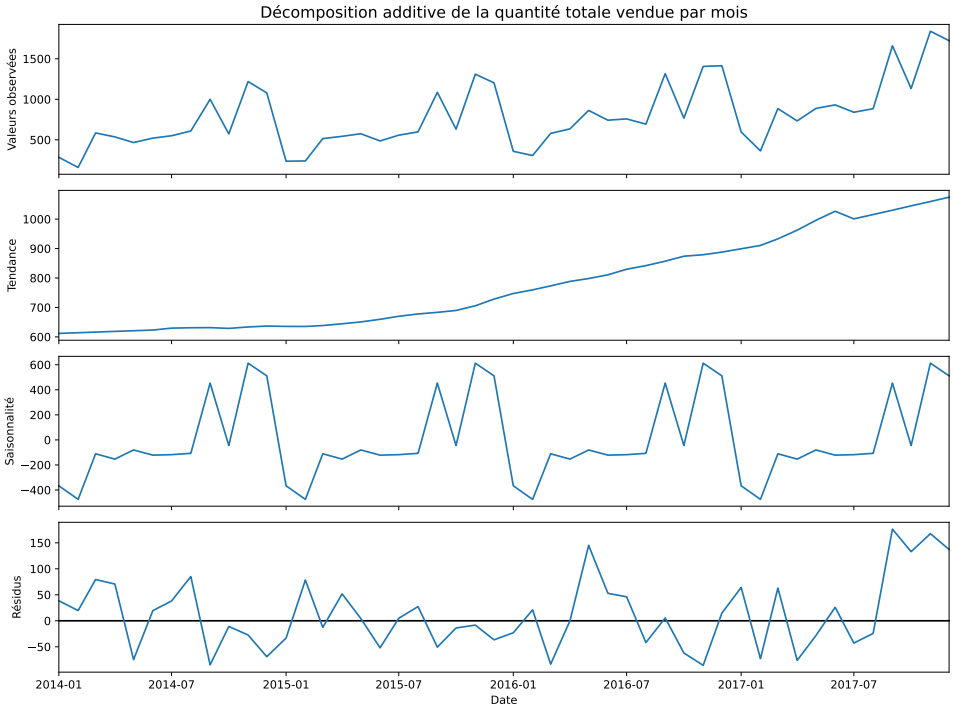


FIGURE 48 – Décomposition additive de la quantité totale vendue par mois

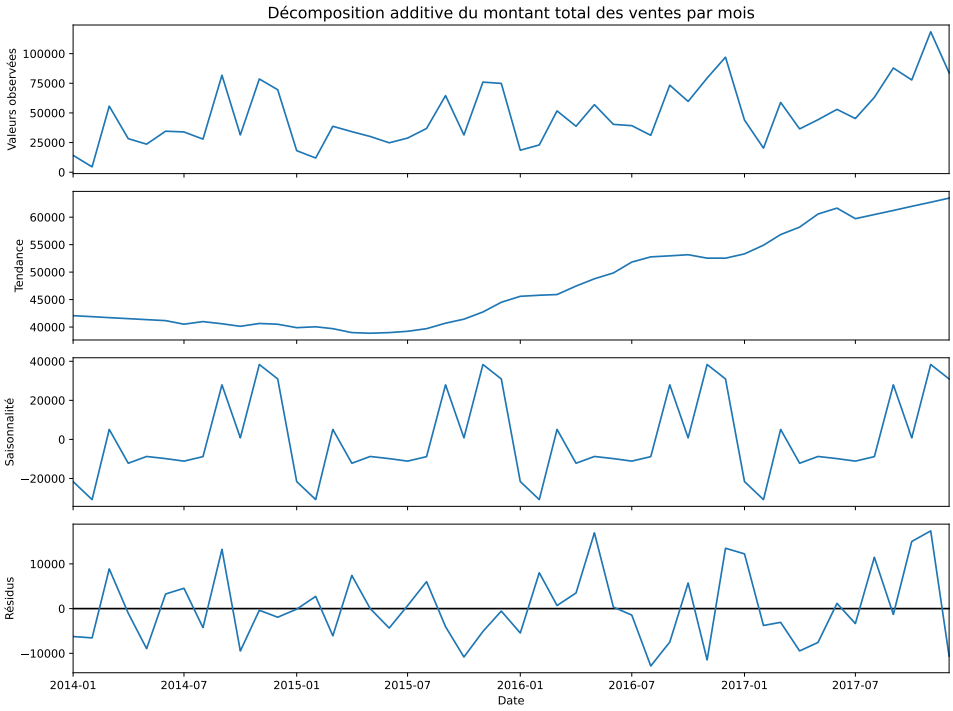


FIGURE 49 – Décomposition additive du montant total des ventes par mois

On observe très clairement une tendance à la hausse pour chacune des deux séries étudiées : le montant total des ventes et la quantité totale vendue par mois. Cela montre que l'activité commerciale évolue sur la période étudiée.

Les deux séries présentent également une saisonnalité marquée. Les ventes et la quantité vendue augmentent considérablement au cours des derniers mois de chaque année et diminue nettement au début de l'année suivante au mois de janvier. Ce comportement met en évidence un cycle stable très certainement lié au période de forte activité commerciale en fin d'année.

Les résidus sont globalement centrés autour de zéro et ne présentent ni tendance ni saisonnalité apparentes.

Les résultats du test de LJUNG-BOX réalisé sur les résidus des deux séries précédentes sont présentés ci-dessous :

```
============================================================
TEST DE LJUNG-BOX - MONTANT TOTAL DES VENTES
============================================================
Lag testé : 12
Statistique : 25.5186
P-value : 0.0125

Résultat : présence d'autocorrélation significative dans les résidus (p < 0.05).
Les résidus ne peuvent donc pas être considérés comme un bruit blanc.

============================================================
TEST DE LJUNG-BOX - QUANTITÉ TOTALE VENDUE
============================================================
Lag testé : 12
Statistique : 10.2579
P-value : 0.5933

Résultat : aucune autocorrélation significative détectée dans les résidus (p >= 0.05).
Les résidus peuvent être considérés comme approximativement indépendants.
```

Le test de Ljung-Box montre que les résidus de la série des quantités ne présentent pas d'autocorrélation significative, contrairement à ceux de la série des ventes. La décomposition semble donc suffisamment capturer la structure temporelle de la série des quantités, tandis que les résidus de la série du montant des ventes présentent encore une dépendance temporelle non expliquée.

VII Modèles de Prévision de la demande (Demand Forecasting)

Dans cette partie, nous utilisons l'historique des commandes afin de prédire la quantité d'articles à prévoir pour les mois à venir. L'objectif sera de prédire la quantité totale

d'articles à prévoir pour les 12 derniers mois du dataset et de comparer les prédictions des différents modèles utilisés avec les quantités réelles d'articles vendues par mois.

VII.1 Séparation des données

Le jeu de données SuperStore Dataset comporte l'historique des commandes de l'enseigne sur 4 ans, soit 4 périodes de 12 mois, donc un total de 48 mois.

```
Première date de commande : 2014-01-03 00:00:00

Dernière date de commande : 2017-12-30 00:00:00
```

Nous créons alors une série temporelle qui va contenir pour chaque mois, la quantité totale d'articles vendues et cela pour tous les 48 mois (de janvier 2014 à décembre 2017). Nous séparons ensuite la serie en :

- les 36 premiers mois (le passé utiliser) pour l'entrainement des modèles
- les 12 derniers mois (le futur à prédir) pour le test final des modèles et les comparaisons

Série d'entraînement :

Mois	Quantité
2014-01-01	284
2014-02-01	159
2014-03-01	585
2014-04-01	536
2014-05-01	466
2014-06-01	521
2014-07-01	550
2014-08-01	609
2014-09-01	1000
2014-10-01	573
2014-11-01	1219
2014-12-01	1079
2015-01-01	236
2015-02-01	239
2015-03-01	515

FIGURE 50 – Aperçu des 15 premiers mois de la série d'entrainement

Série de test :

Mois	Quantité
2017-01-01	597
2017-02-01	363
2017-03-01	885
2017-04-01	733
2017-05-01	887
2017-06-01	931
2017-07-01	840
2017-08-01	884
2017-09-01	1660
2017-10-01	1133
2017-11-01	1840
2017-12-01	1723

FIGURE 51 – Série de test

```
Nombre de mois d'entraînement : 36
Nombre de mois de test : 12
Période d'entraînement : 2014-01-01 00:00:00 à 2016-12-01 00:00:00
Période de test : 2017-01-01 00:00:00 à 2017-12-01 00:00:00
```

VII.2 Entrainement des modèles

Nous construsons trois modèles différents qui vont apprendre pour chaque mois, l'évolution de la quantité totale d'articles commandées sur les 36 premiers mois (janvier 2014 - décembre 2016), et qui ensuite vont prédire la quantité totale d'articles à prévoir pour les 12 prochains mois.

Les modèles entrainés sont :

- Prophet
- Holt-Winters (Triple Exponential Smoothing)
- SARIMA

Dans l'optique d'entrainé les modèles sur les meilleurs paramètres pour ces données, nous effectuons une optimisation d'hyperparamètres par Grid Search pour chaque modèle. Les plages d'hyperparamètres testées pour chacun des modèles sont : **Prophet :**

- `changepoint_prior_scale : [0.001, 0.01, 0.05, 0.1, 0.5]`
- `seasonality_prior_scale : [0.01, 0.1, 1, 10]`
- `seasonality_mode : ['additive', 'multiplicative']`
- `changepoint_range : [0.8, 0.9, 1.0]`
- `n_changepoints : [10, 20, 30]`

Holt-Winters (Triple Exponential Smoothing) :

- `trend : ['add', 'mul', None]`
- `seasonal : ['add', 'mul', None]`
- `seasonal_periods : [12]`
- `damped_trend : [True, False]`
- `use_boxcox : [True, False]`

SARIMA :

- `p : [0, 1, 2]`
- `d : [0, 1]`
- `q : [0, 1, 2]`
- `P : [0, 1]`
- `D : [0, 1]`
- `Q : [0, 1]`
- `m : [12]`

Pour chaque modèle, l'algorithme teste toutes les combinaisons possibles d'hyperparamètres. Pour chaque combinaison, le modèle est construit avec cette configuration puis entraîné et évalué par validation croisée.

Après avoir tester toutes les combinaisons, les performances obtenues pour chaque combinaison sont comparées et la combinaison d'hyperparamètres ayant permis d'obtenir le meilleur score est conservée.

Ce processus d'optimisation est effectué séparément pour chacun des modèles.

Pour chaque combinaison d'hyperparamètres testées, l'étape de validation croisée s'effectue sur 3 folds :

- 1er fold : 1er au 18ème mois pour l'entrainement et du 19ème au 24ème mois pour l'évaluation
- 2ème fold : du 1er au 24ème mois pour l'entrainement et du 25ème au 30ème mois pour l'évaluation
- 3ème fold : du 1er au 30ème mois pour l'entrainement et du 31ème au 36ème mois pour l'évaluation

sauf pour le modèle Holt-Winter qui n'utlisera que les folds 2 et 3, car `seasonal_periods` $= 12$ nécessite au moins $2 \times 12 = 24$ observations mensuelles pour l'entrainement.

Nous affichons ci-dessous les meilleurs paramètres retenues après optimisation pour chacun des trois modèles :

```
======================================
 MEILLEURS HYPERPARAMÈTRES
======================================
```

PROPHET	
changepoint_prior_scale	0.1
seasonality_prior_scale	0.1
seasonality_mode	additive
changepoint_range	0.9
n_changepoints	20
RMSE_Fold_1	71.601187
RMSE_Fold_2	105.767326
RMSE_Fold_3	67.196778
RMSE_moyenne	81.521764

HOLT-WINTERS	
trend	None
seasonal	add
seasonal_periods	12
damped_trend	False
use_boxcox	False
RMSE_Fold_2	147.641367
RMSE_Fold_3	72.432624
RMSE_moyenne	110.036996

SARIMA	
p	0.000000
d	1.000000
q	2.000000
P	0.000000
D	1.000000
Q	0.000000
m	12.000000
RMSE_Fold_1	90.821972
RMSE_Fold_2	105.941759
RMSE_Fold_3	64.357268
RMSE_moyenne	87.040333

Ensuite les modèles sont reconfigurer avec ces paramètres puis réentrainé cette fois sur les 36 moids d'entrainement complet sans aucune validation croisé. Après entrainement, ils sont utilisés pour predires les quantités totales d'articles à prévoir pour chacun des 12 mois suivantes les 36 mois d'entrainements. Les erreurs de prédictions (RMSE et MAE) des différents modèles sont présentées dans le tableau ci-dessous :

Modèle	RMSE	MAE
Prophet	128.970497	110.510110
SARIMA	137.297379	118.347918
Holt-Winters	225.326364	181.138230

FIGURE 52 – Erreurs de prédictions des 3 modèles sur les 12 mois de test

Nous comparons ci-dessous les résultats de prédictions des différents modèles avec les valeurs réelles de la quantité totale vendue sur les 12 mois de l'ensemble test.

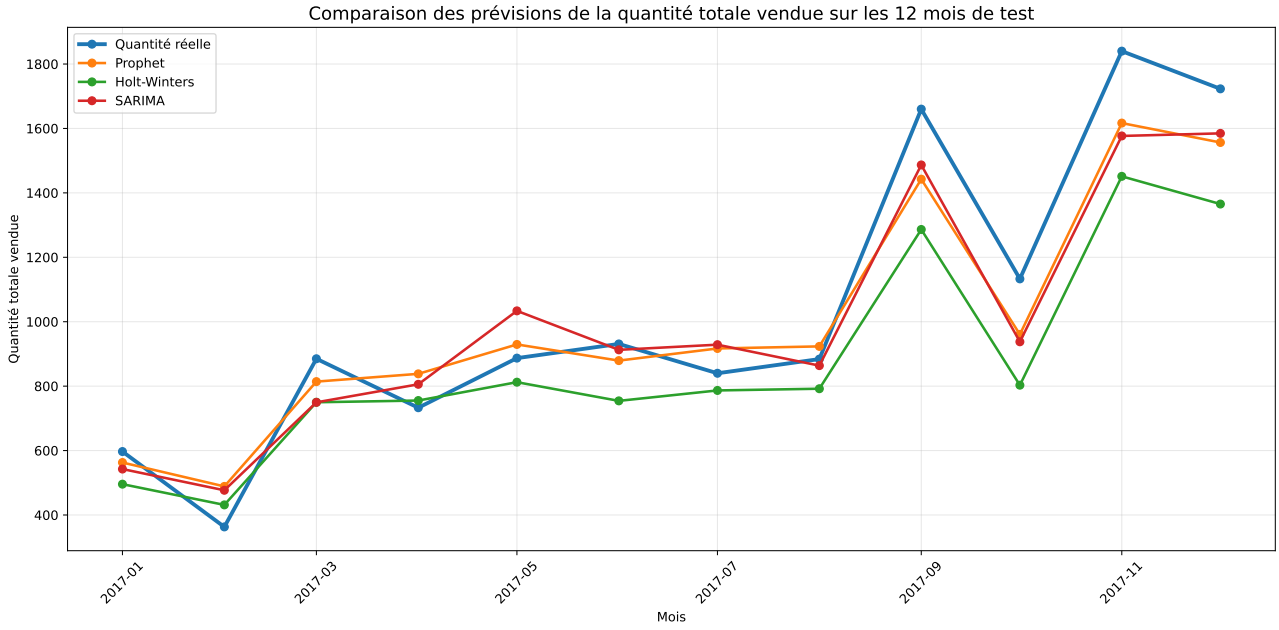


FIGURE 53 – Comparaison des prévisions de la quantité totale vendue sur les 12 mois de test avec les valeurs réelles

Les trois modèles reproduisent globalement la tendance observée sur les 12 mois de test. Ils parviennent notamment à identifier les principales hausses et baisses de la quantité vendue. Parcontre, ils ont tendance à sous-estimer légèrement les pics les plus importants, particulièrement en fin d'année. Holt-Winters semble présenter les sous-estimations les plus marquées, tandis que Prophet et SARIMA suivent globalement mieux les valeurs réelles.

On peut donc dire que les modèles captent correctement la dynamique générale, mais restent un peu moins précis lors des fortes variations.

Précédemment, nous avons prédit la quantité totale d'articles à prévoir pour chacun des 12 prochains mois, mais cela ne nous renseigne nullement sur la quantité réelle à prévoir par catégorie d'articles, par sous-catégorie d'articles ou directement sur la quantité à prévoir par article.

Pour répondre à ces questions, une façon de faire est d'entrainer directement les modèles sur les données de quantités mensuelles d'articles par catégorie ou par sous-catégorie, et de faire les prévisions directement des quantités mensuelles par catégorie ou sous-catégorie. On peut suivre un procédé similaire si l'on souhaite prédire directement la quantité mensuelle future par article. C'est la méthode normale.

Toutefois, on peut également, sous certaines hypothèses, envisager de faire autrement en se basant sur les proportions passées et leur marge d'évolution, et décider de fragmenter la quantité totale mensuelle globale prédite en conséquence. C'est une approche possible.

VIII Modèles de Prévision des ventes (Sales Forecasting)

Dans cette section, les prévisions sont effectuées sur le montant total des ventes par mois. La série temporelle considérée est la série du montant total des ventes de chacun des 48 mois du jeu de données. Les modèles utilisés et les plages d'hyperparamètres considérés pour l'optimisation sont les memes que précédemment.
Les processus de séparation des données, d'optimisation des hyperparamètres, d'entrainement des modèles et de comparaison des prévisions sont effectués de la meme manière qu'avec la série temporelle sur la quantité totale vendue par mois. Nous présentons ci-dessous, les meilleurs hyperparamètres issues de l'optimisation pour chaque modèle :

```
================================================================================
MEILLEURS HYPERPARAMÈTRES - VENTES
================================================================================

PROPHET                          HOLT-WINTERS                       SARIMA

------------------------------ ---------------------------------   ------------------------
changepoint_prior_scale : 0.1  trend : None                       p : 0
seasonality_prior_scale : 0.1  seasonal : add                     d : 1
seasonality_mode : additive    seasonal_periods : 12              q : 1
changepoint_range : 1.0        damped_trend : False               P : 1
n_changepoints : 30            use_boxcox : False                 D : 1
RMSE Fold 1 : 8219.99          initialization_method : heuristic Q : 0
RMSE Fold 2 : 15245.417        RMSE Fold 2 : 13255.042           m : 12
RMSE Fold 3 : 11319.437        RMSE Fold 3 : 13388.54            RMSE Fold 1 : 8934.197
RMSE moyenne : 11594.948       RMSE moyenne : 13321.791          RMSE Fold 2 : 13702.368
                                                                  RMSE moyenne : 11396.717
```

Les modèles sont ensuite reconfigurés puis réentrainés avec les hyperparamètres précédents.

Nous affichons ci-dessous le graphique de comparaison entre les valeurs réelles du montant

total des ventes par mois et celles prédites par chacun des trois modèles précédents sur les 12 mois de test :

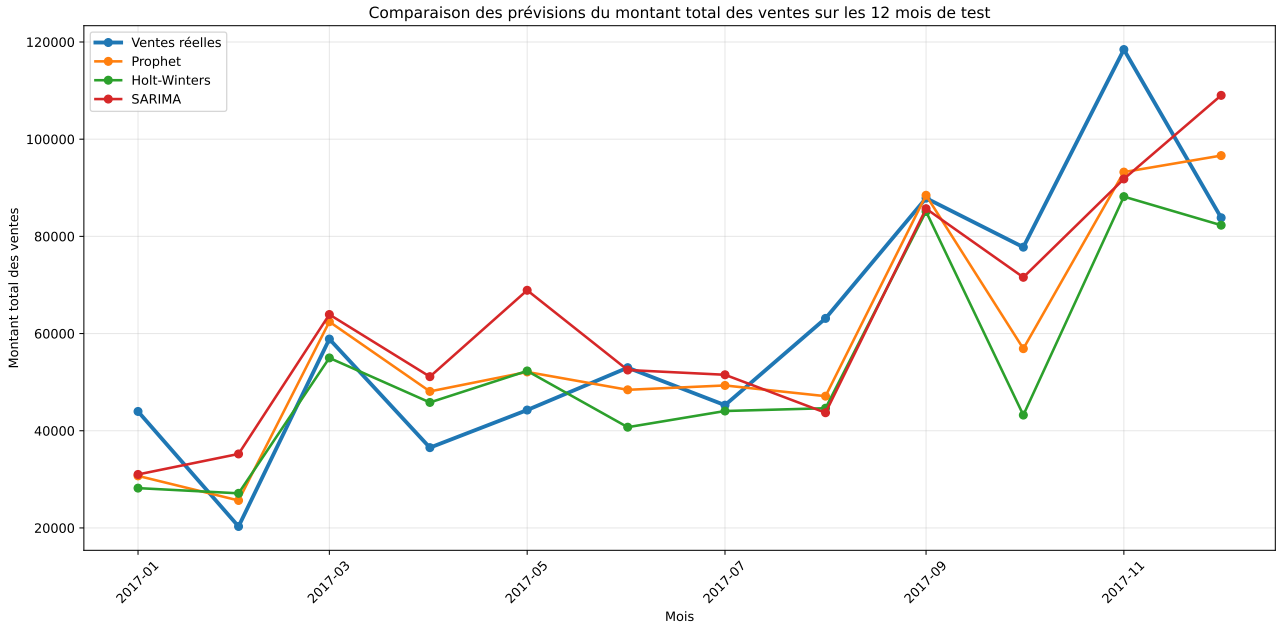


FIGURE 54 – Comparaison des prévisions du montant totale des ventes sur les 12 mois de test avec les valeurs réelles

On peut voir ici que les modèles captent assez bien la tendance générale, meme s'ils restent parfois peu précis sur certains mois.

IX Clients inactifs et KPIs

IX.1 Clients perdus et nouveaux clients

Nous considérons un client comme perdu lorsque sa dernière commande remonte à plus de 400 jours par rapport à la date de commande la plus récente du jeu de données. Autrement dit, si aucune commande n'a été effectuée par un client au cours des 400 derniers jours couverts par le jeu de données, celui-ci est considéré comme perdu. Dans le même temps, nous définissons également ce qu'est un nouveau client. Un nouveau client est un client dont le premier achat a été effectué au cours des 400 derniers jours précédant la date de commande la plus récente du jeu de données. Le choix de 400 jours provient de l'analyse des délais entre deux commandes successives. En effet, nous avons calculés quelques percentiles des delais (en jours) entre deux commandes successives :

```
0.25     55.0
0.50    141.0
0.75    275.0
0.80    315.0
0.90    438.9
0.95    554.0
Name: ecart_jours, dtype: float64
```

Comme on peut le voir, les percentiles des délais entre deux commandes montrent que 80%

des intervalles entre deux commandes sont inférieurs ou égaux à 316 jours et 90% sont inférieurs ou égaux à 445 jours. Le seuil d'inactivité a ainsi été fixé à 400 jours, valeurs comprise entre ces deux percentiles. Cela signifie qu'une très grande majorité des intervalles habituels entre deux commandes sont inférieurs à 400 jours. Un client qui dépasse 400 jours sans nouvelle comme présente donc une inactivité relativement inhabituelle.

Pour finir, nous définissons une dernière variable permettant d'identifier les clients ayant effectué plusieurs commandes distinctes (au moins 2 distinctes) au cours de la période étudiée. Nous appellerons les trois variables crées précedemment : client_perdu, nouveau_client et client_multi_commandes. Les proportions associées à chacune des catégories de ces différentes variables sont présentées ci-dessous :

```
--- nouveau_client ---   --- client_multi_commandes ---  --- client_perdu ---
Effectifs :              Effectifs :                     Effectifs :
nouveau_client           client_multi_commandes          client_perdu
False    779             True     781                    False    710
True      14             False     12                    True      83

Proportions (%) :        Proportions (%) :               Proportions (%) :
nouveau_client           client_multi_commandes          client_perdu
False    98.23           True     98.49                  False    89.53
True      1.77           False     1.51                  True     10.47
```

IX.2 Quelques indicateurs clés de performances

Nous calculons ci-après quelques indicateurs clées de performances :

- Profit moyen par client = $\frac{\text{Profit total}}{\text{Nombre de clients uniques}}$
- Revenu moyen par commande = $\frac{\text{Ventes totales}}{\text{Nombre de commandes uniques}}$
- Chiffre d'affaires moyen par client = $\frac{\text{Chiffre d'affaires total}}{\text{Nombre de clients uniques}}$
- Nombre moyen de commandes par client = $\frac{\text{Nombre total de commandes uniques}}{\text{Nombre total de clients uniques}}$
- Quantité moyenne par commande = $\frac{\text{Quantité totale vendue}}{\text{Nombre de commandes uniques}}$
- Marge globale = $\frac{\text{Profit total}}{\text{Chiffre d'affaires total}} \times 100$
- Taux de commandes rentables = $\frac{\text{Nombre de commandes dont le profit est positif}}{\text{Nombre total de commandes}} \times 100$
- Profit moyen par commande = $\frac{\text{Profit total}}{\text{Nombre de commandes uniques}}$
- Taux de commandes déficitaires = $\frac{\text{Nombre de commandes dont le profit est négatif}}{\text{Nombre total de commandes}} \times 100$

Nous affichons les valeurs des résultats associés ci-dessous :

```
Profit moyen par client : 361.16
Revenu moyen par commande : 458.61
Chiffre d'affaires moyen par client : 2896.85
Nombre moyen de commandes par client : 6.0
Quantité moyenne d'articles par commande : 8.0
Marge globale : 12.47 %
Taux de commandes rentables : 79.26 %
Profit moyen par commande : 57.18
Taux de commandes déficitaires : 20.4 %
```

A partir des résultats précédents et de ceux obtenues à partir des trois variables créées à la sous-section précédente, nous dressons le tableau récapitulatif suivant :

	Indicateur	Valeur
0	Profit moyen par client	361.16 $
1	Revenu moyen par commande	458.61 $
2	Chiffre d'affaires moyen par client	2896.85 $
3	Nombre moyen de commandes par client	6.00
4	Quantité moyenne d'articles par commande	8.00
5	Marge globale	12.47 %
6	Taux de commandes rentables	79.26 %
7	Profit moyen par commande	57.18 $
8	Taux de commandes déficitaires	20.40 %
9	Taux de clients actifs	66.46 %
10	Taux de nouveaux clients	0.50 %
11	Taux de clients perdus	33.54 %
12	Taux de clients multi-commandes	98.49 %

FIGURE 55 – Quelques indicateurs clés de performances

X Segmentation des clients par K-Means

L'objectif de cette partie est de regrouper les clients présentant des caractéristiques ou des comportements d'achat similaires, afin d'identifier différents profils de clientèle et d'adapter les stratégies commerciales à chacun de ces profils.

X.1 Construction des variables RFM et Profit

La similarité entre les clients est évaluée à partir des variables issues de l'analyse RFM. Cette méthode caractérise chaque client selon trois dimensions : la récence de sa dernière commande (R), sa fréquence d'achat (F) et le montant total de ses achats (M). À ces trois variables, nous ajoutons une quatrième dimension correspondant au profit total (bénéfice ou perte) généré par le client.

	Customer ID	Recency	Frequency	Monetary	Total_Profit
0	AA-10315	184	5	5563.560	-362.8825
1	AA-10375	19	9	1056.390	277.3824
2	AA-10480	259	4	1790.512	435.8274
3	AA-10645	55	6	5086.935	857.8033
4	AB-10015	415	3	886.156	129.3465
5	AB-10060	54	8	7755.620	2054.5885
6	AB-10105	41	10	14473.571	5444.8055
7	AB-10150	41	5	966.710	313.6597
8	AB-10165	25	8	1113.838	220.8130
9	AB-10255	166	9	914.532	264.5675
10	AB-10600	50	4	1515.862	-274.9604
11	AC-10420	232	3	925.800	-62.1342
12	AC-10450	11	7	5527.846	1366.0098
13	AC-10615	6	5	2537.686	298.8273
14	AC-10660	282	5	657.316	-28.7004

FIGURE 56 – Aperçu des 15 premiers cliens et les valeurs des variables RFM et Profit

Une fois ces variables calculées pour chaque client et regroupées dans un même tableau comme ci-dessus, elles sont standardisées afin de les placer sur des échelles comparables. Cette étape est particulièrement importante pour K-Means, puisque l'algorithme forme les clusters à partir des distances entre les observations.

Pour chaque valeur x_i d'une variable, la standardisation (centrage - réduction) applique la transformation suivante :

$$z_i = \frac{x_i - \mu}{\sigma}$$

où :

- x_i : valeur originale ;
- μ : moyenne de la variable ;
- σ : écart-type de la variable ;
- z_i : nouvelle valeur standardisée.

Nous affichons ci-dessous les valeurs standardisées des variables RFM et Profit pour les 15 premiers clients :

	Customer ID	Recency	Frequency	Monetary	Total_Profit
0	AA-10315	0.199889	-0.516429	1.015112	-0.810161
1	AA-10375	-0.686762	1.052644	-0.700590	-0.093739
2	AA-10480	0.602912	-0.908697	-0.421139	0.083553
3	AA-10645	-0.493311	-0.124161	0.833680	0.555721
4	AB-10015	1.441199	-1.300965	-0.765391	-0.259383
5	AB-10060	-0.498685	0.660376	1.849543	1.894860
6	AB-10105	-0.568542	1.444913	4.406802	5.688331
7	AB-10150	-0.568542	-0.516429	-0.734728	-0.053146
8	AB-10165	-0.654520	0.660376	-0.678722	-0.157037
9	AB-10255	0.103163	1.052644	-0.754590	-0.108078
10	AB-10600	-0.520179	-0.908697	-0.525687	-0.711781
11	AC-10420	0.457823	-1.300965	-0.750300	-0.473640
12	AC-10450	-0.729751	0.268108	1.001517	1.124377
13	AC-10615	-0.756619	-0.516429	-0.136719	-0.069743
14	AC-10660	0.726505	-0.516429	-0.852502	-0.436229

FIGURE 57 – Aperçu des 15 premiers cliens et les valeurs des variables RFM et Profit standardisées

X.2 Méthode du coude, de la silhouette et algorithme K-Means

X.2.1 Méthode du coude et méthode de la Silhouette

Pour segmenter les clients en groupes homogènes, nous utilisons l'algorithme K-Means. K-Means est un algorithme d'apprentissage non supervisé qui regroupe les observations en plusieurs clusters en fonction de leur similarité. Dans notre cas, chaque client est représenté par quatre caractéristiques : la récence de sa dernière commande, sa fréquence d'achat, le montant total de ses achats et le profit total généré. L'algirithme K-Means cherche donc à regrouper les clients ayant des profils proches selon ces quatre dimensions.

Avant d'appliquer l'algorithme, il est nécessaire de déterminer le nombre de clusters k à retenir. Pour cela, nous utilisons la méthode du coude, qui consiste à calculer l'inertie du modèle pour plusieurs valeurs de k. L'inertie mesure la dispersion des observations autour du centre de leur cluster. On cherche alors la valeur de k à partir de laquelle l'ajout de nouveaux clusters n'entraîne plus qu'une faible diminution de l'inertie.

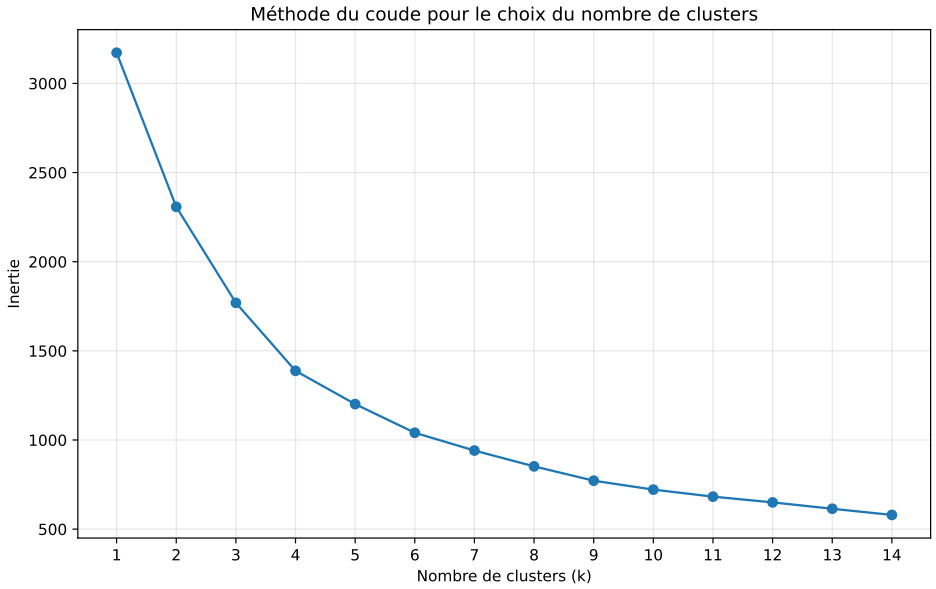


FIGURE 58 – Méthode du coude pour le choix du nombre de clusters

La diminution de l'inertie semble forte jusqu'à 4, puis la courbe commence à s'aplatir. Passer de 4 à 5 apporte encore une amélioration, mais beaucoup moins importante. On peut donc choisir le nombre de cluster à $k = 4$.

Cependant, le problème de la méthode du coude est bien son caractère visuel : quelqu'un pourrait regarder la même courbe et défendre $k = 5$. On va donc ajouter un critère supplémentaire .

L'un des plus pertinent ici peut etre le coefficient de silhouette. Pour chaque valeur de k, il mesure à la fois si les clients sont proches des autres clients de leur cluster et suffisamment éloignés des autres clusters. Le score varie entre -1 et 1 et, globalement, plus il est élevé, meilleure est la séparation des clusters. On peut donc tester $k = 2, ..., 14$:

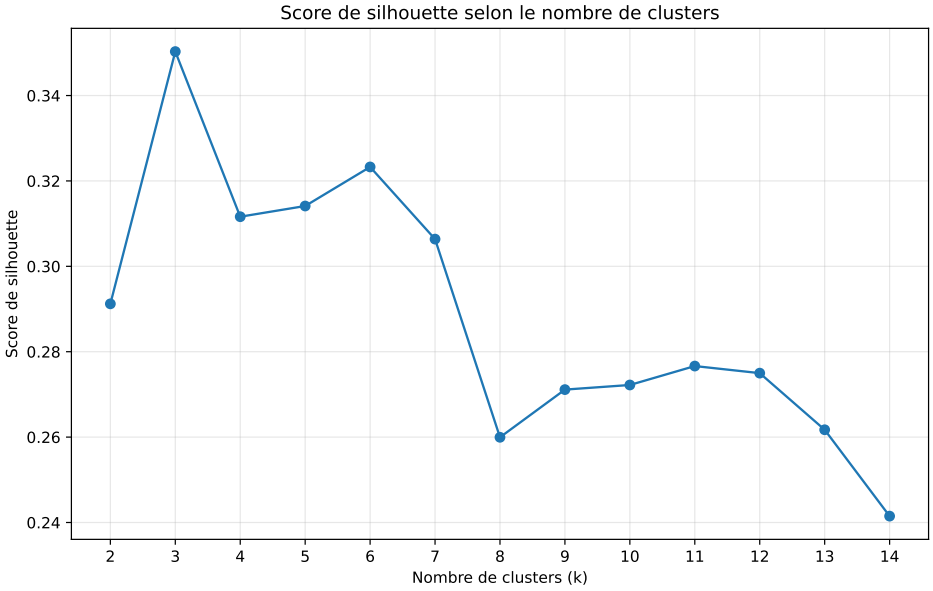


FIGURE 59 – Score de silhouette selon le nombre de clusters

La méthode de la silhouette suggère quant à elle $k = 3$ comme nombre de clusters. Tandis que celle du coude suggérait plutot 4 voir meme 5. Ne sachant qui de $k = 3$, $k = 4$ ou $k = 5$ donnera les groupes les plus interprétables et utiles pour l'enseigne, nous entrainons l'akgorithme K-Means avec $k = 3$ puis $k = 4$ puis $k = 5$ et pour chacun, nous regardons les moyennes de Récence, Fréquence, Montant et Profit total de chaque groupe ainsi que le nombre de clients dans chaque cluster. De cette façon on pourra savoir si avec $k = 4$ ou 5 clusters on découvre réellement un quatrième ou un cinquième profil commercial différent et pertinent.

X.2.2 Algorithme K-Means et interprétation commerciale

Nous présentons ci-dessous les les tableaux contenant les différents clusters avec le nombre de clients associé et les moyennes de chaque variable par clusters.

K-Means pour k=3

	Customer ID	Recency	Frequency	Monetary	Total_Profit	Cluster
0	AA-10315	184	5	5563.560	-362.8825	2
1	AA-10375	19	9	1056.390	277.3824	2
2	AA-10480	259	4	1790.512	435.8274	2
3	AA-10645	55	6	5086.935	857.8033	0
4	AB-10015	415	3	886.156	129.3465	1
5	AB-10060	54	8	7755.620	2054.5885	0
6	AB-10105	41	10	14473.571	5444.8055	0
7	AB-10150	41	5	966.710	313.6597	2
8	AB-10165	25	8	1113.838	220.8130	2
9	AB-10255	166	9	914.532	264.5675	2
10	AB-10600	50	4	1515.862	-274.9604	2
11	AC-10420	232	3	925.800	-62.1342	2
12	AC-10450	11	7	5527.846	1366.0098	0
13	AC-10615	6	5	2537.686	298.8273	2
14	AC-10660	282	5	657.316	-28.7004	2

FIGURE 60 – Clusters associés au 15 premiers clients par l'algorithme K-Means ($k = 3$)

Cluster	Nombre_clients	Recency_moyenne	Frequency_moyenne	Monetary_moyen	Profit_moyen
0	171	93.23	8.85	6348.99	1218.25
1	108	530.05	3.69	1449.64	153.18
2	514	84.10	6.03	2052.46	119.71

FIGURE 61 – Nombre de clients et moyenne des variables par clusters (k=3)

K-Means pour k=4

	Customer ID	Recency	Frequency	Monetary	Total_Profit	Cluster
0	AA-10315	184	5	5563.560	-362.8825	1
1	AA-10375	19	9	1056.390	277.3824	2
2	AA-10480	259	4	1790.512	435.8274	1
3	AA-10645	55	6	5086.935	857.8033	2
4	AB-10015	415	3	886.156	129.3465	3
5	AB-10060	54	8	7755.620	2054.5885	0
6	AB-10105	41	10	14473.571	5444.8055	0
7	AB-10150	41	5	966.710	313.6597	1
8	AB-10165	25	8	1113.838	220.8130	2
9	AB-10255	166	9	914.532	264.5675	2
10	AB-10600	50	4	1515.862	-274.9604	1
11	AC-10420	232	3	925.800	-62.1342	1
12	AC-10450	11	7	5527.846	1366.0098	2
13	AC-10615	6	5	2537.686	298.8273	1
14	AC-10660	282	5	657.316	-28.7004	1

FIGURE 62 – Clusters associés au 15 premiers clients par l'algorithme K-Means ($k = 4$)

Cluster	Nombre_clients	Recency_moyenne	Frequency_moyenne	Monetary_moyen	Profit_moyen
0	62	124.65	8.32	9219.49	2161.11
1	341	99.38	4.77	1689.51	121.37
2	294	72.05	8.54	3429.68	332.12
3	96	558.49	3.70	1470.23	139.35

FIGURE 63 – Nombre de clients et moyenne des variables par clusters (k=4)

K-Means pour k=5

	Customer ID	Recency	Frequency	Monetary	Total_Profit	Cluster
0	AA-10315	184	5	5563.560	-362.8825	0
1	AA-10375	19	9	1056.390	277.3824	3
2	AA-10480	259	4	1790.512	435.8274	0
3	AA-10645	55	6	5086.935	857.8033	2
4	AB-10015	415	3	886.156	129.3465	1
5	AB-10060	54	8	7755.620	2054.5885	2
6	AB-10105	41	10	14473.571	5444.8055	4
7	AB-10150	41	5	966.710	313.6597	0
8	AB-10165	25	8	1113.838	220.8130	3
9	AB-10255	166	9	914.532	264.5675	3
10	AB-10600	50	4	1515.862	-274.9604	0
11	AC-10420	232	3	925.800	-62.1342	0
12	AC-10450	11	7	5527.846	1366.0098	2
13	AC-10615	6	5	2537.686	298.8273	0
14	AC-10660	282	5	657.316	-28.7004	0

FIGURE 64 – Clusters associés au 15 premiers clients par l'algorithme K-Means ($k = 5$)

Cluster	Nombre_clients	Recency_moyenne	Frequency_moyenne	Monetary_moyen	Profit_moyen
0	326	102.56	4.69	1646.23	116.32
1	93	562.27	3.65	1374.67	108.52
2	97	115.60	7.99	7260.19	1409.36
3	270	68.30	8.60	3071.25	223.30
4	7	147.71	6.29	14172.63	5912.25

FIGURE 65 – Nombre de clients et moyenne des variables par clusters (k=5)

Observations et analyses

On peut voir que le passage de 4 à 5 clusters révèle quelque chose de commercialement interessant meme si la silhouette ne favorisait pas $k = 5$.

En effet, dans la segmentation à 5 clusters, le cluster numéro 5 contient seulement 7 clients. Mais les moyennes de ces 7 clients sont complètements atypiques.
EN effet, en passant $k = 4$ à $k = 5$ clusters, K-Means a découvert un groupe supplémentaire de 7 clients qui ne sont pas simplement "meilleurs" que les autres.
Leur montant moyen est d'environ 14 173, contre 7 260 pour le deuxième groupe le plus élevé. Et surtout leur profit moyen est d'environ 5 912 contre 1 409 pour le deuxième groupe le plus rentable.

Autrement dit K-Means à 5 à isoler une petite population de clients à **très forte valeur économique**.

Et c'est d'autant plus intéressant que ces 7 clients n'ont une fréquence moyenne de commandes que de $6,29$ commandes. Donc ils ne sont meme pas les clients qui commandent le plus souvent. Le cluster 3 est à $8,60$ commandes en moyenne à titre de comparaison. Ce qui signifie que leur valeur exceptionnelle vient plutot du montant et de la rentabilité de leurs achats que d'une fréquence exceptionnellement élevée.

C'est également extremement interessant commercialement parce que ces 7 clients pourraient justifier d'une stratégie commerciale complètement différente : fédélisation prioritaire, traitement privilégié, offres personnalisées, suivi particulier, etc.

Remarque :

Tout ce qui précède affine notre réflexion sur le choix de k.
On avait raison de ne pas retenir automatiquement de $k = 3$ uniquement parce qu'il avait le meilleur score silhouette. En effet, la silhouette répond à : "Quelle segmentation produit globalement les groupes les plus compacts et les mieux séparés ? "
Mais l'enseigne veut plutot savoir : "Quelle segmentation fait apparaître des profils de clients suffisamment différents pour permettre des actions commerciales différentes ? "
Et ici, $k = 5$ révèle un profil en plus que les segmentations plus grossières absorbaient dans un groupe plus large.
C'est un très bon exemple de la raison pour laquelle une segmentation commerciale ne doit pas être choisie uniquement sur une métrique statistique.

On retient donc l'algorithme K-Means avec $k = 5$.

Cluster	Nombre_clients	Recency_moyenne	Frequency_moyenne	Monetary_moyen	Profit_moyen
0	326	102.56	4.69	1646.23	116.32
1	93	562.27	3.65	1374.67	108.52
2	97	115.60	7.99	7260.19	1409.36
3	270	68.30	8.60	3071.25	223.30
4	7	147.71	6.29	14172.63	5912.25

FIGURE 66 – Nombre de clients et moyenne des variables par clusters (k=5)

Interprétation des clusters

On peut donc classer les clients en 5 groupes différents caractérisés chacun par :

- cluster 0 (1er) : "**Clients standards / occasionnels**"

  C'est le groupe le plus important avec 326 clients. Ils achètent relativement peu souvent ($4,69$ commandes), dépensent relativement peu et génèrent un profit assez faible. Ils ne sont cependant pas particulièrement anciens avec une récence de 103 jours. C'est donc en quelque sorte la clientèle ordinaire.
- cluster 1 (2ème) : "**Clients dormants / à réactiver**"

  Ici, le signal est extrêmement clair : 562 jours de récence moyenne, de très loin la plus élevée, et seulement $3,65$ commandes en moyenne. Leur montant et leur profit sont également faibles. Ce sont donc des anciens clients qui ne commandent plus depuis longtemps. Ce serait la population naturelle pour une campagne commerciale de réactivation.
- cluster 2 (3ème) : "**Clients à forte valeur**"

  Ce groupe est beaucoup plus intéressant économiquement : presque 8 commandes en moyenne, environ 7 260 de dépenses et surtout 1 409 de profit moyen. Ce sont clairement des clients à forte valeur, rentables et assez réguliers. Ils méritent déjà une attention commerciale particulière.
- cluster 3 (4ème) : "**Clients fidèles et actifs**"

  C'est très intéressant parce que ce sont eux qui ont la récence la plus faible (68 jours) et la fréquence la plus élevée ($8,60$). Autrement dit, ils achètent souvent et récemment. En revanche, leur montant et leur profit sont bien inférieurs au cluster 2.
- cluster 4 (5ème) : "**Clients VIP / très haute valeur / clients stratégiques**"

  C'est le groupe exceptionnel qui a été repéré précédemment : seulement 7 clients, mais environ 14 173 de montant moyen et surtout 5 912 de profit moyen. Leur particularité n'est pas nécessairement d'acheter le plus souvent ou le plus récemment : c'est la valeur économique extraordinaire de leurs achats.

X.3 Visualisations des clusters et identification des clients du groupe "clients VIP"

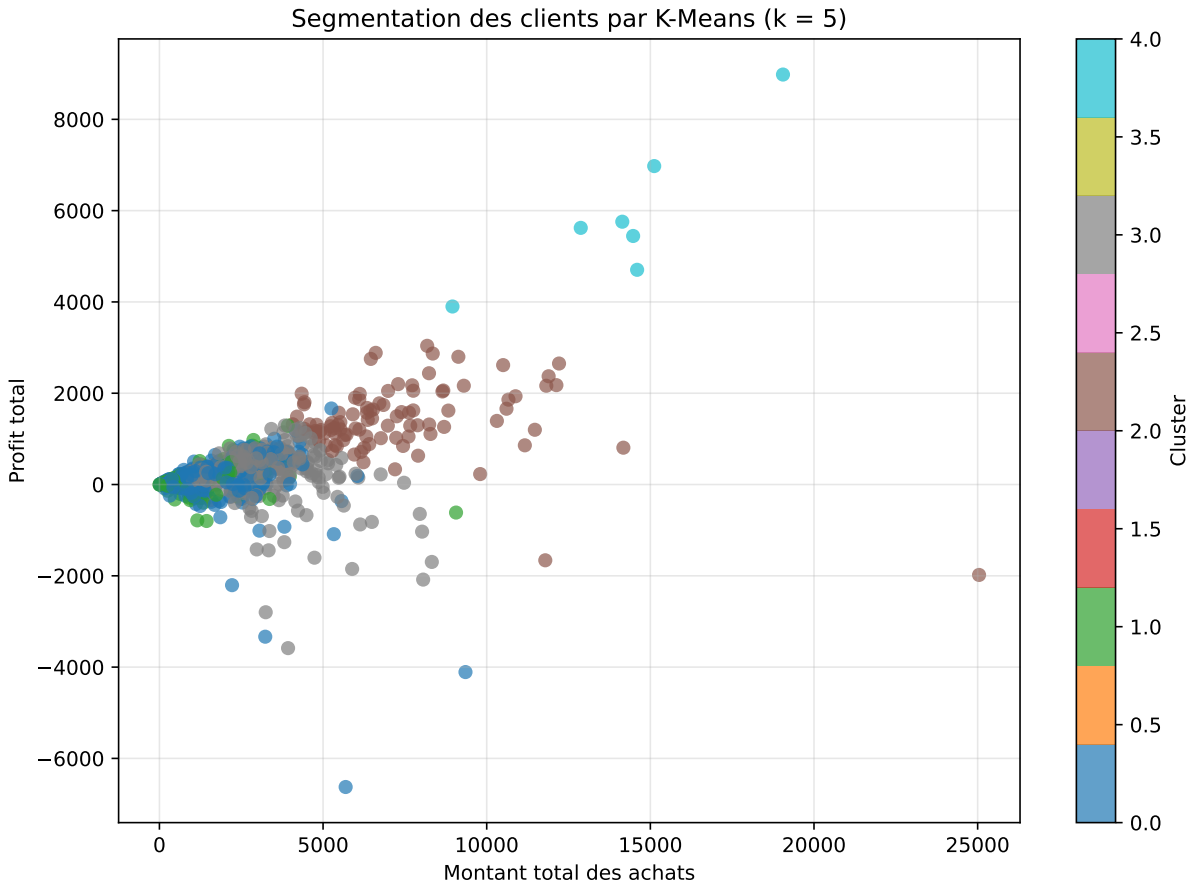


FIGURE 67 – Visualisation des 5 clusters de clients (profit en fonction du chiffre d'affaire)

On peut voir que le cluster des 7 clients exceptionnels (cluster 4) ressort très clairement. En effet, ce sont les points bleu ciel situés tout en haut à droite, avec simultanément des montants d'achats et des profits très élevés. Donc ce n'est pas simplement la moyenne du cluster qui était artificiellement tirée par un ou deux clients : on voit bien graphiquement qu'il existe un petit groupe distinct de clients à très forte valeur économique.
Et l'extraction individuelle ci-dessous le confirme :

Customer ID	Recency	Frequency	Monetary	Total_Profit	Cluster
AB-10105	41	10	14473.571	5444.8055	4
CM-12385	37	4	8954.020	3899.8904	4
HL-15040	43	6	12873.298	5622.4292	4
RB-19360	96	6	15117.339	6976.0959	4
SC-20095	349	9	14142.334	5757.4119	4
TA-21385	69	4	14595.620	4703.7883	4
TC-20980	399	5	19052.218	8981.3239	4

FIGURE 68 – Clients du cluster 4

En effet, les 7 clients ont tous des montants très importants, environ 8 954 à 19 052, et des profits d'environ 3 900 à 8 981. C'est donc bien un segment commercial particulier, pas seulement un artefact de la moyenne.

Une autre chose interessante qu'on peut remarquer dans cette extraction est que les clients avec les Customer ID SC-20095 et TC-20980 ont des récences de 349 et 399 jours. Ce sont donc des clients extremement rentables, mais qui n'ont pas acheté depuis un moment. Ces deux là déjà méritent une attention commerciale particulière.

Nous effectuons une ACP sur les données standardisées utilisées par K-Means et nous obtenons :

$$\texttt{Composante principale 1 :}\ 46,67\%$$

$$\texttt{Composante principale 2 :}\ 27,78\%$$

$$\texttt{Variance totale représentée :}\ 74.45\%$$

Donc les deux premières composantes principales expliquent $74,45\%$ de la variance totale des données, dont $46,67\%$ pour la première composante et $27,78\%$ pour la seconde. La représentation en deux dimensions conserve ainsi une part importante de l'information initialement contenue dans les quatre variables utilisées pour la segmentation. Le graphique ACP qui va suivre permet donc d'obtenir une visualisation globalement représentative de la structure des clients et de la séparation obtenue par K-Means, même si une partie de l'information $(25,55\%)$ n'est pas représentée sur ces deux axes.

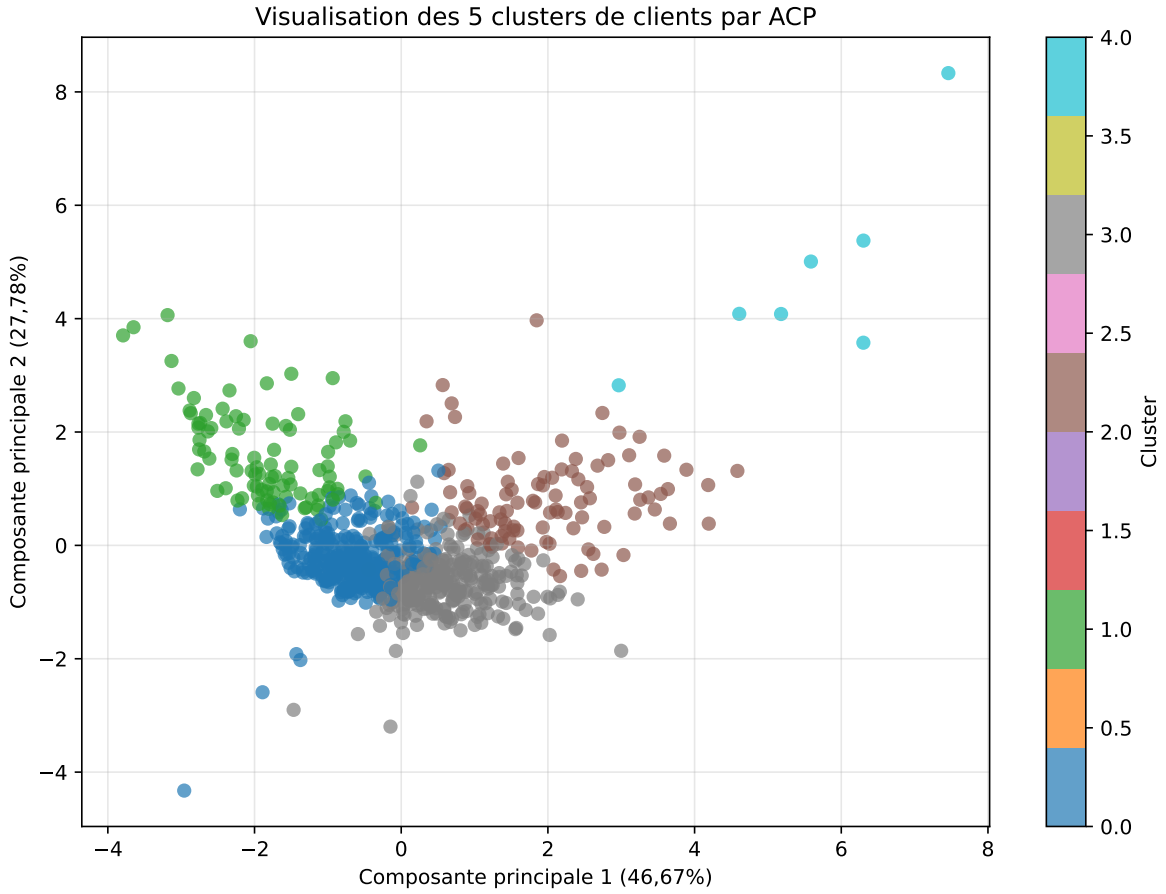


FIGURE 69 – Visualisation des 5 clusters clients par ACP

Le graphique ACP est aussi très intéressant pour valider le clustering. On voit que les différents groupes occupent des zones différentes du plan, même s'ils se chevauchent partiellement, ce qui est tout à fait normal puisque quatre dimensions sont projetées sur seulement deux composantes. En outre, les 7 clients exceptionnels se détachent encore fortement dans la partie supérieure droite. Cela renforce l'idée que le K-means à 5 clusters apporte réellement une information supplémentaire par rapport à 3 ou 4 car il isole un profil rare que ces segmentations plus grossières mélangeaient avec d'autres clients.

Références

[1] Ngomo, L., *Prédiction des prix de logement à partir du jeu de données Ames Housing*, Projet personnel de Data Science, réalisé entre mai et juillet 2026.

[2] Statsmodels, *Seasonal Decomposition using Moving Averages*, Documentation officielle de Statsmodels. Disponible sur : https://www.statsmodels.org/stable/generated/statsmodels.tsa.seasonal.seasonal_decompose.html (consulté en juillet 2026).

[3] Statsmodels, *Ljung-Box test of autocorrelation in residuals*, Documentation officielle de Statsmodels. Disponible sur : https://www.statsmodels.org/stable/generated/statsmodels.stats.diagnostic.acorr_ljungbox.html (consulté en juillet 2026).

[4] Chowdhury, V., *Superstore Dataset*, Kaggle. Disponible sur : https://www.kaggle.com/datasets/vivek468/superstore-dataset-final (consulté en juillet 2026).

[5] Meta Open Source, *Prophet – Forecasting at Scale*, Documentation officielle de Prophet. Disponible sur : https://facebook.github.io/prophet/ (consulté en août 2026)

[6] Statsmodels, *ExponentialSmoothing – Holt-Winter's Exponential Smoothing*, Documentation officielle de Statsmodels. Disponible sur : https://www.statsmodels.org/stable/generated/statsmodels.tsa.holtwinters.ExponentialSmoothing.html (consulté en août 2026).

[7] Statsmodels, *SARIMAX – Seasonal AutoRegressive Integrated Moving Average with eXogenous regressors*, Documentation officielle de Statsmodels. Disponible sur : https://www.statsmodels.org/stable/generated/statsmodels.tsa.statespace.sarimax.SARIMAX.html (consulté en août 2026).

[8] E-marketing.fr, *R.F.M. (récence, fréquence, valeur) – Définition du glossaire*, 6 janvier 2005. Disponible sur : https://www.e-marketing.fr/Definitions-Glossaire/-recence-frequence-valeur-238820.htm (consulté en août 2026).

[9] Scikit-learn, *Selecting the number of clusters with silhouette analysis on KMeans clustering*, Documentation et exemples officiels de Scikit-learn. Disponible sur : https://scikit-learn.org/stable/auto_examples/cluster/plot_kmeans_silhouette_analysis.html (consulté en août 2026).

[10] Google for Developers, *Qu'est-ce que le clustering en k-moyennes ?*, Machine Learning – Cours sur le clustering. Disponible sur : https://developers.google.com/machine-learning/clustering/kmeans/overview?hl=fr (consulté en août 2026).

[11] Scikit-learn, *KMeans – K-Means clustering*, Documentation officielle de Scikit-learn. Disponible sur : https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html (consulté en août 2026).